

# 杭州电子科技大学

## 硕士学位论文

题    目： 面向图像处理应用的生物视觉  
感知计算模型研究

研  究  生 陈  金  龙

专        业 模式识别与智能系统

指导教师 范  影  乐  教  授

完成日期 2013 年 12 月

杭州电子科技大学硕士学位论文

面向图像处理应用的生物视觉  
感知计算模型研究

研究生：陈金龙

指导教师：范影乐 教授

2013 年 12 月

Dissertation Submitted to Hangzhou Dianzi University  
for the Degree of Master

**Study on Biological Visual Perception  
Calculation Model Oriented Image Processing  
Applications**

**Candidate: Chen Jinlong**

**Supervisor: Prof. Fan Yingle**

**December, 2013**

# 杭州电子科技大学

## 学位论文原创性声明和使用授权说明

### 原创性声明

本人郑重声明： 所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

论文作者签名： 日期： 年 月 日

### 学位论文使用授权说明

本人完全了解杭州电子科技大学关于保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属杭州电子科技大学。本人保证毕业离校后，发表论文或使用论文工作成果时署各单位仍然为杭州电子科技大学。学校有权保留送交论文的复印件，允许查阅和借阅论文；学校可以公布论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存论文。（保密论文在解密后遵守此规定）

论文作者签名： 日期： 年 月 日

指导教师签名： 日期： 年 月 日

## 摘 要

在人类了解客观世界的认知功能中，视觉感知系统扮演了举足轻重的作用，从神经计算的角度对视觉感知系统进行建模并应用，对于信息技术以及人工智能技术的研究具有重要的意义。目前随着神经系统研究手段的完善，使人们得以窥探到视觉信息流的检测、传递以及初步编码的过程。但研究者更多从神经生理的角度，去研究和分析视觉感知系统的新特性。而本文尝试利用生物视觉感知的一些重要特性，进行图像处理的实际应用。本文首先构建级联双稳态模型以及阵列级联 FitzHugh-Nagumo(FHN)神经元模型，利用一定强度的噪声能够增强弱信号感知的生物视觉特性，解释随机共振机制在视觉感知系统功能中所扮演的重要角色；其次提出基于方向响应的 Integrate-and-Fire(IF)神经元模型，尝试利用视觉感知的方向选择特性以及神经脉冲编码机制，并以图像边缘检测应用为例，解释视觉感知方向敏感特性及脉冲发放特性在视觉感知中所扮演的关键角色；最后本文以低剂量肺部 CT 图像为例，进行了图像增强的随机共振机制，以及图像边缘检测的神经元方向敏感特性的实际应用。本文主要工作和研究成果如下：

- (1) 提出了一种基于级联双稳态模型的弱信号随机共振增强新方法。研究了级联双稳态模型对于一维模拟信号的随机共振响应，给出了利用定量评价指标选取模型最优参数的方法；采用光栅扫描法实现二维图像的降维，解决了图像增强中行-列级联双稳态模型的输入维数问题，给出了图像增强应用的思路 and 实现步骤。实验结果表明新方法具有低通滤波特性，能够有效去除信号峰值处的毛刺，凸显信号的轮廓。
- (2) 在级联特性的基础上，考虑了视觉皮层神经元在信息流传递和处理中的阵列特性，提出了一种基于阵列级联 FHN 神经元模型的弱信号随机共振增强新方法。研究了阵列级联 FHN 神经元模型对于一维含噪信号的随机共振响应，综合应用光栅扫描和 Hilbert 扫描降维方法，有效保留了图像的空间结构相关特性，给出了应用于二维图像增强的基本思路。新方法充分利用了阵列级联 FHN 模型以及噪声之间的协同作用。实验结果表明：新方法使输出信号更加光滑，信号轮廓与细节得到了加强，噪声在一定程度上得到了有效的抑制，且对内噪声强度具有较强的鲁棒性和自适应性。
- (3) 针对视觉感知中神经元响应具有的激励方向选择特性，提出了一种图像边缘检测的新方法。提出对图像进行 Log-Gabor 滤波器多方向分解，以充分反映视觉系统的方向选择性；并利用 IF 神经元模型的脉冲发放以及编码特性，实现低剂量肺部 CT 图像的边缘检测。实验结果表明：与传统的图像边缘检测方法相比，新方法能够丰富图像的细节，改善图像的边缘特性，加强图像的层次感。

**关键词：**图像处理，视觉机制，随机共振，信号增强，边缘检测

## ABSTRACT

The visual perception system plays an important role in the human cognitive function of understanding the objective world. Modeling and applying for visual perception system from the perspective of neural computation, which has an important significance for the research of information technology and artificial intelligence technology. Currently, the improvement of neurological system research device allows people to take a furtive glance into the process of visual information flow detection, delivery, and coding. But researchers more study and analyze the new features of visual perception system from neurophysiologic perspective. Our paper attempted to take advantage of some important characteristics of biological visual perception to achieve practical application of image processing. Firstly, the model based on cascade-bistable and array-cascade FitzHugh-Nagumo (FHN) neuron model were applied to utilize a certain intensity noise can enhance the biological visual characteristics of perception of weak signals, and explain the mechanism of stochastic resonance plays an important role in the visual perception system function. Second, the model based on the orientation response Integrate-and-Fire (IF) neuron was proposed to achieve the application in image edge detection from the perspective of the characteristics of neurons orientation selection and the mechanism of impulse release and encode, and explain the key role of the characteristics of orientation sensitivity and impulse release in the visual perception. Finally, low-dose lung CT images were used for practical application of image enhancement with stochastic resonance mechanism and image edge detection with neurons orientation sensitive character. The main work and research results of this thesis are summarized as follows:

- (1) A new weak signal enhancement method based on stochastic resonance mechanism of cascade bistable model was presented. The thesis studied on the stochastic resonance signal enhancement ability of cascade bistable model on the one-dimensional analog signal. The method of selection the optimal parameter was given by using a quantitative evaluation index. The Raster scanning method was used for image dimension reduction to solve the input dimension problem in image enhancement of row-column cascade bistable model. The idea and implementation steps of image enhancement of cascade bistable model were given in this paper. The experimental results showed that the propose method had a low-pass filter characteristic, removed the signal peak burr effectively and highlighted the contours of signal.
- (2) Consider the array characteristic of visual cortical neurons in the information flow

transmission and processing based on the cascade characteristic, a new weak signal enhancement method based on stochastic resonance mechanism of array-cascade FHN neuron model was proposed. The thesis researched the stochastic resonance response of array-cascade FHN neuron model on the one-dimensional signal with noise. The method combined with raster scanning and Hilbert scanning was used image dimension reduction to retain the spatial structure correlation properties of image. The basic idea of application in image enhancement was given in this paper. The propose method taken advantage of synergy effect between array-cascade FHN model and noise. The experimental results showed that proposed method could make the output signal smoother, reinforce signal contour edges and details, reduce noise effectively, and improve the robustness and self-adaptation to internal noise.

- (3) For the characteristic of incentive orientation selection in the neurons response of visual perception, a new method of image edge detection was presented. To fully reflect orientation selection characteristic of human visual system, the Log-Gabor orientation response model was put forward to image multi-orientation decomposition. The characteristics of impulse release and encode in the IF neurons model were used for low-dose lung CT image edge detection. The experimental results showed that our propose method could enrich image details, improve image edge characteristics, and enhance image edge layering by comparison with the traditional image edge detection methods.

**Keywords:** image processing, visual mechanism, stochastic resonance, signal enhancement, edge detection

## 目 录

摘 要.....	I
ABSTRACT.....	II
第 1 章 绪论.....	1
1.1 研究目的与意义.....	1
1.2 国内外研究现状.....	2
1.3 本文主要工作及创新点.....	4
1.4 论文的组织结构.....	5
第 2 章 非线性动力系统的随机共振计算模型.....	7
2.1 阈值模型.....	7
2.2 双稳态模型.....	8
2.3 神经元模型.....	9
2.3.1 Hodgkin-Huxley 神经元模型.....	9
2.3.2 FitzHugh-Nagumo 神经元模型.....	10
2.3.3 Integrate-and-Fire 神经元模型.....	10
2.4 小结.....	11
第 3 章 基于级联双稳态随机共振机制的弱信号增强研究.....	12
3.1 弱信号增强概述.....	12
3.2 级联双稳态模型.....	13
3.3 随机共振弱信号增强的定量评价指标.....	13
3.3.1 信噪比和互相关系数.....	13
3.3.2 信噪比改善因子和峰值信噪比.....	14
3.4 基于级联双稳态随机共振机制的弱信号增强研究.....	14
3.4.1 一维周期弱信号随机共振增强研究.....	15
3.4.2 一维非周期弱信号随机共振增强研究.....	17
3.4.3 二维灰度图像弱信号随机共振增强研究.....	19
3.5 小结.....	24
第 4 章 基于阵列级联FHN神经元的弱信号随机共振增强研究.....	25
4.1 阵列级联FHN神经元模型.....	25
4.2 基于阵列级联FHN神经元的一维弱信号随机共振增强研究.....	26
4.2.1 一维周期弱信号随机共振增强研究.....	26
4.2.2 一维非周期弱信号随机共振增强研究.....	28



4.3 基于阵列级联FHN神经元的二值图像弱信号随机共振增强研究.....	30
4.3.1 图像降维方法.....	30
4.3.2 算法步骤.....	30
4.3.3 实验结果与分析.....	31
4.4 小结.....	34
第5章 基于方向响应的IF神经元模型图像边缘检测 .....	35
5.1 图像边缘检测概述.....	35
5.2 基本原理.....	35
5.2.1 方向响应模型.....	35
5.2.2 神经元模型.....	36
5.2.3 最大香农熵.....	36
5.2.4 算法步骤.....	36
5.3 基于方向响应的IF神经元模型图像边缘检测 .....	37
5.3.1 方向响应模型预处理后的直方图分布.....	37
5.3.2 方向响应模型的方向选择性.....	39
5.3.3 不同方法图像边缘检测结果的比较.....	40
5.4 小结.....	42
第6章 随机共振机制和神经元模型在低剂量肺部CT图像中的应用 .....	43
6.1 低剂量肺部CT图像概述 .....	43
6.2 基于双稳态随机共振机制的低剂量肺部CT图像增强.....	44
6.2.1 定量评价方法.....	44
6.2.2 低剂量肺部CT图像增强的实现过程 .....	44
6.2.3 实验结果与分析.....	45
6.3 基于方向响应的IF神经元模型低剂量肺部CT图像边缘检测 .....	48
6.4 双稳态随机共振机制的方向响应IF神经元低剂量肺部CT图像边缘检测 .....	49
6.5 小结.....	51
第7章 总结与展望.....	52
7.1 总结.....	52
7.2 展望.....	53
致谢.....	54
参考文献.....	55
附 录: .....	60

## 第 1 章 绪论

### 1.1 研究目的与意义

人类大脑在地球历史的长河中，虽然只能用稍纵即逝的瞬间来形容，但却显得如此弥足珍贵。人们一直走在认识大脑，利用大脑，甚至创造大脑的梦想路程中。尤其在过去的几十年里，人工智能和仿生技术一直是自动化领域的重要研究内容，神经网络<sup>[1]</sup>、遗传算法<sup>[2]</sup>、模糊理论<sup>[3]</sup>、自组织理论<sup>[4]</sup>以及元胞自动机<sup>[5]</sup>等新概念层出不穷。一方面，随着以事件相关电位ERP<sup>[6]</sup>、功能性核磁共振fMRI<sup>[7]</sup>、双光子显微成像<sup>[8]</sup>以及植入式微电极阵列<sup>[9]</sup>为代表的神经科学实验手段的日趋完备，使得人们有能力从神经元膜上离子通道的开合状态、神经元的兴奋抑制与群体编码，一直到皮层多脑区协作活动展开研究，通过分析生物的智能行为或自然进化法则来理解生物神经系统在感知、记忆、联想以及学习等方面的内在运行机制，从而更好地认识人类自身，为心理或生理疾病治疗和康复提供客观的指导和评估；另一方面，高速计算机并行或分布式计算方式，使得研究者能够从计算模型的角度来仿真或模拟神经系统的部分感知与决策机制，并试图将这种新机制应用于工程领域，例如神经假肢就是建立了运动皮层神经元脉冲发放与外界电子设备响应之间的沟通途径。因此面向工程应用的神经系统计算模型研究，受到了越来越多的关注。

由于人类感知外界环境的绝大部分信息来源于视觉系统，因此视觉神经系统在维持人类认知功能中扮演了举足轻重的作用。而且视觉神经系统具有丰富的生理结构和功能特性，例如弱信号感知时的随机共振特性，感受野以及功能柱在神经回路中的重要作用、视觉方向选择性以及侧抑制的编码机制等，另外视觉神经编码不仅涉及到一种低层次的视觉激励与响应问题，同时也涉及到高级脑区在视觉信息加工时的认知反馈或指导。因此视觉神经系统一直是计算神经科学研究的热门之一，它对于弱信号检测、信息融合、模式识别与人工智能的研究具有重要的指导作用。

目前对于视觉感知神经系统的研究，往往侧重于验证或揭示视觉信息加工过程中所表现出来的心理物理学特性或现象。而对于信息技术领域而言，如何将这种特性或现象应用于智能信息处理中，显得尤为重要和急迫。例如神经电生理实验表明，在生物视觉系统中，适当强度外界噪声的存在，对于弱信号的感知是有益的。后续研究者对此现象进行了建模研究，从理论上验证了此为随机共振特性，改变了传统上人们对于噪声的观点。但如何将生物视觉神经活动中出现的随机共振机制，应用于低信噪比图像的增强，却很少有研究涉及。又例如外侧枕皮质神经元在物体识别时所具有的多种选择模式，但研究者更多关注于实验现象以及视觉功能的描述，并没有考虑如何将方向选择特性或者方向敏感特性选择模式与工程实际结合。

因此本文认为对于计算视觉神经而言，如何准确有效地利用数学模型来表达大脑视觉系统工作的内在机制，固然非常重要。但如何面向具体应用，譬如图像处理应用，来进行模型的构建和实现，显得更为重要。

## 1.2 国内外研究现状

视觉感知是人类了解和认识客观世界的重要手段之一。人类的视觉感知系统是由大量简单的神经元细胞组成，它们通过错综复杂的连接构成一个复杂的网络系统。视觉感知系统从外界杂乱无章的客观世界中筛选有用信息，进而对选择的信息进行逐级编码加工等处理，最后对输入的信息得出高级理解。很久以前，研究者针对视觉感知的实验现象和心理现象进行了研究。随着神经科学和解剖学的不断发展，科学家对灵长类、猫类动物的视觉系统的不断深入研究，使人们对生物视觉感知系统的研究从宏观层面步入微观神经元细胞水平阶段。近年来取得的一些阶段性成果，使人们对视觉感知系统信息获取、加工、理解等有了进一步的认识。

从上世纪 80 年代以来，科学家们对生物视觉感知进行了深入的研究，取得了一定的成果。Hubel等人对视觉感知系统做出了开拓性的研究工作。他们提出的灵长类动物分层视觉感知通路模型，该模型强调了视觉感知系统中的不同神经元通过串行序列连接作用来处理信息，使人们加深了对视觉感知系统的理解<sup>[10]</sup>。Poggio等人于 1985 年在《Nature》期刊上发表了一篇题为《计算视觉和正则化理论》的论文，针对早期的视觉理论需要特定的算法与硬件需求问题，提出了视觉正则化理论，该理论取得了一定的研究成果，解决了初级视觉系统中的不确定性问题，通过对不适定问题的适定化，从而提出了主动视觉理论<sup>[11]</sup>。郭爱克等人于 1995 年在《中国科学》期刊上首次提出了蝇飞行控制系统的视觉感知计算模型。该模型主要通过二层神经回路构成，其中第一层神经回路由运动检测器构成的视觉感知模式输入层，第二层主要由两个平行的视场系统构成的时空整合层。模型的提出有效的解决了时间和空间检测的不连续性问题<sup>[12]</sup>。Grossberg等人率先提出了明度知觉理论，该理论构建了 6 层网络模型，分别从加工亮度、边界和轮廓模型入手，成功的分析了视觉神经系统中的感受野作用机制，有效的模拟了感受野，从而对单眼非彩色的视觉感知做了一定程度的研究<sup>[13]</sup>。Kosslyn等人从认知心理学和神经科学的角度提出了高层视觉加工模型，该模型主要由空间属性编码、目标属性编码、注意选择窗口和联想记忆等几部分组成。该模型模拟了大脑视皮层的多个区的行为，有效的解释了视觉注视特性<sup>[14]</sup>。Linsker和Mougeot通过对视皮层的研究提出了方位柱模型，该模型阐述了空间竞争细胞的出现、方向选择细胞的出现和方位柱的形成三个阶段，并采用 7 层无指导学习方式网络进行模拟，其中连接权的变化符合Hebb规则，通过实验进一步探讨并证实了方位柱的形成机制<sup>[15]</sup>。Lamme对视皮层的前馈反馈机制进行了深入研究<sup>[16]</sup>；Zemel通过对视皮层神经进行研究，从而提出了处理运动的视皮层神经元编码模型<sup>[17]</sup>；Yen等人深入研究了视觉感知系统提取目标轮廓边缘的工作机理<sup>[18]</sup>。上述研究所取得的成果为视觉感知计算模型的后续深入研究奠定了理论基础。

同时从微观角度来看,视觉感知系统有大量的神经元构成,通过对神经元细胞膜离子通道的开启,神经元的兴奋与抑制,神经元动作电位的发放与传导以及神经元动作电位的编码等研究有助于进一步深入理解视觉感知机制。近年来,一些理论研究和生理实验结果表明,单个的神经元、神经元功能团、甚至是整个神经系统在噪声广泛存在的条件下表现出随机共振非线性特性。正是由于随机共振机制的存在,使得神经元中弱信号得到了增强,从而有利于弱信号的检测。随机共振机制在神经系统中的弱信号增强也逐渐受到了研究者的关注。Douglass等人于1993年从龙虾尾扇部的感知细胞感知微弱信号的能力中也发现了随机共振现象的存在,研究结果表明独立神经元可能是感觉系统中可以产生随机共振的基本单元<sup>[19]</sup>。Braun在1994年的实验证实,适宜的噪声有利于鲨鱼神经细胞膜上振荡信号的传播<sup>[20]</sup>。加利福尼亚伯克利分校的Levin通过研究蟋蟀触须的感知细胞,发现了外界的噪声在一定程度上也能够促进蟋蟀对微弱刺激的反映<sup>[21]</sup>。2006年Sakumura等人研究了各层突触随机连接的负反馈神经网络,发现其与神经元膜体对输入刺激的敏感性和放大性上具有类似随机共振响应的特性,由此他们认为实际大脑可能以某种自适应方式在调整神经系统内部噪声的强度<sup>[22]</sup>。后来陆续的研究结果证明随机共振机制有利于视觉感知系统对信号检测能力的增强,如Matthias等人通过模拟眼的微运动所引入的噪声,证实了眼球的微运动有助于增强皮层视觉细胞的视觉分辨率<sup>[23]</sup>,Aihara等人发现视觉系统的信号检测能力在内部和外部噪声叠加情况下显著提高<sup>[24]</sup>,Sasaki等人研究表明添加适当强度的噪声能够促进视觉信号的感知<sup>[25]</sup>,Funke等人通过引入类似眼动范围内的频率和幅度视觉刺激,对猫大脑皮层的17区域进行单电极记录,发现一定强度的视觉刺激有助于改善视觉的信噪比<sup>[26]</sup>。随机共振机制在视觉感知系统中扮演着增强弱信号感知与检测的作用,随着研究的不断深入,研究者尝试将随机共振机制与其他方法相结合,将其应用于图像处理领域,并获得了初步的研究成果,但与传统方法相比,上述方法实现过程相当复杂。如Rallabandi等人提出了双稳态随机共振机制与小波变化相结合的方法,并将其应用于超声图像的增强,从而获得了较理想的图像增强效果<sup>[27]</sup>。之后,Rallabandi等人在上述基础上,又提出了傅立叶变换与随机共振相结合的方法,并将其应用于磁共振图像的增强,也获得了不错的效果<sup>[28]</sup>。Janpaibon S等人在2006年提出采用RGB阈值分割法和自适应随机共振方法,从而有效的实现了彩色物体目标与背景的分割<sup>[29]</sup>。天津大学的冷永刚等人将二维随机共振参数调节用于图像处理领域,获得了双稳态系统参数和变尺度随机共振步长对二维随机共振图像的影响规律,从而有效的提高了图像质量<sup>[30]</sup>。

视觉感知除了表现出上述的随机共振特性外,同时还表现出方向选择特性、神经元动作电位发放机制以及神经元动作电位编码等生理特性。神经生理和心理实验从宏观角度表明了视觉系统在观察事物时具有一定的方向选择性,并非对所有方向产生同样的反应<sup>[31, 32]</sup>。例如Campbell等人的研究表明视觉感知系统对水平或垂直方向的光强变化感知最大,但对于倾斜方向上的光强变化感知最小<sup>[33]</sup>。另外从微观角度来看,初级视皮质存在具有方向选

择性的敏感神经元<sup>[34]</sup>，它们通常被最优方向的边缘所兴奋或抑制<sup>[35, 36]</sup>。而对于其它方向上的视觉刺激，则表现为较弱的响应。最后随着视皮质加工流的延伸，形成复杂的视觉功能。Barlow等人在视觉感知系统神经元编码方面提出了“老祖母细胞”假说。Barlow认为，视觉感知系统中层次分明。信息进行逐级加工，初级视皮层神经细胞对条形或边形感兴趣，颞叶皮层的神经细胞对复杂图形比较敏感。高层次上的神经细胞像“老祖母细胞”一样位于高层，主要对抽象复杂的图像进行识别<sup>[37]</sup>。Attneave等人对视觉感知系统的研究提出了有效编码假说，该理论认为视觉感知的作用是产生输入信号的有效表示。通过对视觉感知系统表现出来的一些生理特性的模拟仿真有助于进一步揭示视觉感知的本质特性<sup>[38]</sup>。

随着对生物视觉感知系统的不断深入研究，人们对生物视觉感知系统的结构和功能机制有了初步的了解。有些研究者们开始尝试从数学模型角度来解释生物视觉感知系统的内在机制，也有研究者开始从神经元微观角度来充分模拟视觉感知系统的结构功能特性以及信息加工形成机制，从而实现不同层次的视觉感知任务。但是他们大多基于视觉通路结构宏观角度构建复杂的数学模型来解释视觉感知，但是忽略了视觉感知系统本身有大量神经元细胞构成，而神经元会表现出相应的微观特性——神经元的随机共振、神经元的方向选择特性、神经元的脉冲发放机制以及神经元编码等。

### 1.3 本文主要工作及创新点

本文研究的主要内容是围绕基于面向图像处理应用的生物视觉感知计算模型来进行展开。一方面侧重于视觉感知系统中随机共振机制计算模型对信号增强的探讨，另一方面结合神经元计算模型的生理特性如方向选择特性、动作电位脉冲发放机制以及神经元编码，将其应用于图像的边缘检测。首先，探讨了级联双稳态模型的随机共振特性，验证了该模型在强噪声背景下具有较理想的信号增强效果。其次，通过构造阵列级联FitzHugh-Nagumo(FHN)神经元模型，探究了该模型的随机共振特性，也进一步证实了该模型能够很好地增强强噪声背景下的弱信号。然后，为了符合视觉感知方向选择的生理特性，引入方向响应模型，同时结合Integrate-and-Fire(IF)神经元模型的动作电位脉冲发放及其编码机制，尝试将其应用于图像边缘检测。最后，将相应的模型应用于具体的实际应用中，本文将结合双稳态随机共振模型和方向响应的IF神经元模型应用于低剂量肺部CT图像的边缘检测，获得了比较理想的结果。

论文具体研究内容包括以下几个方面：

- (1) 本文充分考虑了信号连续级联传递特性，提出了一种基于级联双稳态模型的弱信号随机共振增强方法，在研究了一维含噪模拟弱信号随机共振机制增强响应的基础上，给出了结合定量评价指标选取模型的最优参数方法，为灰度图像的随机共振增强提供了理论指导。针对灰度图像增强应用，选取光栅扫描法将灰度图像从二维空间映射成一维序列，从而有效的解决了图像增强中的输入维数问题，给出了灰度图像增强应用的思路和实现步骤。

- (2) 由于单个 FHN 神经元模型能够反映神经细胞电生理活动的随机共振机制，本文在级联特性的基础上，考虑了神经元的突触多输入连接以及动作电位的连续传递特性，提出了基于阵列级联 FHN 神经元模型的弱信号随机共振增强方法。以一维周期信号和一维非周期信号为例，给出了其在阵列级联 FHN 神经元模型上的随机共振增强响应。在此基础上，尝试将研究对象扩展到二值图像上，综合采用光栅扫描和 Hilbert 扫描方法将图像从二维空间映射到一维空间，有效的解决了图像空间结构特性的保留以及像素之间的关联特性等问题，给出了二值图像随机共振增强的详细实现思路。其中，内噪声强度的变化对阵列级联 FHN 神经元模型的随机共振信号增强是本文的一大关注点，从定性和定量的角度深入研究了内噪声强度的变化对阵列级联 FHN 神经元模型输出的影响。
- (3) 针对神经元视觉感知中表现出的激励方向选择特性及传统图像边缘检测方法并未真实反映视觉感知方向选择特性与神经元动作电位脉冲发放机制等生理特性，提出了基于方向响应的 IF 神经元模型图像边缘检测新方法。提出采用 Log-Gabor 方向响应模型对图像进行多方向分解预处理，以充分反映视觉系统的方向选择特性，利用 IF 神经元模型的动作电位脉冲发放以及编码特性，尝试将其应用于图像的边缘检测。本文方法有效的解决了神经元模型在视觉感知时所表现的生理特性。
- (4) 将随机共振机制模型和神经元模型分别扩展应用到医学图像处理领域，以低剂量肺部 CT 图像为例，研究其在 CT 图像上的增强和边缘检测中的应用。提出了基于双稳态随机共振机制 CT 图像增强方法，有效地解决了图像细节保留与噪声抑制问题，获得较理想的增强效果；给出了基于方向响应的 IF 神经元模型的低剂量肺部 CT 图像边缘检测方法，新方法能够有效的强化图像的轮廓边缘，丰富图像的细节。最后，给出了综合双稳态随机共振机制和方向响应的 IF 神经元模型的 CT 图像边缘检测方法，在图像增强的基础上实现图像的边缘检测，获得了较理想的图像边缘检测结果。

## 1.4 论文的组织结构

本文的主要结构及各章节内容安排如下：

第一章绪论，首先对本文的研究目的、背景以及国内外研究现状进行了概述；介绍了生物视觉感知的研究现状，阐述了视觉神经系统中的随机共振特性、方向选择特性以及视觉信息编码的研究进展；给出了本文的主要研究内容和创新点；最后列出了论文的组织结构和各章节内容的安排。

第二章对常用的非线性动力系统的随机共振计算模型进行了详细介绍，主要包括简单的阈值模型、双稳态模型、Hodgkin-Huxley 神经元模型、FHN 神经元模型和 IF 神经元模型。

第三章构造级联双稳态模型，研究其在一维强噪声背景下的周期信号和非周期信号刺激下的信号增强，发现该模型在一定程度上具有抑制噪声、凸显信号轮廓，进而将其拓展到强噪声背景下的二维灰度图像的增强，结果表明：与单双稳态模型相比，具有低通滤波去噪功能，在一定程度上有效抑制噪声，信号更加光滑平稳，凸显信号轮廓，改善了图像

增强的效果。

第四章构造阵列级联 FHN 神经元模型，首先研究了阵列级联 FHN 神经元模型在一维强噪声背景下的周期信号和非周期信号的增强，分别结合信噪比和互相关系数评价指标进行定量分析。在研究了一维弱信号随机共振增强的基础上，将研究范围拓展到二值含噪弱图像增强，采用光栅扫描和 Hilbert 扫描相结合进行降维，并采用峰值信噪比进行定量分析。实验结果表明：阵列级联 FHN 神经元模型能够有效抑制噪声，凸显信号轮廓边缘与细节，同时对内噪声具有较强的鲁棒性。

第五章提出了基于方向响应的 IF 神经元模型，并将其应用于图像边缘检测。通过与传统的图像边缘检测方法相比，结果表明本文方法不仅能够真实的反映生物特性——视觉感知方向选择特性和神经元动作电位脉冲发放机制，而且能够丰富图像细节，凸显图像轮廓，具有较理想的边缘检测结果。

第六章以低剂量肺部 CT 图像为例，首先引入简单双稳态随机共振模型对其进行图像增强，与传统方法相比，本文方法能够凸显图像中的有用信息，保留更多的细节，图像增强效果显著。其次采用基于方向响应的 IF 神经元模型对其图像边缘检测，与传统方法相比较，本文方法具有凸显图像轮廓，丰富图像细节等效果。最后，将双稳态随机共振模型和基于方向响应的 IF 神经元模型相结合，发挥两者的优点，即先采用双稳态随机共振模型对低剂量肺部 CT 图像进行增强，在此基础上采用方向响应的 IF 神经元模型对其进行边缘检测，获得较理想的效果。

第七章对本文的研究内容进行总结和归纳，对后续进一步的研究内容和目标进行了展望。

## 第2章 非线性动力系统的随机共振计算模型

正如前述，视觉神经系统在视觉感知中往往会表现出随机共振特性，即一定强度的噪声对视觉神经系统的弱信号检测具有增强作用，从而增强视觉感知能力。随机共振机制是基于非线性系统、噪声和输入信号三者之间的协同作用，系统输出信号被噪声能量所增强，从而达到改善输出信号质量的目的。其中非线性动力系统是产生随机共振机制现象不可或缺的因素，它将特定强度的噪声信号能量向有用信号能量进行转化，从而增强非线性系统对弱信号的响应能力。对于某些非线性动力学模型，可以通过调节模型的参数或调节添加噪声信号的强度，使给定的弱信号的输入和输出达到最大的相关性，即类似于动力学系统中的共振现象。其随机共振机制示意图如图 2.1 所示。

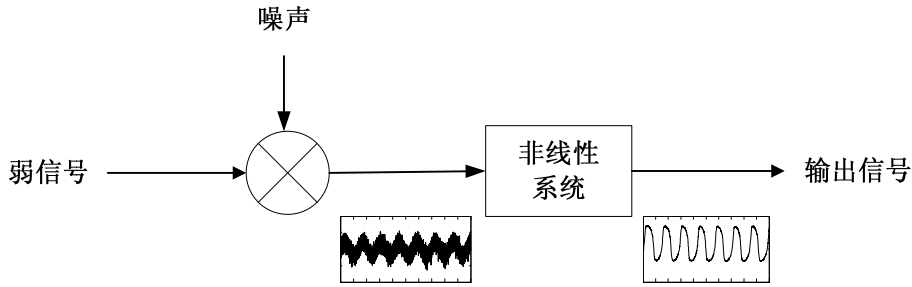


图 2.1 随机共振机制示意图

人们最初对随机共振机制的研究主要集中于简单的双稳态系统模型，对其进行了一系列的理论和应用研究。近年来，随着神经电生理学研究的进展，随机共振机制被逐渐扩展到神经元模型中，从简单的 Integrate-and-Fire(IF)神经元、FitzHugh-Nagumo(FHN)神经元模型再到复杂的 Hodgkin-Huxley(HH)神经元模型。

### 2.1 阈值模型

阈值模型被公认为是神经网络研究的基本模型，且被视为一种简化的可兴奋性神经元模型。有研究发现，施密特双稳态电路中存在阈值模型，且在后续的一些实际系统中也陆续发现存在阈值模型。阈值模型的经典解析表达式如式(2.1)所示<sup>[39]</sup>：

$$v(x) = \begin{cases} l, & x \leq \eta \\ h, & x > \eta \end{cases} \quad (2.1)$$

其中  $\eta$  为双稳态模型的阈值， $l$  和  $h$  分别为系统输出对应的低电平和高电平 ( $l < h$ )， $v(x)$  为双稳态模型的输出信号， $x$  为模型的输入信号。当输入信号低于阈值时，系统不存在输出响应；只有当输入信号高于阈值时，系统才会有对应的输出响应。虽然输入信号幅值低于设定的阈值时没有系统输出，但是噪声的添加使得弱信号在某些时刻超过阈值，从而使系统产生输出响应。尤其在输入信号的峰值处，噪声和输入弱信号相互叠加后增大了系统越



过阈值的机会，从而使系统产生输入响应。因此，在一定程度上，含噪信号的阈值系统的输出能够有效地反映添加噪声后输入信号的变化情况。这种通过引入噪声来增强输入信号响应的现象被称为随机共振现象，阈值模型随机共振示意图如图 2.2 所示。

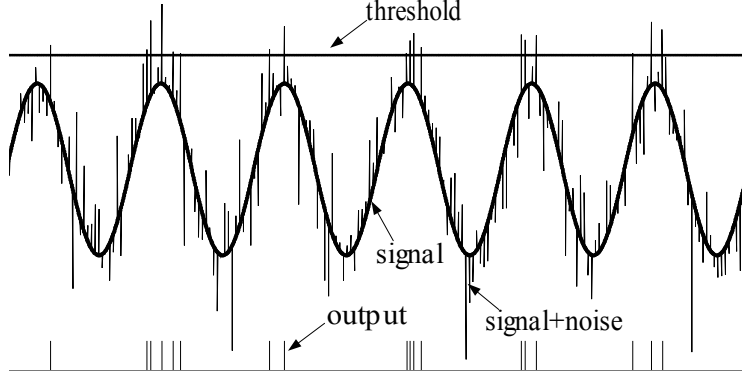


图 2.2 阈值模型随机共振示意图

## 2.2 双稳态模型

随机共振机制的经典非线性模型为双稳态模型，该模型由朗之万(Langevin)方程按式(2.2)描述<sup>[40]</sup>：

$$\frac{dx}{dt} = ax - bx^3 + f(t) + \xi(t) \quad (2.2)$$

其中，方程中的系数  $a$  和  $b$  为正数， $f(t)$  为双稳态系统的无噪输入信号； $\xi(t)$  是输入信号中的噪声项，通常用高斯噪声模拟， $\xi(t)$  满足以下两个条件：(1) 统计平均  $\langle \xi(t) \rangle = 0$ ；(2) 自相关函数  $\langle \xi(t)\xi(0) \rangle = 2D\delta(t)$ ， $\delta(t)$  表示冲激函数， $D$  表示噪声强度。相应地，系统的势函数表示为：

$$U(x) = -\frac{a}{2}x^2 + \frac{b}{4}x^4 - x \cdot (f(t) + \xi(t)) \quad (2.3)$$

则朗之万(Langevin)方程进一步可以由势函数  $U(x)$  来描述：

$$\frac{dx}{dt} = -\frac{dU(x)}{dt} \quad (2.4)$$

势函数  $U(x)$  可以用以描述由两个势阱所组成的双稳态模型。特殊条件下，当噪声强度和输入信号的幅值均为零时，此时系统内存在着两个对称的双势阱，分别对应着系统中的两个稳定状态。其中，阱底位置分别位于  $x_m = \pm\sqrt{a/b}$  处，通过势函数能够求出系统的势垒高度为  $\Delta U = a^2/4b$ 。外力的存在使双稳态周期性的发生倾斜，为系统的输出状态越过势垒在两个势阱之间跃迁提供了条件。双稳态系统的临界值为  $C = \sqrt{4a^3/27b}$ ，当施加于系统的外力小于临界值  $C$  时，质点只会在两势阱之间做局部周期运动，只有当施加的外力大于临界值  $C$  时，质点才能在两势阱间进行跃迁。外界噪声的存在使得施加于系统的外力小于临界值  $C$  的情况下也能在两势阱间进行跃迁。双稳态响应示意图如图 2.3 所示：

有研究表明：双稳态系统如果要产生随机共振现象必须具备如下三个条件：吸引子存

在势垒的双稳态模型、低于势垒的输入信号和一定强度的噪声。随机共振正是基于噪声、输入信号和非线性系统三者之间的协同作用才得以实现的。




图 2.3 双稳态响应示意图

由前面双稳态模型的势阱数学表达式  $x_m = \pm\sqrt{a/b}$  和势垒高度表达式  $\Delta U = a^2/4b$  可以发现系统的参数变化将会直接影响双稳态模型的势阱位置和势垒高度。因此，通过合理调整系统的参数也能实现双稳态模型的状态变化，使其发生随机共振现象，从而显著提高系统输出信号的质量。同时也进一步说明了系统参数的变化同样也能达到改善信号质量的目的，从数学角度层面诠释了使其发生随机共振所具备的条件。

## 2.3 神经元模型

神经元是神经系统的基本结构和功能单位，其由胞体和突起(树突和轴突)组成。神经元具有阈值特性，且神经元内外部广泛存在着噪声，这为随机共振机制的发生提供了客观条件，也进一步说明了神经元具备随机共振现象发生的生理基础。许多感官神经元利用随机共振机制检测微弱的小信号，如虾和鱼等动物通过感官神经元利用随机共振机制灵敏地检测周围噪声环境下的天敌，也从另一角度进一步证实了神经元利用随机共振现象来对外界微弱刺激进行感受、检测以及传导。HH 神经元模型既满足神经电生理特性又符合动作电位的产生和传递特性，因此常被作为随机共振可兴奋细胞研究的经典模型。而其中 FHN 神经元和 IF 神经元模型是作为 HH 神经元的简化可兴奋性模型，也在神经元随机共振工程领域得到了广泛的应用。

### 2.3.1 Hodgkin-Huxley 神经元模型

Hodgkin和Huxley等人研究乌贼轴突隔膜电流随时间和电压的变化情况，在 1952 年首次提出了一个定量数学模型，用于描述波在乌贼神经中的传播<sup>[41]</sup>。同时该模型既具有神经电生理特性，又符合动作电位产生和传导等规律，可以有效的解释神经元膜电位与电流的刺激两者之间的关系。它的提出对于后续研究生物神经系统中的非线性特性具有重要的指导意义，HH神经元模型的数学表达式如式(2.5)所示：

$$\begin{cases} C_m \frac{dV}{dt} = I_{ext} - g_{Na} m^3 h (V - V_{Na}) - g_K n^4 (V - V_K) - g_L (V - V_L) \\ \frac{dm}{dt} = \frac{(m_\infty(V) - m)}{\tau_m(V)} \\ \frac{dh}{dt} = \frac{(h_\infty(V) - h)}{\tau_h(V)} \\ \frac{dn}{dt} = \frac{(n_\infty(V) - n)}{\tau_n(V)} \end{cases} \quad (2.5)$$

其中,  $V$  为细胞膜电压;  $g_{Na}$ 、 $g_K$ 、 $g_L$  分别代表钠离子通道、钾离子通道和漏电流通道的最大电导,  $V_{Na}$ 、 $V_K$ 、 $V_L$  分别代表相应通道的逆转电位;  $C_m$  为细胞膜电容;  $m$  和  $h$  为钠离子通道的门控变量,  $n$  为钾离子通道的门控变量;  $m_\infty(V)$ 、 $h_\infty(V)$ 、 $n_\infty(V)$  和  $\tau_m(V)$ 、 $\tau_h(V)$ 、 $\tau_n(V)$  分别为  $m$ 、 $h$ 、 $n$  的饱和值和时间常数。  $I_{ext}$  为外部电流输入之和, 即  $I_{ext} = I_0 + S(t) + \xi(t)$ 。  $S(t)$  是神经元的检测对象;  $I_0$  为恒定刺激, 用以模拟周围环境对该神经元的一种总和输入;  $\xi(t)$  为高斯白噪声, 满足以下两个条件:  $\langle \xi(t) \rangle = 0$ ,  $\langle \xi(t_1)\xi(t_2) \rangle = 2D\delta(t_1 - t_2)$ ,  $D$  为噪声强度,  $\delta(t)$  为冲激函数。

### 2.3.2 FitzHugh-Nagumo 神经元模型

由FitzHugh R.和Nagumo J.于 20 世纪五六十年代首次提出了FHN模型。该模型是Hodgkin-Huxley(HH)模型的简化, 只有简单的两变量形式。该模型不仅保留了易兴奋神经细胞再生激发机制的特征, 而且也能用于描述神经和心肌纤维电脉冲的激发阈值存在、相对和绝对的恢复周期和在外电流作用下的脉冲链的产生等特性。因而, FHN神经元模型被广泛用于可激发系统的性质及螺旋波的规律研究。其数学表达式可用式(2.6)描述<sup>[42]</sup>:

$$\begin{cases} \varepsilon \frac{dv}{dt} = v(v-a)(1-v) - w + A_T - B + I_{ext} \\ \frac{dw}{dt} = \gamma(v-w-b) \end{cases} \quad (2.6)$$

其中,  $I_{ext}$  为外部输入电流,  $I_{ext} = S(t) + \xi(t)$ ,  $S(t)$  为输入信号,  $\xi(t)$  为高斯白噪声, 满足以下条件:  $\langle \xi(t) \rangle = 0$ ,  $\langle \xi(t_1)\xi(t_2) \rangle = 2D\delta(t_1 - t_2)$ ,  $D$  为噪声强度,  $\delta(t)$  为冲激函数,  $v$  为快变的神经元细胞膜电压;  $w$  为慢变的恢复变量;  $\varepsilon$  和  $\gamma$  为时间常数, 决定神经元细胞的点火速率;  $A_T$  为临界值, 促使神经元细胞定期点火;  $B$  为信号电平均值与  $A_T$  的差值;  $a$ 、 $b$  为方程组常数。

### 2.3.3 Integrate-and-Fire 神经元模型

虽然HH神经元模型能够模拟神经脉冲传导等一系列复杂的生理现象, 但是其数学表达式比较复杂, 模型的求解较困难, 出于对时间效率的考虑, 研究者对HH神经元模型进行简化, 降低其运算复杂度, 上述FHN神经元模型便是其中的一类, 另一类简化模型为IF神经元模型。由Lapicque于 1907 年提出IF神经元模型, 该模型有效的保留了HH神经元模型的生

物特性，同时简化了支配神经元的细胞膜动作电位，忽略了具体离子通道构造的动力学系统，集中研究其发放机制。其模型的数学表达式如式(2.7)所示<sup>[43]</sup>：

$$\begin{cases} \tau_m \frac{dV_t}{dt} = -V(t) + RI(t) \\ V(t_j^f) = V_{th} \\ \lim_{\Delta t \rightarrow 0} V(t_j^f + T_{ref} + \Delta t) = V_{rest} \end{cases} \quad (2.7)$$

其中， $V_t$  表示神经元的细胞膜电压； $V_{th}$  为细胞膜电压阈值； $V_{rest}$  为细胞静息电压； $\tau_m$  表示细胞膜时间常数，由钠离子通道和漏电流通道的平均传导率决定； $I(t)$  表示 IF 神经元模型的输入电流，是由各个前突触神经元细胞产生的电流之和，其表达式如式(2.8)所示：

$$I(t) = \sum_j \sum_{t_j^f} \omega_j \alpha(t - t_j^f) \quad (2.8)$$

$\omega_j$  表示第  $j$  个前突触神经元对后突触神经元的权重； $\alpha(t - t_j^f)$  表示后突触神经元反应形式； $t_j^f$  表示前突触神经元的第  $j$  个突触发放动作电位的时间。当后突触神经元的细胞膜电压超过阈值  $V_{th}$  时，说明该神经元发放了动作电位。当发放一个动作电位后，立刻重设细胞膜电压值等于静息电压值。

随着IF神经元模型研究的不断深入，逐渐出现了多种形式的IF神经元模型，比如：简单的IF神经元模型、适应的IF神经元模型、爆发的IF神经元模型、二次IF神经元模型、Izhikevich 神经元模型等<sup>[44]</sup>。上述研究的模型主要基于如下考虑：一方面实现神经元真实的生理特征，另一方面改进模型的执行效率。

## 2.4 小结

本章主要介绍了视觉感知中的非线性随机共振数学计算模型，分别为阈值模型、双稳态模型、神经元模型。其中，阈值模型和双稳态模型是早期随机共振机制研究领域中最早的、应用最广泛的模型。随着生理学实验研究的发展，出现了旨在模拟神经元动作电位发放机制和神经元电信号传导的神经元模型，本章主要介绍了三种模型，分别为 HH 神经元模型、FHN 神经元模型和 IF 神经元模型。其中 HH 神经元模型，可以很好的满足神经电生理特性，有效的描述了神经元轴突中电压和电流之间的关系，但是其解析表达式较复杂，计算求解较困难，因而出现了 FHN 神经元模型和 IF 神经元两种简化模型，这两种模型在神经元非线性系统中得到了广泛的研究。

### 第3章 基于级联双稳态随机共振机制的弱信号增强研究

人类主要通过视觉来感知外界世界中的大部分信息，因而视觉感知系统在人类认识客观世界中扮演着不可替代的作用。视觉感知系统是一个具有复杂生理特性的系统，由大量的简单神经元细胞通过相互之间的连接以及耦合作用构成。视网膜通过感光神经元细胞从外界客观世界中获取有用信息并转化为神经电信号，经过中间层的传输，并在神经节细胞层进行信息处理，然后经过侧膝体对加工的信息送至初级视皮层进一步加工，最后通过高层皮层区域神经元对感知的信息获取高级的理解和认知功能<sup>[45]</sup>。在整个信息处理加工过程中，视觉感知系统表现出了丰富的生理结构和功能特性，如弱信号感知时的随机共振特性、感受野以及功能柱等在神经通路中的作用、神经元的视觉方向选择特性以及侧抑制、延时反馈等机制特性，因此，视觉感知系统的研究广泛受到了神经电生理学、心理学、计算科学等领域内的研究者的关注。视觉神经系统的研究进展对于弱信号的检测、信息融合以及模式识别与人工智能具有重要的指导意义。自从神经电生理实验记录神经元细胞在信号检测中表现出随机共振特性以来，随机共振在视觉神经系统中逐渐受到研究者们的关注。有研究指出，添加适当强度的噪声有助于促进视觉信息的感知。视觉神经系统中广泛存在着随机共振现象，利用噪声在神经系统表现出来的随机共振特性来增强视觉弱信号的感知，而本章和下一章将从视觉神经系统中表现出来的随机共振特性着手，主要研究如何将随机共振机制计算模型应用于弱信号中的增强。

#### 3.1 弱信号增强概述

信号在产生、记录、传输和处理过程中往往会受到噪声的干扰，噪声的存在严重降低了信号的质量。尤其是在强噪声背景下的弱信号，由于噪声在有用信号中占据着主导，从而使得传统方法的消噪能力被严重削弱，信号增强效果不理想，这就导致后续处理操作如特征提取、边缘检测和信号识别等难以进行。因而，弱信号增强是信号处理环节中的一个重要部分。

目前，常用的信号增强方法主要有线性滤波器信号增强方法<sup>[46]</sup>、维纳滤波信号增强方法<sup>[47]</sup>、基于马尔科夫随机场信号增强方法<sup>[48]</sup>以及小波滤波增强方法<sup>[49]</sup>等。但是这些方法具有一定自身的局限性，比如：线性滤波器中信号混有非叠加性噪声、非高斯噪声或者信号频谱与噪声频谱混叠时，线性滤波器的信号增强效果不理想。维纳滤波信号增强方法需要先验知识，但是这些先验知识往往是未知的，往往只能通过实验对参数进行估计，这存在一定的缺陷；基于马尔科夫随机场信号增强方法主要存在收敛速度问题，该方法计算速度慢，不利于信号增强的实时处理；小波滤波增强方法对均匀的白化噪声的情况不适用。同时上述方法都有着一个根深蒂固的观点，即把噪声视为对有用信号的干扰而试图加以滤除。

虽然在噪声较弱的情况下，上述方法能够取得较满意的效果，但是对于被强噪声淹没的弱信号，由于噪声信号与有用信号之间的差异很小，消噪能力被严重削弱，传统方法的信号增强效果并不是很理想。而且由于它们需要提供噪声相关的先验知识，如噪声类型和强度等，因而在具体应用时存在一定的局限性。

直到随机共振理论的出现，改变了噪声完全有害的传统观点。随机共振基于噪声、非线性系统和输入信号三者之间的协同作用，认为特定强度的噪声能量可以向有用信号能量进行转移，系统输出信号被噪声增强，从而达到改善输出信号质量，达到信号增强的目的。

近几年，已经出现了基于双稳态模型随机共振机制信号增强方法，但是双稳态系统在强噪声背景下信号增强效果不理想，信号峰值存在严重的毛刺现象以及边缘轮廓较模糊等问题，本章充分考虑了信号连续级联传递的特性，对简单双稳态模型进行级联改进，构建级联双稳态模型，探究其在强噪声背景下的弱信号增强作用。

### 3.2 级联双稳态模型

针对单双稳态模型在强噪声背景下信号增强效果不理想，峰值处存在较大的毛刺，信号边缘轮廓模糊等问题，本章在简单双稳态模型基础上进行级联改进，其模型框图如图 3.1 所示，其对应的级联双稳态朗之万方程由式(3.1)和(3.2)来描述：

$$\frac{dx_1}{dt} = a_1 x_1 - b_1 x_1^3 + f(t) + \xi(t) \quad (3.1)$$

$$\frac{dx_i}{dt} = a_i x_i - b_i x_i^3 + x_{i-1}(t) \quad (i = 2, 3, \dots, N) \quad (3.2)$$

其中  $a_i (i=1, 2, \dots, N)$  和  $b_i (i=1, 2, \dots, N)$  为双稳态的正系数， $f(t)$  为双稳态系统第一级的无噪输入信号， $\xi(t)$  是第一级输入信号中的噪声项，通常用高斯噪声模拟， $\xi(t)$  满足以下两个条件：(1)统计平均  $\langle \xi(t) \rangle = 0$ ；(2)自相关函数  $\langle \xi(t)\xi(0) \rangle = 2D\delta(t)$ ， $\delta(t)$  表示冲激函数， $D$  表示噪声强度， $x_{i-1}(t)$  是第  $i-1$  级系统的输出同时作为第  $i$  级系统的输入。




图 3.1 级联双稳态模型图

### 3.3 随机共振弱信号增强的定量评价指标

含噪信号通过随机共振双稳态模型时质量会显著提高，为了定量评价随机共振信号增强的强弱，针对强噪声背景下的一维周期信号和一维非周期信号分别采用信噪比和互相关系数定量评价指标，而对二维图像信号的增强则采用信噪比改善因子和峰值信噪比定量指标来评价随机共振信号增强效果的优劣。

#### 3.3.1 信噪比和互相关系数

信噪比(Signal-to-Noise Ratio, SNR)能够很好的刻画周期信号的随机共振现象。信噪比的定义如式(3.3)所示<sup>[50]</sup>：

$$SNR = 10 \log_{10}(S / B) \quad (3.3)$$

其中,  $S$  和  $B$  分别代表在功率谱密度计算中对应输入周期性激励频率位置处的响应信号峰值和基底噪声强度。本文计算中取功率谱密度中输入信号频率  $f_0$  处的值作为  $S$ , 取  $0.9f_0 < f < 1.1f_0$  (除去  $f_0$  处的值) 的功率谱密度平均值作为  $B$ 。

但是对于非周期信号, 利用信噪比来评价非周期随机共振就不合适了。Collins提出了一种衡量方法——互相关系数  $C$ , 其意味着最大化系统输入输出波形上的匹配关系, 其中互相关系数  $C$  的定义如式(3.4)所示<sup>[51]</sup>:

$$C = \frac{\max \{ \overline{S(t) \cdot R(t + \tau)} \}}{\left[ \overline{S^2(t)} \right]^{\frac{1}{2}} \cdot \left\{ \left[ \overline{R(t) - \overline{R(t)}} \right]^2 \right\}^{\frac{1}{2}}} \quad (3.4)$$

其中  $S(t)$  表示非周期输入信号,  $R(t)$  表示系统响应信号,  $\tau$  表示滞后时间。

### 3.3.2 信噪比改善因子和峰值信噪比

对于强噪声背景下的图像增强结果应该尽量接近原始图像, 这就需要一个客观定量指标来评价图像增强的效果, 可以采用信噪比改善因子(Signal to Noise Ratio Improvement Factor, SIF)和峰值信噪比(Peak Signal to Noise Ratio, PSNR)作为图像增强的定量评价指标。信噪比改善因子的定义如式(3.5)所示<sup>[52]</sup>:

$$SIF = -20 \log_{10} \frac{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} |f'(x, y) - f(x, y)|}{\sum_{x=0}^{M-1} \sum_{y=0}^{N-1} |f_N(x, y) - f(x, y)|} \quad (3.5)$$

其中  $f(x, y)$ 、 $f_N(x, y)$  和  $f'(x, y)$  分别为原始图像、退化图像和由退化图像增强后的图像中点  $(x, y)$  灰度值。 $M$  和  $N$  分别是图像的行数和列数,  $L$  为数字图像的灰度级数。

峰值信噪比反映的是图像信噪比变化情况的一种统计平均, 是用于评价图像质量的客观依据。峰值信噪比的数学表达式如式(3.6)和(3.7)所示<sup>[53]</sup>。

$$PSNR = 10 \times \log_{10} \left( \frac{255^2}{MSE} \right) \quad (3.6)$$

$$MSE = \frac{1}{MN} \sum_{i=0}^{M-1} \sum_{j=0}^{N-1} (I(i, j) - K(i, j))^2 \quad (3.7)$$

其中,  $MSE$  为原始图像与增强图像的均方误差,  $M$  和  $N$  为图像的行数和列数,  $I(i, j)$  为原始图像的第  $i$  行第  $j$  列像素灰度值;  $K(i, j)$  为增强图像的第  $i$  行第  $j$  列像素灰度值。

## 3.4 基于级联双稳态随机共振机制的弱信号增强研究

本章首先分别对一维周期信号和一维非周期信号进行级联双稳态模型实验仿真, 探究

了级联双稳态模型参数的选取对随机共振弱信号增强的影响，在最优参数情况下，从定性和定量的角度分别分析和评价级联双稳态模型信号增强的效果，进而将研究对象拓展到二维灰度图像，采用光栅扫描方法对图像降维，研究了参数选取对弱灰度图像信号增强的影响，在选择最优参数情况下，结合定性和定量分析方法分别评价了级联双稳态模型对灰度图像信号增强的效果，并与单双稳态模型随机共振信号增强的效果进行对比。

不失一般性，本章在后续的仿真研究中选取级联双稳态级数  $N=2$ ，级联双稳态模型中各级中的参数满足  $a_1 = a_2 = a$  和  $b_1 = b_2 = b$  的条件。

### 3.4.1 一维周期弱信号随机共振增强研究

首先研究级联双稳态模型对含噪单频周期信号的响应，选择输入信号为  $A\sin(2\pi f_0 t) + \xi(t)$  作用于级联双稳态非线性系统，其中正弦信号  $A\sin(2\pi f_0 t)$  为系统的周期驱动力， $\xi(t)$  是均值为 0，强度为  $D$  的高斯噪声。参数设定为  $A=0.3$ ， $f_0=0.002$ 。以  $D=0.7$  和  $D=1.5$  为例，从信噪比定量评价指标的角度来选取参数  $a$ 、 $b$ ，但由于同时改变  $a$ 、 $b$  两参数将会使得参数的选取变得较复杂，为了降低参数选取的复杂性，将参数  $a$  设定为某一固定值(本实验选取  $a=1$ )，通过改变系统参数  $b$  来探究其对信噪比的影响，如图 3.2 所示。从图中可以看出大致都是在  $b=1$  附近处取得信噪比的最大值，故取  $a=1$ ， $b=1$  分别进行噪声强度  $D=0.7$  和  $D=1.5$  级联双稳态模型和单双稳态模型信号增强效果的比较。




图 3.2 周期正弦信号级联双稳态模型参数  $b$  对信噪比的关系图

由图 3.3 一维周期正弦信号单双稳态模型与级联双稳态模型输出图中可以看出，(b)图中添加强度  $D=0.7$  的噪声后正弦信号基本被噪声淹没，但是(c)图单双稳态系统输出信号和(d)图级联双稳态模型输出信号都能很好的将正弦信号从噪声背景下恢复出来，系统输出信号基本能够跟随正弦信号的周期变化，同步效果较好，但是相比之下，级联双稳态的增强效果更好，在峰值处较单双稳态输出更加平滑，去掉了毛刺，更加接近原始信号，噪声得到了较好的抑制。



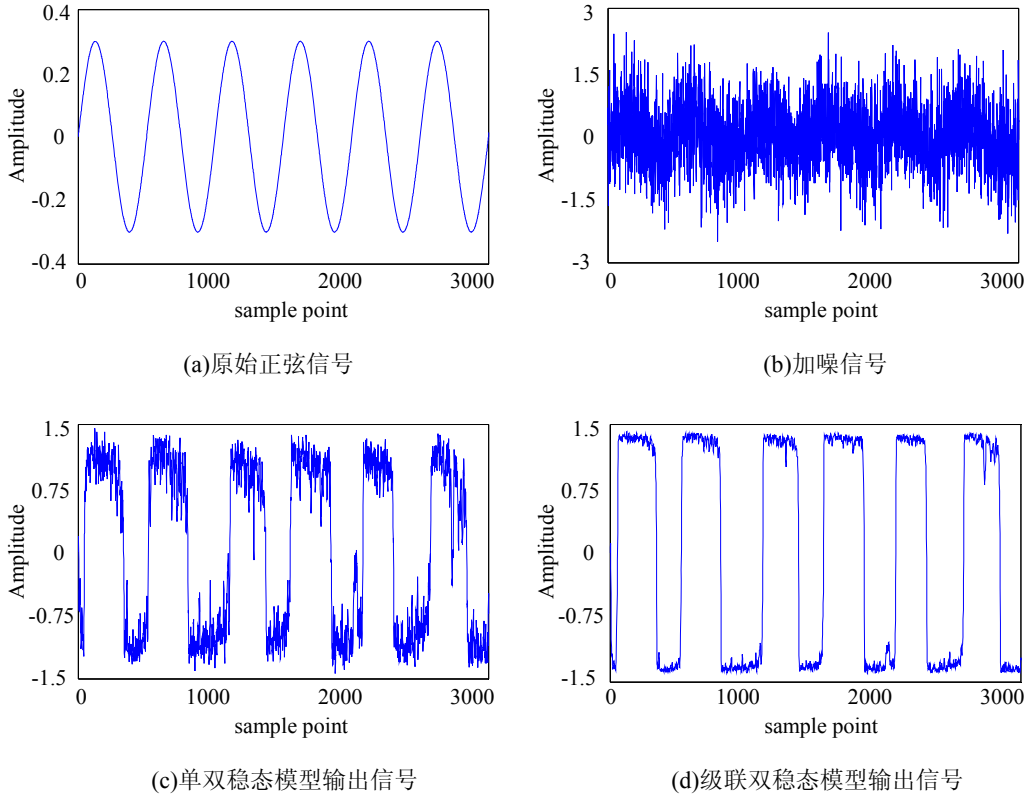

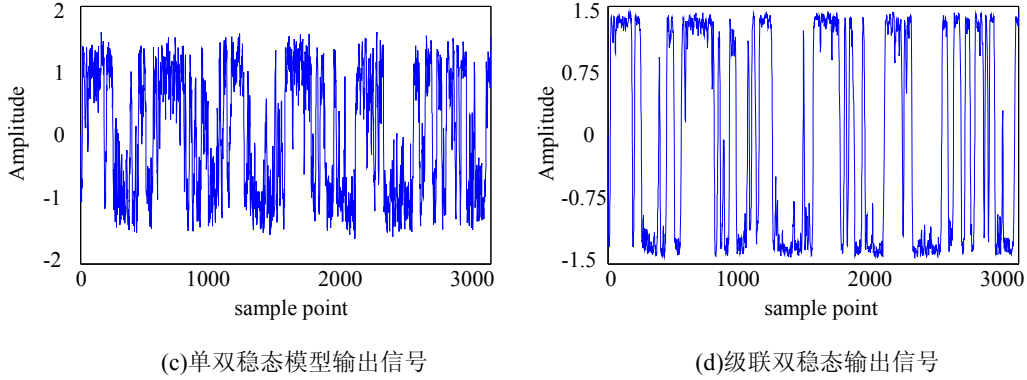


图 3.3 一维周期正弦信号在  $D=0.7$  处单双稳态模型与级联双稳态模型输出比较

继续增大噪声强度使  $D=1.5$ ，其单双稳态模型和级联双稳态模型输出信号如图 3.4 所示，由图可以看出在强噪声背景下，级联双稳态模型信号增强的优势更加明显、效果更好。图 3.4(b)中由于噪声信号强度太大使得原始信号失真被强噪声所淹没，但是级联双稳态的输出信号还是在一定程度上能够反映原始信号的频率变化情况，相比于单双稳态模型的信号增强效果要好得多，增强信号轮廓较清晰，峰值处幅值波动较小，噪声得到了有效地抑制。



图 3.4 一维周期正弦信号在  $D=1.5$  处单双稳态模型与级联双稳态模型输出比较

为了定量评价单双稳态模型与级联双稳态模型信号增强的效果，将信噪比作为定量评价指标，其结果如表 3.1 所示。表 3.1 中的级联双稳态模型输出信号信噪比普遍比单双稳态模型的大，从定量的角度也说明了级联双稳态模型的信号增强的性能要优于单双稳态模型，与主观视觉效果相一致。

表 3.1 不同噪声强度周期信号信噪比对比表

SNR 噪声强度 $D$	类型	单双稳态模型	级联双稳态模型
0.3		4.6621	<b>5.2425</b>
0.5		12.5199	<b>12.8674</b>
0.7		14.3251	<b>14.7102</b>
0.9		15.3501	<b>15.5947</b>
1.1		13.6452	<b>13.8319</b>
1.3		14.4108	<b>14.5781</b>
1.5		12.7528	<b>13.3632</b>


### 3.4.2 一维非周期弱信号随机共振增强研究

对于一维非周期信号，用二进制双极性信号  $S(t)$  作为系统无噪的非周期输入信号

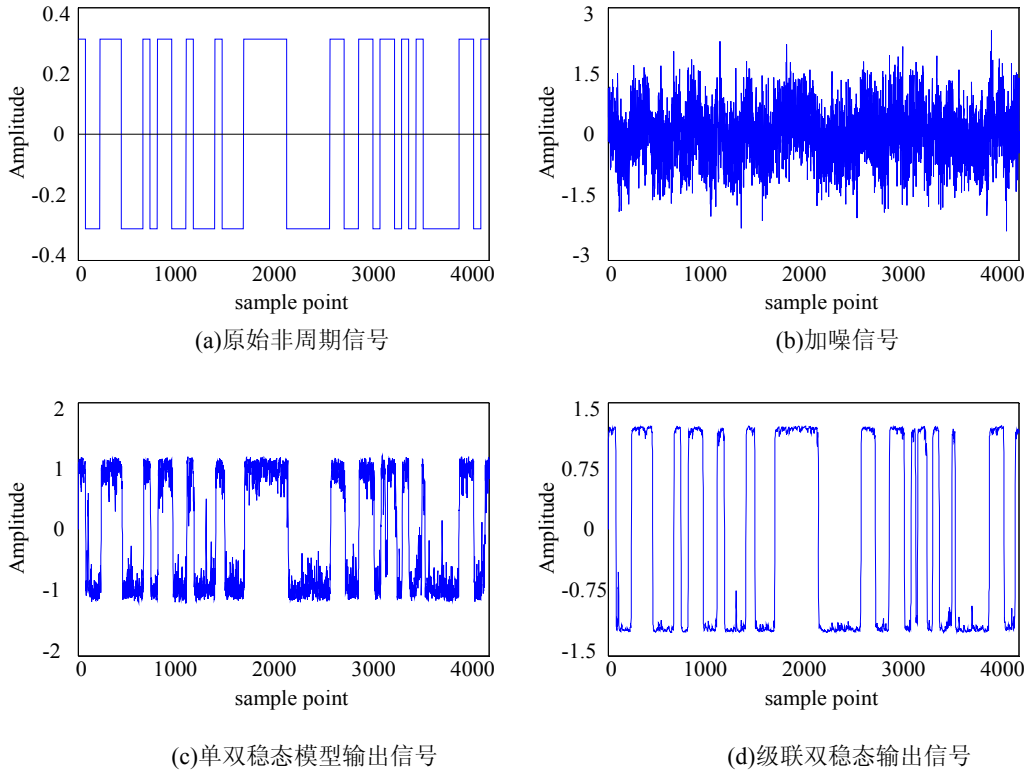
$$S(t) = A \cdot \sum_{j=-\infty}^{\infty} S_j \Gamma(t - jT_j) \quad (3.8)$$

其中信号幅值  $A > 0$  且为常数，而  $\Gamma(t) = \begin{cases} 1 & t \in [0, T_j] \\ 0 & \text{其它} \end{cases}$ ， $T_j$  表示信号的脉宽， $S_j = \pm 1$  为独立

分布的随机变量。参数设定为  $A = 0.3$ ， $T_j = 70$ 。对于一维非周期信号级联双稳态模型参数  $a$  和  $b$  的选取，为了降低参数选取的复杂性，将参数  $a$  固定为某一值(本实验假定  $a = 1$ )，通过改变系统参数  $b$  的选取，探究其对互相关系数的影响，其结果如图 3.5 所示。当使得互相关系数为最优时，此时的参数  $b$  即为需要设定的参数。由图 3.5 可以看出对于噪声强度  $D = 0.6$  和  $D = 1.2$  所对应的最优参数  $b$  分别为 1.2 和 1。取  $a = 1, b = 1.2$  和  $a = 1, b = 1$  分别为  $D = 0.6$  和  $D = 1.2$  的最优参数进行级联双稳态模型和单双稳态模型随机共振信号增强研究。

图 3.5 非周期信号级联双稳态参数  $b$  对互相关系数的关系图

对一维非周期信号叠加强度为  $D=0.6$  的噪声，分别输入单双稳态模型与级联双稳态模型中，获得对应的随机共振输出响应，如图 3.6 所示。对(a)图中的非周期信号加入  $D=0.6$  的高斯白噪声，(b)图的原信号被噪声所淹没，基本反映不出非周期信号的规律，但是分别经过单双稳态模型和级联双稳态模型后基本都能恢复非周期信号，与输入的非周期信号相匹配。通过对图 3.6(c)与(d)的对比发现级联双稳态的效果明显要优于单双稳态模型，在单双稳态输出信号的峰值处仍旧存在较大的噪声，信号幅值波动较大，毛刺较明显，但是级联双稳态输出信号在峰值处较平稳，不存在很大的波动，噪声相对于(c)图明显减少了，级联双稳态模型起到了低通滤波器的作用，使输出信号更光滑，减少了毛刺，与原信号更加匹配。

图 3.6 一维非周期信号在  $D=0.6$  处单双稳态模型与级联双稳态模型输出比较

增大噪声强度使  $D=1.2$ ，单双稳态模型输出信号和级联双稳态模型输出信号如图 3.7

所示。相比于非周期信号的幅值，噪声的幅值远远大于非周期信号的幅值，使非周期信号处于强噪声背景下，这时(b)图中基本由噪声信号占主导。此时(c)图单双稳态输出信号中噪声还是很明显，信号峰值处幅值波动很大，信号阶跃处轮廓模糊，不能很好的跟随非周期输入信号的变化情况，但是(d)图中的级联双稳态模型依旧保持了与非周期信号的同步性，且信号光滑、轮廓清晰，去噪效果好。

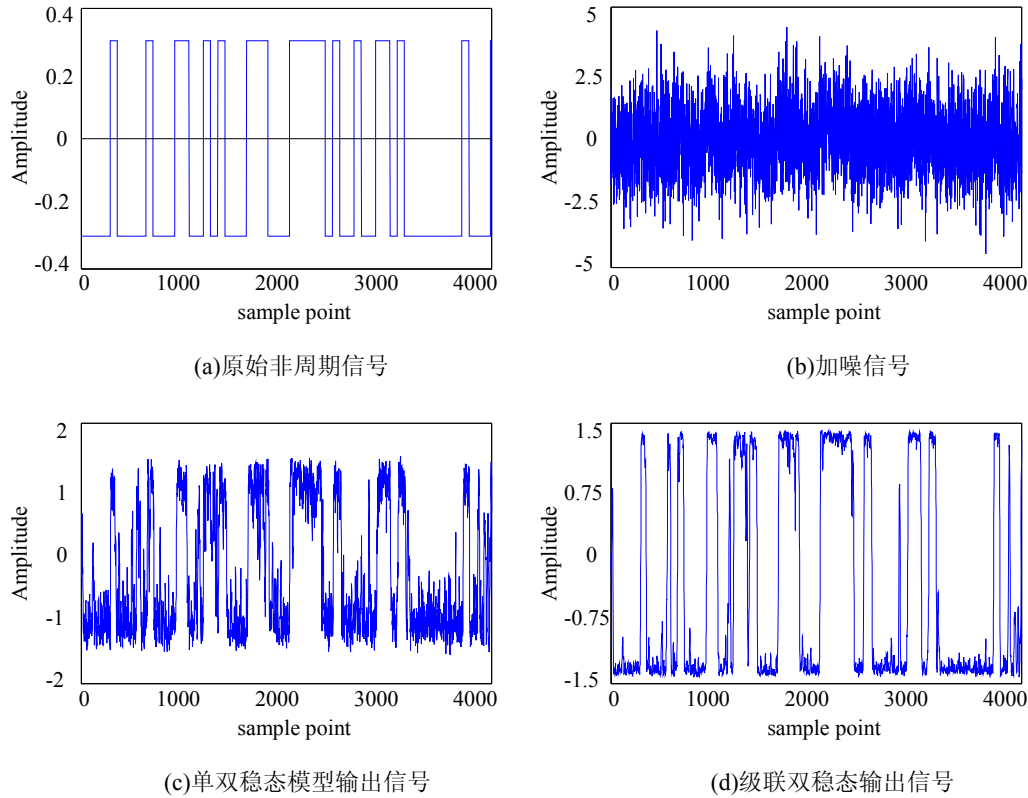


图 3.7 一维非周期信号在  $D=1.2$  处单双稳态模型与级联双稳态模型输出比较

表 3.2 不同噪声强度非周期信号互相关系对比表

类型 噪声强度 $D$	$C$	类型	
		单双稳态模型	级联双稳态模型
0.3		0.8238	<b>0.9819</b>
0.4		0.6513	<b>0.6531</b>
0.5		0.7114	<b>0.7121</b>
0.6		0.9748	<b>0.9941</b>
0.7		0.8148	<b>0.8847</b>
0.8		0.9022	<b>0.9411</b>
0.9		0.8328	<b>0.9777</b>
1.0		0.7761	<b>0.7802</b>
1.1		0.7643	<b>0.7792</b>
1.2		0.7569	<b>0.7772</b>

为了进一步定量说明级联双稳态模型性能优于单双稳态模型的性能，对两者的互相关系数进行比较，如上表 3.2 所示。从表 3.2 中可以看出，改进后的互相关系数评价指标基本

与定性的观察结果相一致，说明了互相关系数能够客观有效地定量评价随机共振信号增强的效果，而且级联双稳态模型的信号增强性能要明显优于单双稳态模型。

### 3.4.3 二维灰度图像弱信号随机共振增强研究

在研究了一维周期信号和非周期信号的基础上，将研究范围拓展到二维灰度图像。本章将二维灰度图像信号转换成一维信号时采用光栅扫描，即水平扫描或垂直扫描，如图 3.8 所示。图 3.8(a)表示对图像进行水平扫描。以左上方为起点，按行依次读取像素，将其存储为一维行序列。垂直扫描以图像的左上方为起点，按列依次读取像素，可将其转换为一维列序列，如图 3.8(b)所示。




图 3.8 光栅扫描方法

考虑到级联双稳态模型的双极性，对原始灰度图像像素取值范围由  $[0, 255]$  映射到  $[-128, 127]$ ，然后加入高斯噪声进行水平扫描将二维图像信号降维成一维行信号序列  $f(n) (n=1, 2, \dots, M \times N)$ 。针对级联双稳态模型输入要求具有小信号参数的特点，将行信号序列按式(3.9)进行归一化处理得  $F(n) (n=1, 2, \dots, M \times N)$ ：

$$F(n) = \frac{f(n) - \min(f)}{\max(f) - \min(f)} (n=1, 2, \dots, M \times N) \quad (3.9)$$

其中  $\min(f)$  表示图像  $M \times N$  个像素中的最小值， $\max(f)$  表示图像  $M \times N$  个像素中的最大值。

然后将归一化序列  $F(n)$  输入行双稳态系统得到行输出序列  $G(n) (n=1, 2, \dots, M \times N)$ ，将  $G(n)$  一维信号还原重构成对应的二维图像信号  $I(n)$  ( $I(n)$  为  $M \times N$  二维矩阵)，对  $I(n)$  进行垂直扫描降维成一维列信号序列  $W(n) (n=1, 2, \dots, M \times N)$ ，将  $W(n)$  输入列双稳态系统得到列输出序列  $R(n) (n=1, 2, \dots, M \times N)$ ，最后对  $R(n)$  按式(3.10)处理

$$g(n) = \frac{255 * (R(n) - \min(R))}{\max(R) - \min(R)} (n=1, 2, \dots, M \times N) \quad (3.10)$$

其中  $\min(R)$  表示输出序列  $R(n) (n=1, 2, \dots, M \times N)$  中的最小值， $\max(R)$  表示输出序列

$R(n) (n=1, 2, \dots, M \times N)$  中的最大值。

进行归一化处理还原为图像像素取值范围  $g(n) (n=1, 2, \dots, M \times N)$ ，使其满足图像像素值为  $0 \sim 255$  的取值范围，进而将一维信号  $g(n)$  重构还原为二维图像，其处理流程框图如图 3.9 所示。

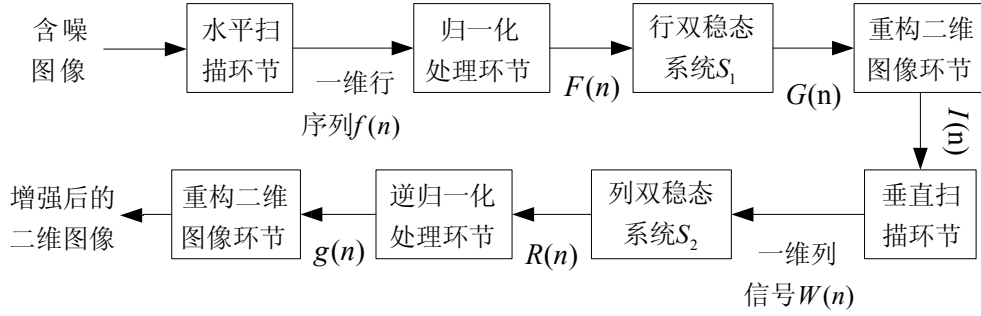



图 3.9 二维图像级联双稳态模型处理流程图

在二维图像级联双稳态随机共振仿真实验中以图 3.10 所示的灰度图像为研究对象，在图像中添加均值为 0，强度  $D=150$  的高斯噪声。对于级联双稳态模型参数  $a$ 、 $b$  的选取，为了减少同时改变参数  $a$  和  $b$  的复杂性，本实验中假定  $b=1$ ，探究参数  $a$  对信噪比改善因子的关系，最终确定参数  $a$  的选取，图 3.10 所对应三幅图像中的参数  $a$  对信噪比改善因子的关系图如图 3.11 所示。



图 3.10 二维图像仿真原始灰度图

纵观图 3.11 中三幅图中参数  $a$  对信噪比改善因子的关系图，Lena 图和 Letter 图的信噪比改善因子随着参数  $a$  的增加而出现递减趋势，而 Cameraman 图随参数  $a$  的增加出现先增后减的趋势，在 0.01 处出现最大值。但是信噪比改善因子评价级联双稳态模型随机共振信号增强效果仅是一方面，还需结合视觉定性分析角度来综合评价图像增强效果，因而对参数  $a$  进行小幅度的微调，最终对三幅图选取统一参数  $a=0.01$  与  $b=1$  进行后续的仿真实验。

图 3.11 参数  $a$  对信噪比改善因子的关系图

本章选择单双稳态模型、 $3 \times 3$  中值滤波和  $3 \times 3$  维纳滤波方法作为级联双稳态模型灰度图像增强的比较对象，其结果如图 3.12、图 3.13 和 3.14 所示。其中级联双稳态是由图 3.9 的流程来处理的，图像通过行与列双稳态系统的级联处理，而单双稳态模型只单独执行了图 3.9 流程的前半部分即行双稳态处理部分。

由图可知，对 Lena 图而言，(c)图和(d)图的传统方法图像增强效果不理想，增强后的图像仍旧被大量噪声淹没，图像模糊，而(b)图单双稳态模型增强后的图的质量与传统方法相比有所提升，在一定程度上去除了少量噪声，但是图像依旧模糊，图像的轮廓依旧淹没在噪声背景中，相比之下，(e)图级联双稳态模型增强后的效果与其它方法相比有较大的改进，噪声得到了有效的抑制，而且凸显了图像的边缘，尤其是帽子的边缘轮廓以及眼睛变得较清晰。对 Cameraman 图而言，定性分析相一致，(c)图和(d)图传统方法增强后的图像模糊，且背景偏暗，受噪声影响依旧比较严重，(b)图的单双稳态模型增强后的图像质量有所改善，相比较图像的轮廓得到了有效的凸显，边缘更清晰，但是不足之处是图像仍旧保留大量的噪声，(e)图级联双稳态增强后的结果较理想，噪声得到了有效的抑制，人的轮廓边缘与细节得到了强化。相比之下，Letter 图的效果最明显，级联双稳态模型方法与其他方法相比，图像增强后的质量得到了显著改善，噪声被大大削弱，轮廓边缘细节得到了凸显且变得更清晰。

随机共振图像增强的效果要优于传统的图像增强方法，这于图像增强的原理相关，传统方法的出发点是基于噪声有害理论，想法设法将噪声滤除，这就在一定程度上不可避免



的削弱了图像中的有用信息，使图像的整体质量变差，图像模糊。而随机共振却恰恰相反，它的出发点是基于噪声有利的思想，将噪声的能量最大化的转化为有用信号的能量，使图像中的有用信号得以增强，从而显著改善图像的质量，这也是随机共振理论的独特之处。

更重要的是，级联双稳态模型增强效果要明显优于单双稳态模型，改进后的方法在一定程度上具有类似于低通滤波器的作用，将有效的抑制高频噪声信号，同时使图像的边缘轮廓信息得到了很好的保留且加以凸显和强化，使其变得更加清晰，同时级联双稳态模型有效的提高了二维灰度图像行列的对等关系，有利于灰度图像通过双稳态系统随机共振处理后的空间结构保留。

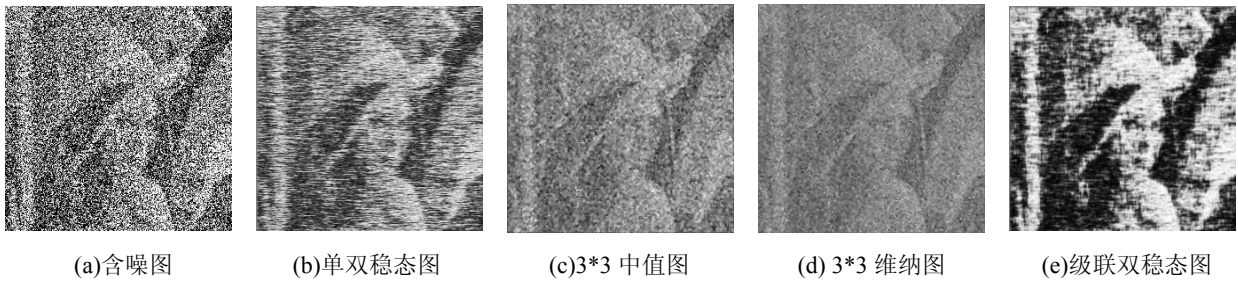


图 3.12 Lena 图像在  $D=150$  处不同方法增强的实验结果图



图 3.13 Cameraman 图像在  $D=150$  处不同方法增强的实验结果图

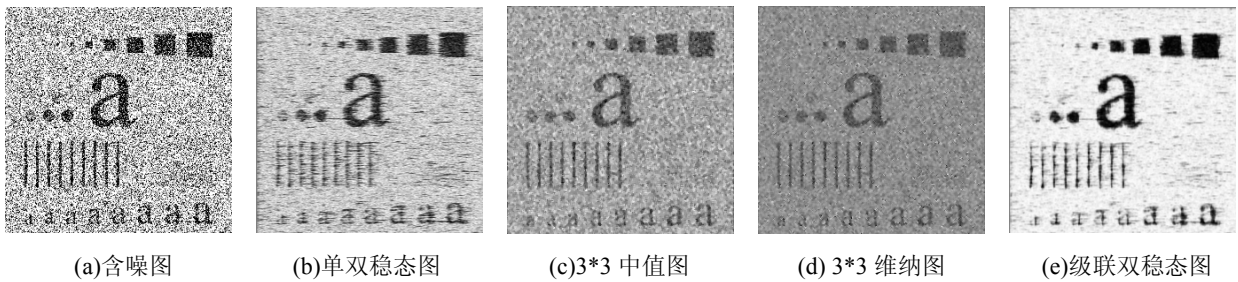


图 3.14 Letter 图像在  $D=150$  处不同方法增强的实验结果图

为了进一步衡量改进后的方法在二维图像增强中性能，采用信噪比改善因子定量评价指标对其进行研究。不同噪声强度以及不同图像增强方法的信噪比改善因子结果如表 3.3 所示。级联双稳态模型方法的信噪比改善因子普遍要高于其他方法，且传统方法的信噪比改善因子整体低于随机共振方法，定量评价指标的结果基本与主观观察结果的定性分析相一致，也进一步说明了改进后的方法图像增强的效果要优于其他图像增强方法。且信噪比改善因子能够有效的作为灰度图像增强的定量评价指标。



表 3.3 不同图像增强方法信噪比改善因子对比表

噪声强度 $D$	$SIF$	类型	单双稳态模型	3*3 中值	3*3 维纳	级联双稳态模型
Lena 图		$D=150$	8.2190	7.6723	7.7405	<b>9.5081</b>
		$D=225$	11.9393	7.6726	7.7327	<b>12.2713</b>
		$D=300$	14.0653	7.7666	7.8600	<b>14.5548</b>
Cameraman 图		$D=150$	8.9774	7.5306	7.7282	<b>9.1380</b>
		$D=225$	11.5975	7.7295	7.8061	<b>12.6965</b>
		$D=300$	13.6363	7.7378	7.8364	<b>14.8532</b>
Letter 图		$D=150$	8.1669	7.0182	7.2876	<b>11.8667</b>
		$D=225$	9.6953	7.2647	7.5497	<b>14.6118</b>
		$D=300$	11.0186	7.4815	7.6743	<b>15.7358</b>

### 3.5 小结

神经电生理实验证实了随机共振特性存在于视觉感知系统中，随机共振特性提高了视觉信号的感知和检测，因此本章从视觉感知中表现出的随机共振特性作为出发点，以级联双稳态模型为研究对象，探究了随机共振机制在信号增强中的应用。首先构造级联双稳态模型，分别对一维周期正弦信号和一维非周期信号进行级联双稳态模型随机共振研究，探究了参数选取对随机共振的影响，在选取最优参数的基础上，对其进行强噪声背景下的弱信号增强仿真实验，从定性和定量的角度对增强效果进行分析和评价，结果表明级联双稳态模型具有低通滤波器的功能，有效的去除了峰值处的毛刺，使信号更加光滑并且凸显信号的边缘轮廓。在一维信号基础上将研究对象扩展到二维灰度图像信号，对图像采取光栅扫描进行降维，幅值映射以及归一化处理，进而构造行-列级联双稳态模型进行仿真并与其它图像增强方法进行对比，揭示了级联双稳态模型具有其它方法无法比拟的优势，随机共振效果更明显，将噪声最大化转化成了有用信号，图像的边缘与轮廓得到了凸显且变得更清晰，同时噪声在一定程度上得到了有效的抑制。

## 第 4 章 基于阵列级联FHN神经元的弱信号随机共振增强研究

考虑到随机共振在强噪声背景下的信号检测、以及目标识别等生物视觉特性中的重要作用，例如有研究在内外噪声叠加情况下，神经电生理实验证实视觉系统的信号检测能力将显著提高<sup>[25]</sup>；也有研究指出添加适当强度的噪声能够促进视觉信号的感知<sup>[24]</sup>。由于单神经元模型能够较好的反映神经细胞电生理活动，因此其激励响应关系经常被用来描绘神经系统在弱信号处理时所表现出来的随机共振特性。目前也出现了基于FitzHugu-Nagumo(FHN)神经元模型的弱信号随机共振检测研究，在图像增强方面也取得了较好的应用<sup>[54]</sup>，但也存在受内噪声影响波动较大，弱信号边缘轮廓模糊等缺点。上述研究的模型通常只考虑了微观的可兴奋细胞电生理特性，而丢弃了宏观的神经元互连特性，而这种神经元连接的网络特性对于神经系统的功能实现是不可或缺的。因此本章提出了一种FHN神经元阵列级联结构，研究神经元之间的串并联连接对于弱信号随机共振检测的作用。通过对一维信号(周期信号和非周期信号)和二维图像的实验仿真，研究阵列级联FHN神经元模型在强噪声背景下的弱信号增强随机共振效果，并与传统单个FHN神经元随机共振信号增强效果及传统信号增强方法进行比较<sup>[55]</sup>。

### 4.1 阵列级联 FHN 神经元模型

如前所述，单个神经元模型能够较好的反映神经细胞电生理活动，但其并没有重点描述神经元突触多输入连接以及动作电位连续传递等特性。本章认为上述特性在神经系统的随机共振机制中扮演了重要的角色，因此提出了一种阵列级联 FHN 神经元模型，如式 4.1 和 4.2 所示，其结构框图如图 4.1 所示。

$$\begin{cases} \varepsilon_1 \frac{dv_{1,i}}{dt} = v_{1,i}(v_{1,i} - a_1)(1 - v_{1,i}) - w_{1,i} + A_{T1} - B_1 + I_{ext} \\ \frac{dw_{1,i}}{dt} = \gamma_1(v_{1,i} - w_{1,i} - b_1) \end{cases} \quad (i=1,2,\dots,n) \quad (4.1)$$

$$\begin{cases} \varepsilon_2 \frac{dv_{2,j}}{dt} = v_{2,j}(v_{2,j} - a_2)(1 - v_{2,j}) - w_{2,j} + A_{T2} - B_2 + v_{2,j-1} \\ \frac{dw_{2,j}}{dt} = \gamma_2(v_{2,j} - w_{2,j} - b_2) \end{cases} \quad (j=1,2,\dots,m) \quad (4.2)$$

其中， $v_{1,i}(i=1,2,\dots,n)$  和  $v_{2,j}(j=1,2,\dots,m)$  分别为阵列环节和级联环节处的快变神经元膜电压； $w_{1,i}(i=1,2,\dots,n)$  和  $w_{2,j}(j=1,2,\dots,m)$  分别为阵列环节和级联环节处的慢变恢复变量； $\varepsilon_k$  和  $\gamma_k$  为时间常数，决定了神经元的点火速率； $A_{Tk}$  为临界值，促使神经元定期点火； $B_k$  为信号电平均值与  $A_{Tk}$  的差值； $a_k$ 、 $b_k$  为方程组常数(其中  $k=1,2$ )； $I_{ext}$  为外部电流输入。

$I_{ext} = S(t) + \xi(t) + \xi_i(t)$ ,  $S(t)$  为输入信号,  $\xi(t)$  为外部高斯白噪声,  $\xi_i(t)$  为内部高斯白噪声 ( $i=1,2,\dots,n$ ), 同样须满足前述噪声条件。  $v_{2,j-1}$  ( $j=1,2,\dots,m$ ) 为级联处前一个神经元的输出值, 当  $j=1$  时,  $v_{2,0} = \sum_{i=1}^n v_{1,i} \times W_i$ ,  $W_i$  表示阵列环节处的权值。

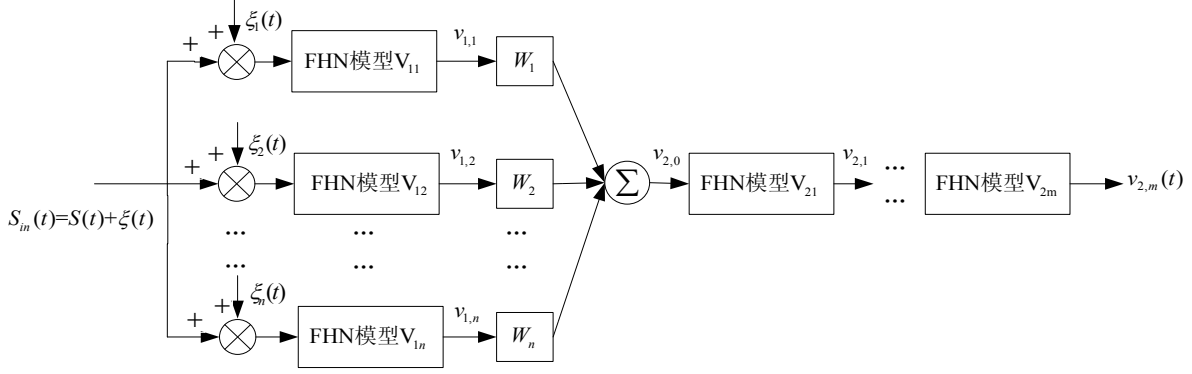


图 4.1 阵列级联 FHN 神经元模型示意图


## 4.2 基于阵列级联 FHN 神经元的一维弱信号随机共振增强研究


本章首先分别对一维周期信号和非周期信号进行阵列级联 FHN 神经元模型实验仿真, 从定性和定量 (信噪比和互相关系数) 角度来评价信号增强效果, 进而将研究对象拓展到二维图像, 采用光栅扫描和 Hilbert 扫描相结合的方法对图像降维, 从定性和定量 (峰值信噪比) 的角度来衡量阵列级联 FHN 神经元模型信号增强效果, 并与其他增强方法进行比较。

不失一般性, 本章在后续的仿真研究中取阵列环节个数  $n=4$  和级联环节个数  $m=1$ , 同时权值  $W_1=W_2=W_3=W_4=0.25$ , 阵列和级联两环节中 FHN 方程中的参数  $\varepsilon_1=\varepsilon_2$ 、 $\gamma_1=\gamma_2$ 、 $a_1=a_2$ 、 $b_1=b_2$ 、 $A_{T1}=A_{T2}$  和  $B_1=B_2$ 。


### 4.2.1 一维周期弱信号随机共振增强研究

本章首先研究含噪周期信号在阵列级联 FHN 神经元模型上的响应, 选择输入信号为周期正弦信号, 幅值  $A=0.8$ 、频率  $f_0=0.02$ 、采样时间间隔为  $0.01\text{ms}$ , 将外噪声强度  $D=0.45$  的高斯白噪声施加于周期正弦信号, 分别选择内噪声强度  $D$  为  $0.1$ 、 $0.5$  和  $1$  高斯白噪声进行实验, 结果如图 4.2 所示。其中神经元模型参数设置如下:  $\varepsilon=1$ ,  $\gamma=0.01$ ,  $a=0.1$ ,  $b=0$ ,  $A_T-B=0\text{mV}$ , 快变神经元膜电压和慢变恢复变量满足零初值条件, 数值求解步长为  $0.01$ 。







(c)内噪声为 0.1 的单个 FHN 模型输出响应图




(d)内噪声为 0.1 的阵列级联 FHN 模型输出响应图




(e)内噪声为 0.5 的单个 FHN 模型输出响应图



(f)内噪声为 0.5 的阵列级联 FHN 模型输出响应图



(g)内噪声为 1 的单个 FHN 模型输出响应图



(h)内噪声为 1 的阵列级联 FHN 模型输出响应图

图 4.2 单个 FHN 神经元模型与阵列级联 FHN 神经元模型的一维周期响应图

由图 4.2 可以看出, (b)图中的噪声基本淹没了有用的周期正弦信号, 从纵向比较来看, 随着内噪声信号强度的逐渐增大, 单个 FHN 神经元的输出变得无序, 如图 4.2(c)、(e)和(g)所示。图 4.2(c)的单个 FHN 神经元输出基本能够跟随周期正弦信号的变化, 只是在峰值处存在较大的噪声, 但是到图 4.2(g)中单个 FHN 神经元输出已经不能很好的跟随周期信号, 输出变得杂乱无章, 基本上由噪声占主导。相比之下, 阵列级联 FHN 神经元模型的输出响应受内噪声强度变化影响不大, 如图 4.2(d)、(f)和(h)所示, 只是在峰值处存在微小的波动, 说明阵列级联 FHN 神经元模型对内噪声具有较好的鲁棒性与自适应性。从横向比较而言, 在相同噪声强度的条件下阵列级联 FHN 神经元模型的输出效果要明显优于单个 FHN 神经元的输出, 如图 4.2(c)、(d), 图 2(g)、(h)相比所示。图 4.2(c)和图 4.2(d)相比, 两者基本都能跟随周期正弦信号的频率变化, 但是图 4.2(d)较图 4.2(c)更平滑(峰值处波动更小), 信号

轮廓更清晰。图 4.2(g)和图 4.2(h)的比较更能说明阵列级联 FHN 神经元模型的优势,图 4.2(g)已经不能跟随周期信号的频率变化,噪声在信号中占据着主导,但是图 4.2(h)仍旧能够很好的跟随周期信号的频率变化,信号得到凸显,噪声在一定程度上得到了有效的抑制。

为了定量评价本文方法在一维周期弱信号增强中的有效性,采用信噪比作为衡量指标,其结果如表 4.1 所示。从表 4.1 可以看出,横向比较:在相同强度的内噪声条件下阵列级联 FHN 神经元模型的信噪比普遍要高于单个 FHN 神经元模型;纵向比较:随着内噪声强度的增大,单个 FHN 神经元模型的信噪比逐渐减小,阵列级联 FHN 神经元模型的信噪比受内噪声强度变化影响不大,这正好与上述主观视觉效果的定性分析相一致,同时也在一定程度上说明了信噪比能够作为周期信号随机共振信号增强效果的定量评价指标。

表 4.1 不同内噪声强度周期信号信噪比对比表

SNR 内噪声强度 $D$	类型	单个 FHN 神经元模型	阵列级联 FHN 神经元模型
0.1		8.0932	<b>8.1443</b>
0.25		8.0816	<b>8.1143</b>
0.5		7.9944	<b>8.0948</b>
1.0		7.8265	<b>8.0437</b>
1.5		7.5443	<b>8.0588</b>
2.0		7.5088	<b>8.0409</b>


#### 4.2.2 一维非周期弱信号随机共振增强研究


对于一维非周期信号,用二进制双极性信号  $S(t)$  作为系统无噪非周期输入信号。

$$S(t) = A \cdot \sum_{j=-\infty}^{\infty} S_j \Gamma(t - jT_j) \quad (4.3)$$


其中信号幅值  $A > 0$  且为常数,而  $\Gamma(t) = \begin{cases} 1 & t \in [0, T_j] \\ 0 & \text{其它} \end{cases}$ ,  $T_j$  表示信号的脉宽,  $S_j = \pm 1$  为独立

分布的随机变量。参数设定为  $A = 0.8$ ,  $T_j = 500$ , 将外噪声强度  $D = 0.635$  的高斯白噪声施加于非周期信号,分别选择内噪声强度  $D$  为 0.1、0.5 和 1 高斯白噪声进行实验,结果如图 4.3 所示。







(c)内噪声为 0.1 的单个 FHN 模型输出响应图




(d)内噪声为 0.1 的阵列级联 FHN 模型输出响应图




(e)内噪声为 0.5 的单个 FHN 模型输出响应图



(f)内噪声为 0.5 的阵列级联 FHN 模型输出响应图



(g)内噪声为 1 的单个 FHN 模型输出响应图



(h)内噪声为 1 的阵列级联 FHN 模型输出响应图

图 4.3 单个 FHN 神经元模型与阵列级联 FHN 神经元模型的一维非周期响应图

由图 4.3 可以看出其实验结果基本与一维周期信号相类似。纵向比较来看，随着内噪声强度的增大，阵列级联 FHN 神经元模型显示了对内噪声具有较强的鲁棒性与自适应性；横向比较而言，在相同噪声强度的条件下，阵列级联 FHN 神经元模型随机共振信号增强效果明显要优于单个 FHN 神经元模型，阵列级联 FHN 神经元模型能够有效的跟随输入信号，信号轮廓较清晰，信号比较平滑，噪声在一定程度上得到了有效的抑制。

为了进一步定量评价本文方法在一维非周期信号增强中的性能，采用互相关系数作为评价指标进行研究，结果如表 4.2 所示。从表 4.2 中可以看出，横向比较：对于相同强度的噪声，阵列级联 FHN 神经元模型的互相关系数普遍要高于单个 FHN 神经元模型；纵向比较：随着内噪声强度的增大，单个 FHN 神经元模型和阵列级联 FHN 神经元模型的互相关

系数都呈现下降趋势，但是阵列级联 FHN 神经元模型的互相关系数受内噪声影响的程度要小于单个 FHN 神经元模型，其结果基本与上述定性主观视觉效果相一致，说明了互相关系数作为定量评价非周期信号指标的有效性，同时也证实了阵列级联 FHN 神经元模型随机共振信号增强效果要明显优于单个 FHN 神经元。

表 4.2 不同内噪声强度非周期信号互相关系数对比表

内噪声强度 $D$	$C$	类型	单个 FHN 神经元模型	阵列级联 FHN 神经元模型
0.1			0.9643	<b>0.9989</b>
0.5			0.9411	<b>0.9943</b>
1.0			0.8707	<b>0.9491</b>
1.5			0.8646	<b>0.9208</b>
2.0			0.8552	<b>0.9010</b>

### 4.3 基于阵列级联 FHN 神经元的二值图像弱信号随机共振增强研究

#### 4.3.1 图像降维方法

在研究了一维周期信号和一维非周期信号的基础上，将研究范围拓展到二维图像信号。由于在随机共振应用中，FHN 神经元模型的激励为一维信号，因此需要对二维图像信号进行降维。目前常用的降维方法为光栅扫描法和 Hilbert 扫描法，两种扫描方法各有优缺点，前者在算法描述及实现上较为简单，但是通常需要融合多个方向扫描信息，且在图像的空间特性保持方面，更多的依赖于图像边缘的本身特性以及扫描方向的选择；后者具有更佳的图像空间特性表达能力，但需采用迭代过程，算法实现较复杂。

#### 4.3.2 算法步骤

以二值图像的增强为例进行说明。为了保留图像像素的空间结构特性，同时减小判别误差，本文通过将 Hilbert 扫描法和光栅扫描法相结合以实现二维图像的降维，在阵列并联环节处分别采用  $0^\circ$ 、 $90^\circ$ 、 $180^\circ$  和  $270^\circ$  Hilbert 扫描，在级联串联环节处采用行与列的光栅扫描，由判别器对输出信号进行择优选取。其具体步骤如下：

- (1) 获取二值图像  $P = \{p(i, j) | i = 1, 2, \dots, M; j = 1, 2, \dots, N\}$  ( $M$  表示图像的行数， $N$  表示图像的列数)，考虑到输入信号的双极性，对二值图像减去 128 进行灰度映射，由原来的 0 和 255 二值像素映射为 -128 和 127 二值像素图像  $G = \{g(i, j) | i = 1, 2, \dots, M; j = 1, 2, \dots, N\}$ ，对其添加高斯白噪声；
- (2) 分别进行  $0^\circ$ 、 $90^\circ$ 、 $180^\circ$  和  $270^\circ$  四路 Hilbert 扫描，将图像降维成一维信号  $f_{90xi}(n) (n = 1, 2, \dots, M \times N, i = 0, 1, 2, 3)$ ，并分别输入阵列并联 FHN 神经元环节得到四路输出，按照  $0^\circ$  Hilbert 扫描的顺序，调整各路一维输出序列的元素位置，建立统一的对应关系，将调整位置后的一维信号序列记为  $g_{90xi}(n) (n = 1, 2, \dots, M \times N, i = 0, 1, 2, 3)$ ；
- (3) 对调整位置后的四路一维信号进行加权运算得  $h(n) (n = 1, 2, \dots, M \times N)$ ，同时将得到的一维信号  $h(n)$  重构为二维信号  $H = \{h(i, j) | i = 1, 2, \dots, M; j = 1, 2, \dots, N\}$ ；

- (4) 分别对二维信号  $H$  进行行扫描和列扫描，将其降维为一维信号  $k_{row}(n)$  和  $k_{col}(n)$  ( $n=1,2,\dots,M \times N$ )，分别输入级联串联 FHN 神经元环节得到  $s_{row}(n)$  和  $s_{col}(n)$  ( $n=1,2,\dots,M \times N$ )；
- (5) 将得到的一维输出信号重构为二维信号  $R_{row} = \{r_{row}(i, j) | i=1,2,\dots,M; j=1,2,\dots,N\}$  和  $R_{col} = \{r_{col}(i, j) | i=1,2,\dots,M; j=1,2,\dots,N\}$ ，保留  $R_{row}$  和  $R_{col}$  相应位置上的较大值，其判别规则为：

$$s(i, j) = \begin{cases} r_{row}(i, j) & |r_{row}(i, j)| \geq |r_{col}(i, j)| \\ r_{col}(i, j) & |r_{row}(i, j)| < |r_{col}(i, j)| \end{cases} \quad (4.4)$$

其中  $s(i, j)$  ( $i=1,2,\dots,M; j=1,2,\dots,N$ ) 表示判别器输出信号，同时考虑到最终的输出为二值图像，因此对判别器输出信号进行二值化，以得到最终的输出图像，其二值化规则如下：

$$I(i, j) = \begin{cases} 0 & s(i, j) < 0 \\ 255 & s(i, j) \geq 0 \end{cases} \quad (4.5)$$

其中  $I(i, j)$  ( $i=1,2,\dots,M; j=1,2,\dots,N$ ) 为最终的二值化图像。

#### 4.3.3 实验结果与分析

以图 4.4 所示的二值图像作为研究对象，在图像中添加均值为 0，强度为 250 的高斯白噪声作为外噪声，加噪后的图像如图 4.5 所示。分别选择强度为 25、50 和 100 的内噪声为进行实验，选择单个 FHN 神经元模型、3\*3 中值滤波、3\*3 维纳滤波和二阶 sym4 小波基函数小波滤波方法作为阵列级联 FHN 神经元模型的比较对象，结果如图 4.6、图 4.7 和图 4.8 所示。



图 4.4 二维图像原始二值图



图 4.5 二值图像加噪图



从图中可以看出, 单个 FHN 神经元模型输出响应受内噪声强度变化影响较大, 而阵列级联 FHN 模型随着内噪声强度的变化输出基本保持不变, 这说明了阵列级联 FHN 模型对图像信号的内噪声具有较强的鲁棒性与自适应性, 能够保持较高的图像输出质量。

另外在内噪声强度一定的条件下, 随机共振信号增强的效果要显著优于中值、维纳以及小波信号增强方法, (b)图、(c)图和(d)图三组整体效果相近, 增强图像中仍然存在大量的噪声, 图像轮廓模糊, 这与信号增强的原理有关, 传统方法将噪声作为有害的因素滤除, 因此将不可避免的在一定程度上削弱了有用信号, 使图像整体质量变差。而随机共振信号增强的出发点是将噪声转化为有用信号, 从而使有用信号得到了增强, 这正是其独特之处。

更重要的是, 阵列级联 FHN 模型信号增强效果要明显优于单个 FHN 模型, 新方法有效抑制了噪声, 图像边缘轮廓较清晰, 边缘轮廓与细节得到凸显, 图像层次感较强。

但最后需要指出的是, 随机共振方法也丢失了一些窄而细的局部细节, 究其原因, 问题可能并非是随机共振本身所引起的, 而在图像的降维过程中, 虽然选择了较佳的扫描方式, 但仍然不可避免的会丢失图像的部分空间结构, 导致丢失一些图像中的小细节, 但从整体效果来说, 阵列级联 FHN 神经元模型的信号增强效果要优于单个 FHN 神经元模型。

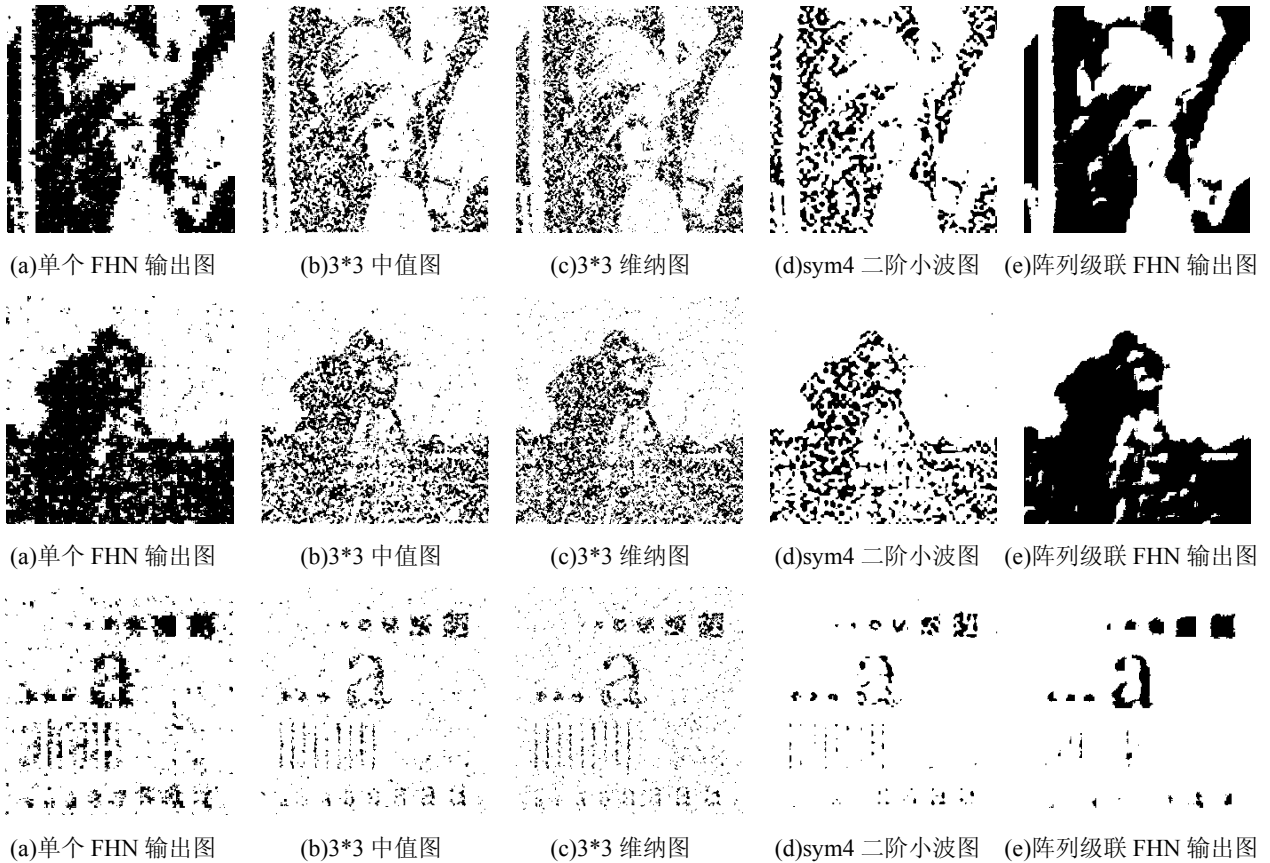


图 4.6 内噪声强度为 25 时, 不同增强方法的实验结果图

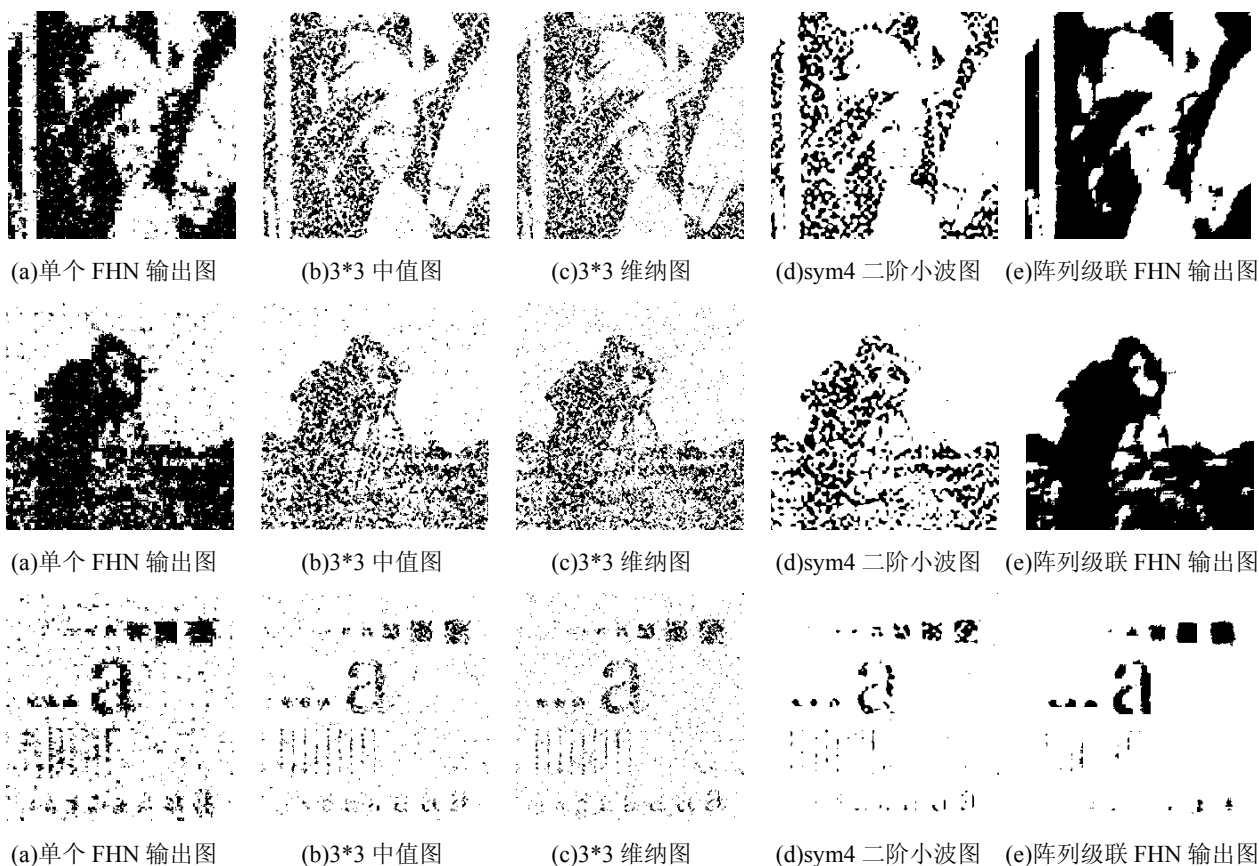


图 4.7 内噪声强度为 50 时，不同增强方法的实验结果图

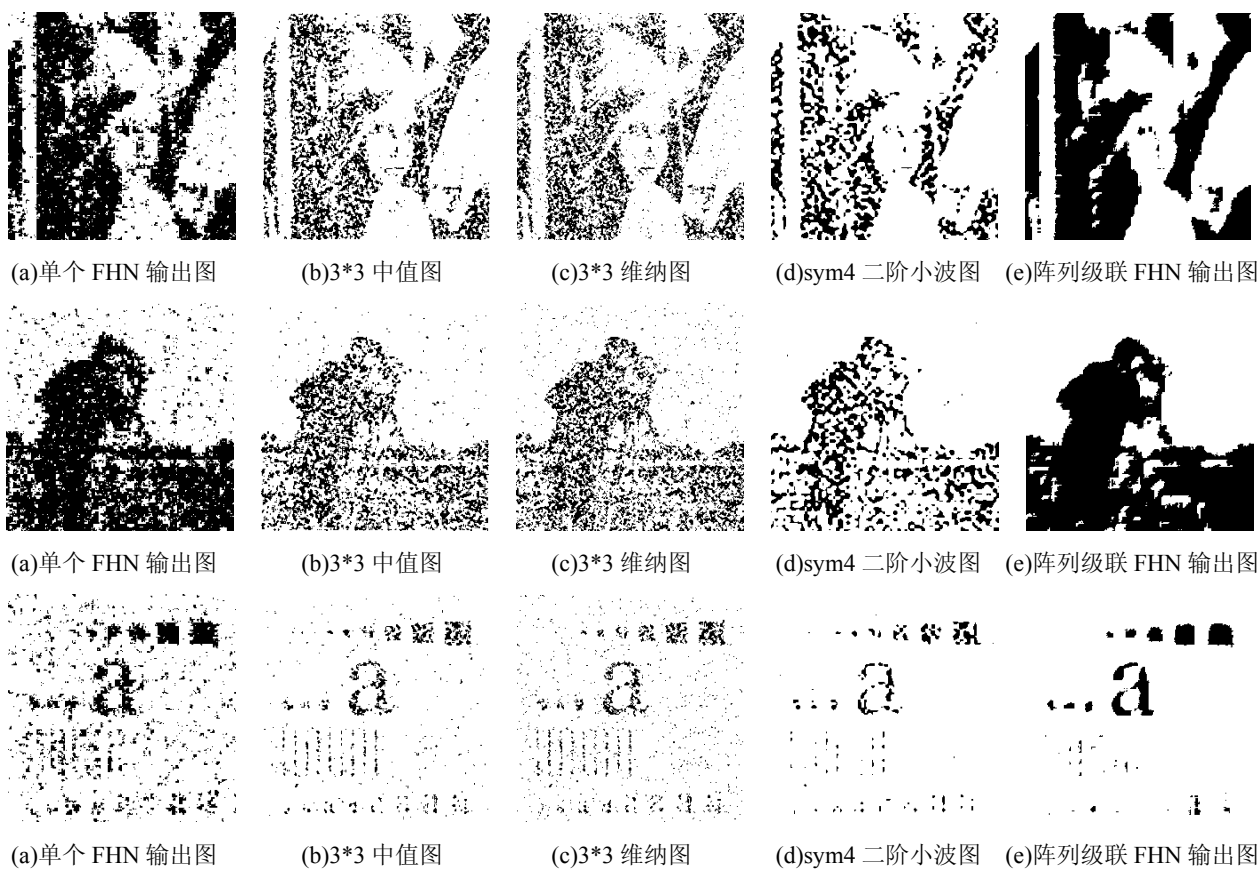


图 4.8 内噪声强度为 100 时，不同增强方法的实验结果图

为了更好地评价图像信号增强效果，引入峰值信噪比作为定量评价指标来衡量图像信号增强的优劣。不同内噪声强度以及不同信号增强方法的图像峰值信噪比结果如表 4.3 所示，从表中可以看出，其峰值信噪比定量评价指标的结果基本与主观观察结果的定性分析相类似，这进一步说明了阵列级联 FHN 神经元模型图像信号增强效果要优于其它图像增强方法。

表 4.3 不同图像增强方法峰值信噪比对比表

PSNR		类型	单个 FHN 模型	3*3 中值	3*3 维纳	sym4 二阶 小波	阵列级联 FHN 模型
内噪声强度 $D$							
Lena 图	$D=25$		9.1284	5.3683	5.4639	5.2510	<b>9.7721</b>
	$D=50$		8.8959	5.4776	5.5172	5.2856	<b>9.7553</b>
	$D=100$		8.3661	5.4317	5.5196	5.3125	<b>9.5751</b>
Cameraman 图	$D=25$		9.1258	5.4704	5.5499	5.2229	<b>10.1316</b>
	$D=50$		8.9997	5.5560	5.6364	5.2572	<b>10.0637</b>
	$D=100$		8.3702	5.5900	5.6797	5.3259	<b>10.1072</b>
Letter 图	$D=25$		10.9544	11.1996	11.1282	11.1154	<b>11.9622</b>
	$D=50$		10.5848	11.2239	11.1231	11.1547	<b>11.9129</b>
	$D=100$		9.6446	11.2677	11.2160	11.1044	<b>11.8611</b>

#### 4.4 小结

神经电生理实验表明了视觉系统中的神经元在视觉感知时表现出随机共振特性，该特性显著提高视觉感知能力。本章从神经元的随机共振特性出发，探究了神经元模型中的随机共振机制在信号增强中的应用。首先分别研究了一维周期正弦信号和非周期信号的强噪声背景下的随机共振信号增强，结果表明本章提出的阵列级联 FHN 神经元模型具有去噪效果强，弱信号轮廓边缘清晰等优点，且新模型对内噪声强度具有较强的鲁棒性和适应性。然后将研究对象拓展到二值图像信号，结合光栅扫描法和 Hilbert 扫描法将含噪二值图像降维成一维信号，通过阵列级联 FHN 神经元模型进行随机共振信号增强，并与其他传统图像增强方法进行比较，结果表明输出图像更加平滑，信号轮廓与细节得到凸显，与之相对应的是噪声在一定程度上得到了有效的抑制，达到了图像增强的目的，输出图像质量得到了显著改善。

## 第 5 章 基于方向响应的 IF 神经元模型图像边缘检测

### 5.1 图像边缘检测概述

图像的边缘是图像灰度值发生跃变的地方，往往包含了图像中大部分有用的信息。因而图像边缘检测是图像处理环节中的一个重要部分，其结果的好坏直接关系到后续图像特征的提取、图像分析与识别等。神经生理和心理实验从宏观角度表明了视觉系统在观察事物时具有一定的方向选择性，并非对所有方向产生同样的反映。例如Campbell等人的研究表明视觉感知系统对水平或垂直方向的光强变化感知最大，但对于倾斜方向上的光强变化感知最小。另外从微观角度来看，初级视皮质存在具有方向选择性的敏感神经元，它们通常被最优方向的边缘所兴奋或抑制。而对于其它方向上的视觉刺激，则表现为较弱的响应。最后随着视皮质加工流的延伸，形成复杂的视觉功能。传统的边缘检测方法，如Sobel算子<sup>[56]</sup>、Prewitt算子<sup>[57]</sup>和Canny算子<sup>[58]</sup>等，大都基于图像本身的微分门限原理，并不能反映神经元钾钠离子通道开合所产生的放电模式编码以及视觉系统对图像信息的方向选择感知特性。

目前，基于神经元模型响应的图像边缘检测研究受到了广泛的关注。例如结合空间和灰度特性自动选取阈值的改进PCNN模型用于彩色图像边缘检测研究<sup>[59]</sup>；另外还有将三态的自适应线性神经元模型用于数字图像的边缘检测<sup>[60]</sup>。上述方法更多关注于模型的网络结构，但事实上与视皮质复杂的加工流相比，这种网络结构只能是一种理想化的抽象模型。另一方面它们忽略了视皮质神经元对于边缘方向的选择特性，而这对于基于视觉机制的图像边缘检测尤为重要。

针对上述问题，本章提出了基于方向响应的 IF 神经元模型图像边缘检测方法。首先采用与人类视觉系统认知相一致的 Log-Gabor 方向响应模型对图像进行预处理，使其满足方向选择性；其次采用符合神经元电生理特性的 Integrate-and-Fire 神经元模型获得相应的动作电位编码序列，最后将各个方向的信息经判别器综合获得图像边缘检测结果。

### 5.2 基本原理

本章首先采用 Log-Gabor 滤波器对原始图像选择  $0^\circ$ 、 $45^\circ$ 、 $90^\circ$  和  $135^\circ$  四个特定方向进行预处理，使之符合人眼的方向选择注意机制，其次采用相应的行列扫描降维方式将其降维为四路一维信号序列，然后将获得的四路一维信号序列分别输入至 IF 神经元模型获得四路神经元动作电位脉冲序列，将四路一维信号序列分别重构为二维信号并经过判别器综合成一路二维信号，最后将脉冲二维信号重新映射为二值图像。本文将分别从定性分析和定量指标的角度对图像边缘检测效果进行评价，并与传统图像边缘检测方法进行比较。

#### 5.2.1 方向响应模型

人类视觉感知系统具有一定的方向选择性，而 Log-Gabor 方向响应模型具有良好的方向选择性，并在该方向上产生最优的响应，同时在一定程度上有效的抑制其它方向的输出。该模型还具备两个显著优点：(1)没有直流分量，因此图像处理时不受亮度条件变化的影响；(2)Log-Gabor 方向响应模型传递函数在高频处具有一个延长的尾巴，这可以弥补普通 Gabor 函数在低频段表示过度而高频段表示不足的缺点。

由于Log-Gabor方向响应模型在极点处的奇异性，不能直接得到解析表达式，其频域表达式如 5.1 所示<sup>[61]</sup>：

$$H(f, \theta) = \exp\left\{\frac{-[\ln(f / f_0)]^2}{2[\ln(\sigma_f / f_0)]^2}\right\} \exp\left\{\frac{-(\theta - \theta_0)^2}{2\sigma_\theta^2}\right\} \quad (5.1)$$

其中， $f$ 、 $\theta$ 为待滤波图像的频率和方向； $f_0$ 为中心频率； $\theta_0$ 为滤波器方向； $\sigma_f$ 为径向带宽； $\sigma_\theta$ 为方向带宽。

### 5.2.2 神经元模型

对于感受野内的视觉激励，视皮质神经元通过动作电位发放来进行信息的加工和编码，因此本文选择保留神经元主要电生理特性的IF神经元模型用于图像边缘检测。IF神经元模型可看作一个激活系统，存在阈值特性：当刺激值在阈值下时，神经元只产生被动的去极化电位，不产生动作电位；当刺激强度大于阈值时神经元产生兴奋，进行点火，出现动作电位。其模型表达式如下<sup>[44]</sup>：

$$\begin{cases} v' = I + a - bv \\ \text{if } v \geq v_{thresh}, \text{ then } v \leftarrow c \end{cases} \quad (5.2)$$

其中， $v$ 是细胞膜电位， $I$ 是输入电流， $a$ 、 $b$ 和 $c$ 为参数， $v_{thresh}$ 为阈值，当 $v$ 大于等于 $v_{thresh}$ ，神经元发放脉冲(标记为 1)，同时 $v$ 被重新设定为 $c$ 。否则神经元不发放脉冲(标记为 0)。

### 5.2.3 最大香农熵

为了更好地评价图像边缘检测的效果，本文引入最大香农熵（Maximum Shannon Entropy, MSE）作为定量评价指标来衡量图像边缘检测的效果，如式 5.3 所示<sup>[62]</sup>：

$$MSE = -P_1 \ln P_1 - P_0 \ln P_0 \quad (5.3)$$

其中， $P_0$ 和 $P_1$ 分别表示边缘检测后二值图像为 0 和 255 的概率。对于大多数图像而言，香农熵代表了图像中的信息量，香农熵越大表明边缘检测后从原始图像中获得的信息量越大，细节越丰富，边缘检测效果越好。

### 5.2.4 算法步骤

基于方向响应的 IF 神经元模型图像边缘检测算法，其具体步骤如下：

- (1) 对原始图像  $I(i, j)$  ( $i=1, 2, \dots, M; j=1, 2, \dots, N$ ，变量  $i$  和  $j$  下同)采用 Log-Gabor 滤波器进

行预处理, 分别获得 $0^\circ$ 、 $45^\circ$ 、 $90^\circ$ 和 $135^\circ$ 四个方向的结果, 记为 $f_x(i, j)$  ( $x=0, 45, 90, 135$ ,  $x$ 下同);

(2) 对四个方向的结果 $f_x(i, j)$ 取其复数的实部, 记为 $r_x(i, j)$ , 并分别将其按照映射规则式 5.4 重新灰度映射为 0-255 之间的像素, 记为 $g_x(i, j)$ :

$$g_x(i, j) = \frac{255 * (r_x(i, j) - \min(r_x))}{(\max(r_x) - \min(r_x))} \quad (5.4)$$

其中,  $\min(r_x)$ 表示 $r_x(i, j)$ 的最小值,  $\max(r_x)$ 表示 $r_x(i, j)$ 的最大值。

(3) 将 $g_x(i, j)$ 分别按照行列扫描方式对图像降维, 降维后的一维序列记为 $F_x(n)$ , (其中 $n=1, 2, \dots, M \times N$ , 下同);

(4) 将 $F_x(n)$ 作为 IF 神经元模型的输入刺激, 获得相应的四路神经元脉冲序列, 记为 $P_x(n)$ 。 $P_x(n)$ 的元素由 0 和 1 所构成。当皮层神经元发放脉冲时, 标记为 1, 无发放脉冲则标记为 0;

(5) 对 $P_x(n)$ 分别经过图像降维的逆扫描方式还原为四路二维信号, 记为 $p_x(i, j)$ ;

(6) 为了保留图像中的更多细节, 对四个方向上的 $p_x(i, j)$ 结果经过判别器综合判别, 融合成一路二维信号, 记为 $p(i, j)$ , 其判别器准则如式 5.5 所示:

$$p(i, j) = p_0(i, j) | p_{45}(i, j) | p_{90}(i, j) | p_{135}(i, j) \quad (5.5)$$

其中,  $|$ 表示逻辑或操作。

(7) 对二维信号 $p(i, j)$ 按照式 5.6 中所示二值映射规则映射成 0 和 255 二值图像 $I'(i, j)$ 。

$$I'(i, j) = \begin{cases} 0 & p(i, j) = 0 \\ 255 & p(i, j) = 1 \end{cases} \quad (5.6)$$

### 5.3 基于方向响应的 IF 神经元模型图像边缘检测

为了实现对图像特定方向信息的选取, 本文选择四种方向通道。对于不同分辨率下图像频率信息的提取则选用相同尺度的频率。根据实验经验, 具体参数设置如下:  $a=0.5$ 、 $b=0.1$ 、 $c=-50$ 、 $f_0=1/3$ 、 $\sigma_\theta=\pi/6$ 、 $\sigma_f=0.2167$ , 神经元脉冲发放的阈值 $v_{thresh}$ 可设定为 60 左右, 方向通道 $\theta_0$ 为四个, 即 $0^\circ$ 、 $45^\circ$ 、 $90^\circ$ 和 $135^\circ$ 。

#### 5.3.1 方向响应模型预处理后的直方图分布

本章选择图 5.1 所示的图像进行仿真实验研究, 对应的直方图如图 5.2 所示。从图中可以看出, 不同图像所对应的直方图分布呈现出很大的差异, **Lena** 直方图在灰度级范围内分布相对均匀, **Cameraman** 直方图在较小和中间段上的灰度级上占主导, 而 **Letter** 直方图的分布相对稀疏, 在某几个特殊灰度级上有分布, 其他灰度级上没有分布。经过 $0^\circ$ 、 $45^\circ$ 、 $90^\circ$ 和 $135^\circ$ 四种方向 Log-Gabor 滤波器预处理后的直方图分布分别如图 5.3~5.5 所示。可以发现上述三幅图经过 Log-Gabor 滤波器预处理后直方图的分布呈现相类似的规律, 中间段灰度级处占主导, 两端灰度级处得到了有效的抑制, 且直方图分布呈现高斯函数形状分布。这

个结果也验证了 Log-Gabor 滤波器在图像边缘检测的应用，具有与图像亮度特性无关的性质。



图 5.1 原始图像




图 5.2 原始图像直方图




图 5.3 Lena Log-Gabor 预处理直方图




图 5.4 Cameraman Log-Gabor 预处理直方图




图 5.5 Letter Log-Gabor 预处理直方图

### 5.3.2 方向响应模型的方向选择性

经过 $0^\circ$ 、 $45^\circ$ 、 $90^\circ$ 和 $135^\circ$ 四种方向的 Log-Gabor 滤波器预处理结果以及将其输入至 IF 神经元模型后所对应的边缘检测结果如图 5.6~5.8 所示。从图中的(a)~(d)可以发现 Log-Gabor 滤波器具有方向选择性，对其选定的特定方向上的边缘信息进行凸显与强化，同时减小背景差异，使背景与边缘呈现明显的层次差异，有利于后续的图像边缘检测处理。将方向选择的 Log-Gabor 滤波器结果输入至 IF 神经元模型获得相应的神经元动作电位脉冲序列，同时神经元动作电位脉冲序列结果也呈现出明显的方向性，结果如图 5.6~5.8 中的(e)~(h)所示。引入 Log-Gabor 滤波器对原图进行多方向的分解，从而使 IF 神经元动作电位脉冲也表现出了特定的方向选择性，这正体现了视皮质神经元的方向选择特性，也可以进一步从生理角度得到很好的解释，神经元并不是对所有方向上的刺激都会产生特定相同的输出结果，它只是对其中某些感兴趣的方向进行输出，最后综合各个方向上的信息进行最优判决，得到最终的最优输出。

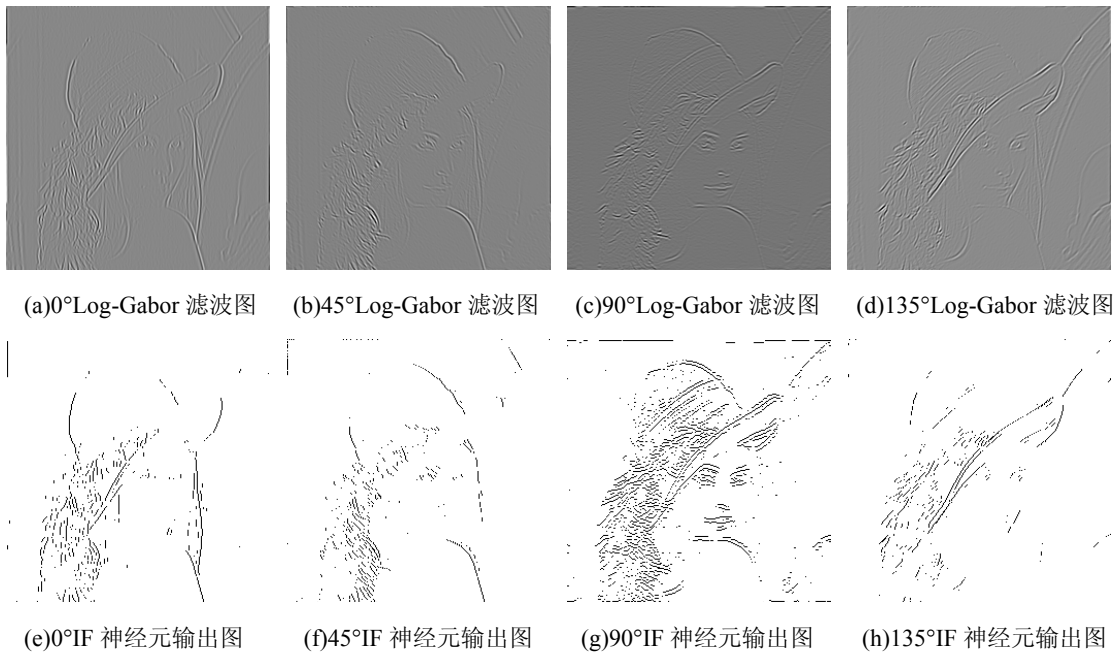
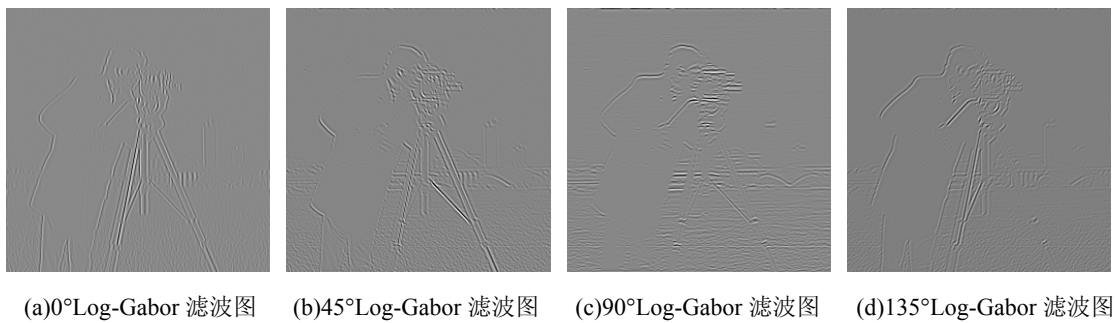


图 5.6 Lena Log-Gabor 滤波与 IF 神经元输出图





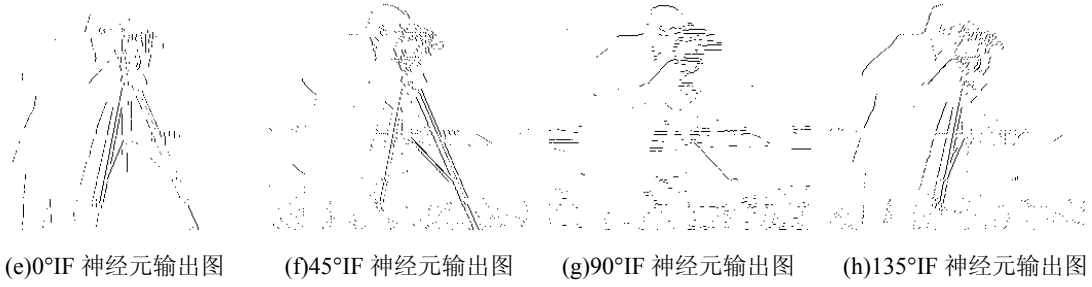


图 5.7 Cameraman Log-Gabor 滤波与 IF 神经元输出图

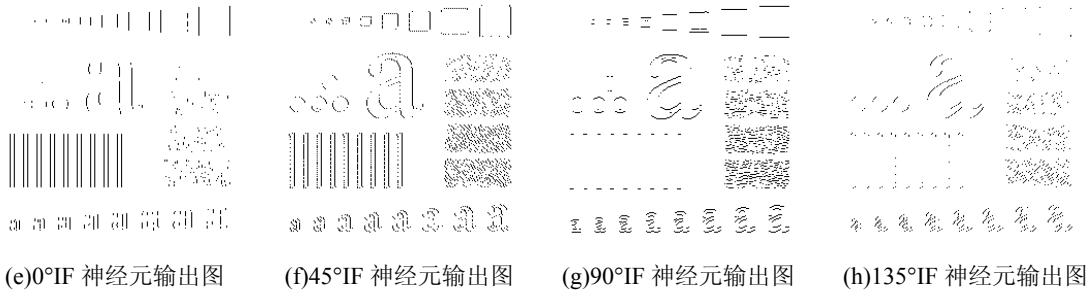
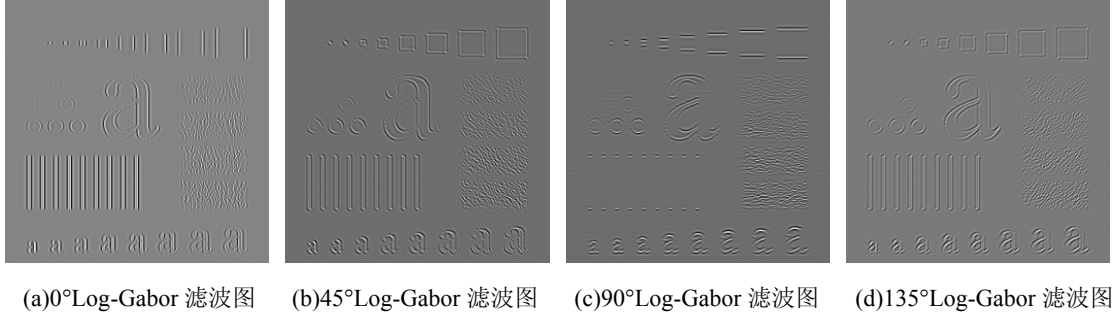


图 5.8 Letter Log-Gabor 滤波与 IF 神经元输出图

### 5.3.3 不同方法图像边缘检测结果的比较

本文对四个方向上的神经元脉冲序列经过判别器进行信息综合，得到最优的边缘检测结果，为了说明本文方法的有效性，选择传统的边缘检测方法 Prewitt 算子、Roberts 算子和 PCNN 脉冲耦合神经元模型作为图像边缘检测的比较对象，其结果如图 5.9~5.11 所示。其

中 PCNN 脉冲耦合神经元模型参数设置如下：连接权矩阵为  $\begin{bmatrix} 0.5 & 1 & 0.5 \\ 1 & 0 & 1 \\ 0.5 & 1 & 0.5 \end{bmatrix}$ ，连接系数为 0.4，

衰减系数为 0.3。

从图 5.9~5.11 的(a)中可以看出，单个方向的 Log-Gabor 滤波器预处理后的 IF 神经元模型结果经过综合判别器后能够有效的融合各个方向上的边缘信息，有效的凸显图像中的细节，丰富图像中的边缘信息，增强了边缘检测的效果，也进一步说明了该判别器的有效性，其作用类似于神经元最后通道的信息整合输出功能。

另外通过图 5.9~5.11 的每组四幅图的横向比较，可以发现本文方法优于其他三种传统

的图像边缘检测方法, 每组的(b)、(c)和(d)三幅图的效果相近, 这类方法对图像边缘检测时丢掉了一些边缘细节, 如 Lena 图中的帽子边缘轮廓以及帽子中的条纹层次均被忽略了, Lena 图的头发部分细节边缘也被丢失了, 而且传统的 prewitt 算子和 roberts 两种基于空域边缘检测方法对图像中类似噪声部分的边缘检测不是很理想, 如 Cameraman 图中的草地边缘信息和 Letter 图中的四块矩形噪声在传统方法中都不能很好的体现出来, 而在本文方法中能够有效地检测出来, 表明本文方法对类似于噪声的边缘信息具有一定的自适应性与优越性。

更重要的是, 本文方法能够使图像的边缘轮廓细节得到了很好的凸显, 图像层次感丰富, 这得益于充分利用神经元脉冲发放特性与方向的特定选择性, 使其更符合神经元真实的生理特性, 能从视觉感知特性角度得到很好的解释。

但是最后需要指出的是, 本文方法在图像边缘检测存在边缘不连续和部分细节丢失等问题, 究其原因, 问题可能并非是本文模型的问题, 而是在图像降维过程中, 虽然选择了与 Log-Gabor 滤波器方向相对应的扫描方式, 但仍然不可避免会丢失图像的部分空间结构同时忽略了像素周围邻域之间的关联性。

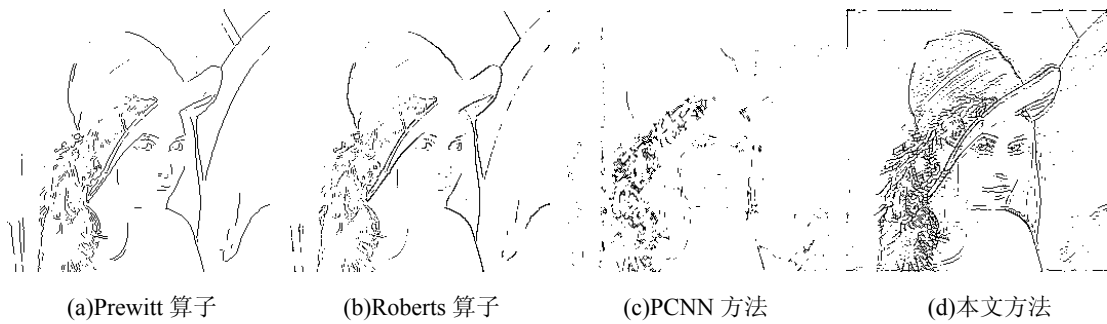


图 5.9 Lena 图不同方法的图像边缘检测结果图

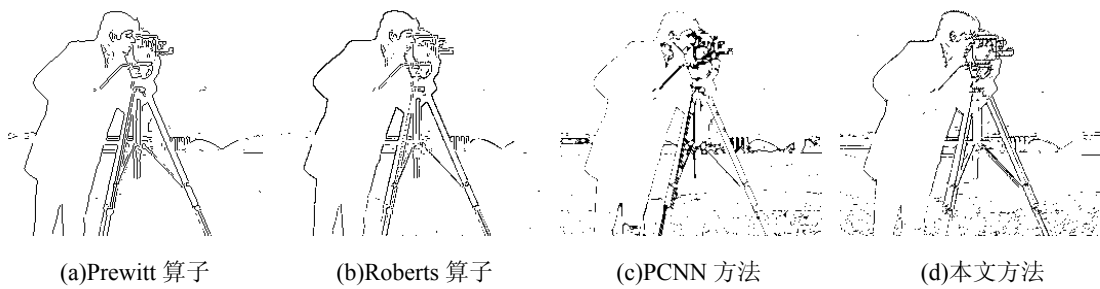


图 5.10 Cameraman 图不同方法的图像边缘检测结果图

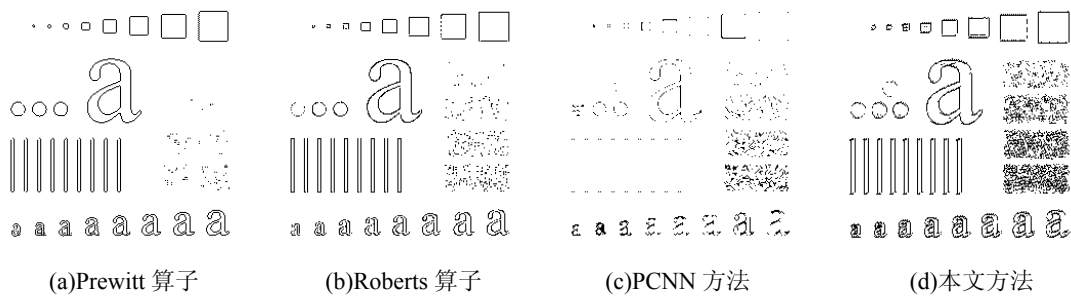


图 5.11 Letter 图不同方法的图像边缘检测结果图

不同图像边缘检测方法的定量指标最大香农熵结果如表 5.1 所示。从表中可以看出，本文方法的最大香农熵值要大于传统的边缘检测方法，这与主观的定性分析相一致，也进一步说明了本文方法的图像边缘检测效果要稍优于传统的图像边缘检测方法。

表 5.1 不同方法的图像边缘检测最大香农熵对比表

图像	<i>MSE</i>			
	Prewitt 算子	Roberts 算子	PCNN 方法	本文方法
Lena	0.1661	0.1529	0.1280	<b>0.2831</b>
Cameraman	0.1627	0.1541	0.1768	<b>0.1912</b>
Letter	0.1649	0.1837	0.1029	<b>0.2829</b>

## 5.4 小结

神经生理学实验表明初级视皮质存在具有方向选择性的敏感神经元，因而视觉系统在感知事物时会表现出方向选择性。本章从神经元动作电位脉冲发放特性和神经元的方向选择特性作为出发点，探究其在图像边缘检测中的应用。首先通过引入 Log-Gabor 方向响应模型对图像进行方向选择分解预处理，以充分反映视觉系统的方向选择特性，其次将预处理的结果分别选择相应的扫描方式降维为一维信号序列输入至 IF 神经元模型获得相应的神经元动作电位脉冲序列，最后通过判别器综合输出获得边缘检测图像，结果表明本文方法与真实的神经元生理特性相一致，能够真实的反映生物特性，图像边缘检测效果要优于传统方法，能够使图像边缘轮廓得到凸显，丰富了图像细节，图像层次感得到加强，图像边缘检测较理想。

## 第 6 章 随机共振机制和神经元模型在低剂量肺部CT图像中的应用

### 6.1 低剂量肺部 CT 图像概述

近年来,随着医学可视化技术的发展以及计算机X线断层成像(Computed Tomography, CT)技术具有较高的密度分辨率、成像速度快、适用范围广等优点,使得CT在临床诊断与治疗领域得到了广泛的应用。随着CT诊断技术的普及,关于CT辐射剂量也逐渐受到了检查者的关注。一般一次病人CT检查的辐射剂量远远超出了标准的腹部X射线辐射剂量的标准。据研究显示,电离辐射剂量的高低目前已成为癌症风险的直接诱导因素。虽然,CT诊断在临床上获得了广泛的应用,但是其较高的辐射剂量极大的限制了在普通人群中的应用,尤其是在孕妇、儿童等高危人群中的应用,因此,如何减少CT辐射剂量已成为放射学界需要迫切解决的一个问题。目前,放射学界的研究者试图通过在临床上采用调整系统扫描参数的方法来降低辐射剂量,也有通过改进CT扫描装置,提高探测器单元的效率等技术来降低辐射剂量<sup>[63]</sup>,但是上述方法不可避免的会降低图像质量,使得CT图像中存在较多的噪声,其中病灶以及病变组织等信息已基本被噪声淹没,从而影响医生的后续诊断。为了提高低剂量CT扫描的图像质量,需要对低剂量CT图像进行增强,凸显图像中的细节与有用信息,以适应临床中的准确诊断,因而应用于低剂量的CT图像增强的方法被陆续提出来,主要有局部直方图均衡化<sup>[64]</sup>、多尺度Curvelet变换<sup>[65]</sup>和小波变换<sup>[66]</sup>等。其中前者属于空域图像增强方法,后两者为频域增强方法。空域图像增强算法简单且具有较高的实时性,但是其忽视了图像的空间结构特性易发生过增强现象,即在增强有用信号的同时也增强了噪声信号。频域增强方法能够有效的提升图像整体对比度,凸显图像中的细节特征,但是由于细节与噪声在频域上的相似性,使得图像部分细节模糊失真。上述方法的出发点都是基于将噪声看作一种有害的干扰,通过消除噪声来增强图像,因而上述方法图像增强能力有限。而随机共振机制是基于噪声、非线性系统和输入信号三者之间的协同作用,通过将噪声转化为有用信号的能量,从而改善输出信号的质量,为图像增强提供了一种新的方法。

低剂量肺部 CT 图像中由于肺癌结构、钙化、结点密度、形状、纹理以及周围环境的复杂特性,因此,有必要为医生提供定量的测量方法以获取医学图像特征,来对疾病进行深入诊断。而要对低剂量肺部 CT 图像中的病灶特征作出定量的测量,其首要的任务是对图像进行边缘检测,确定病灶的大致区域,进而才能进行后续的特征参数的计算。针对传统的图像边缘检测方法如 Roberts 算子、Sobel 算子、Prewitt 算子、Log 算子和 Canny 算子等,虽然它们具有计算简单、求解速度快等优点,但是对于噪声都比较敏感,不适用于含噪图像的边缘检测。本章从视觉方向选择感知特性和神经元动作电位脉冲序列发放机制出发,将基于方向响应的 IF 神经元模型用于低剂量的肺部 CT 图像的边缘检测。

本章以低剂量肺部 CT 图像为例，首先利用简单双稳态模型的随机共振机制，实现低剂量肺部 CT 图像中噪声能量向弱信号能量的转移，从而实现图像的增强。其次，结合视觉方向选择感知特性与神经元动作电位脉冲发放机制，采用方向响应的 IF 神经元模型对低剂量肺部 CT 图像进行边缘检测，为后续关于特征参数的提取做铺垫。最后，结合上述两模型的优点，在采用双稳态模型对图像增强的基础上，然后采用基于方向响应的 IF 神经元对低剂量肺部 CT 图像进行边缘检测，获得了较理想的实验结果。

## 6.2 基于双稳态随机共振机制的低剂量肺部 CT 图像增强

### 6.2.1 定量评价方法

图像增强的效果除了人眼鉴定之外，需要采用定量的客观评价指标进行衡量。本章分别采用 Distribution Separation Measurement(DSM)和标准差(Standard Deviation, SD)作为图像增强效果的量化评价方法。其中 DSM 的数学表达式如下所示<sup>[67]</sup>：

$$DSM = |D_E - \mu_B^E| + |D_E - \mu_T^E| - |D_O - \mu_T^O| - |D_O - \mu_B^O| \quad (6.1)$$

$$\text{其中, } D_O = \frac{\mu_B^O \sigma_T^O + \mu_T^O \sigma_B^O}{\sigma_B^O + \sigma_T^O}; \quad \sigma_B^O + \sigma_T^O \neq 0 \quad (6.2)$$

$$D_E = \frac{\mu_B^E \sigma_T^E + \mu_T^E \sigma_B^E}{\sigma_B^E + \sigma_T^E}; \quad \sigma_B^E + \sigma_T^E \neq 0 \quad (6.3)$$

$\mu_T^O$  和  $\mu_B^O$  分别是原始图像(O)中目标区域(T)和背景区域(B)的灰度均值， $\sigma_T^O$  和  $\sigma_B^O$  分别是原始图像中目标区域和背景区域的灰度标准偏差。 $\mu_T^E$ ， $\mu_B^E$ ， $\sigma_T^E$  和  $\sigma_B^E$  分别是增强图像(E)中目标区域和背景区域的灰度均值和标准偏差。

DSM 为负值，说明对比度并没有得到增强，如果 DSM 为正值，说明图像对比度得到了增强，DSM 越大，增强效果越好。

标准差反映了图像灰度相对于灰度均值的离散情况，标准差越大，则灰度分布越分散，反映图像的对比度越大，可以显示出更多的细节信息。其标准差的定义如下式所示<sup>[68]</sup>：

$$\mu = \frac{1}{NM} \sum_{i=0}^{N-1} \sum_{j=0}^{M-1} I(i, j) \quad (6.4)$$

$$\sigma^2 = \frac{1}{NM} \sum_{i=0}^{N-1} \sum_{j=0}^{M-1} (I(i, j) - \mu)^2 \quad (6.5)$$

其中， $N$  和  $M$  表示图像的行数和列数， $I(i, j)$  为图像的第  $i$  行第  $j$  列像素灰度值， $\mu$  为图像的均值， $\sigma$  为图像的标准差。

### 6.2.2 低剂量肺部 CT 图像增强的实现过程

以低剂量肺部 CT 图像增强为例，为了尽可能的保留图像像素的空间结构特性，同时减小判别误差，选择行-列光栅扫描作为图像降维方式，获取一维信号作为双稳态系统的输入

信号，最后由判别器对不同重构输出信号进行择优选取。其具体实现过程如下：

- (1) 考虑到级联双稳态模型的双极性，对原始灰度图像  $I(i, j)$  ( $i=1, 2, \dots, M; j=1, 2, \dots, N$ ，变量  $i$  和  $j$  下同) 的像素取值范围由  $[0, 255]$  映射到  $[-128, 127]$ ；
- (2) 然后分别采用行扫描和列扫描方式将二维图像信号降维为一维行信号序列和一维列信号序列，分别记为  $f_k(n)$  ( $n=1, 2, \dots, M \times N; k=1, 2$ )；
- (3) 针对双稳态系统输入要求具有小信号参数的特点，将行和列一维信号序列分别按下式 (6.6) 进行归一化处理得  $F_k(n)$  ( $n=1, 2, \dots, M \times N; k=1, 2$ )：

$$F_k(n) = \frac{f_k(n)}{\max(f_k(n))} (n=1, 2, \dots, M \times N; k=1, 2) \quad (6.6)$$

其中  $\max(f_k(n))$  表示  $f_k(n)$  ( $n=1, 2, \dots, M \times N; k=1, 2$ ) 的最大值。

- (4) 将归一化处理的序列  $F_k(n)$  ( $n=1, 2, \dots, M \times N; k=1, 2$ ) 分别输入双稳态模型中，得到输出序列  $G_k(n)$  ( $n=1, 2, \dots, M \times N; k=1, 2$ )；
- (5) 对  $G_k(n)$  ( $n=1, 2, \dots, M \times N; k=1, 2$ ) 采用行列逆扫描方式重构为二维信号  $P_k(i, j)$  ( $i=1, 2, \dots, M; j=1, 2, \dots, N; k=1, 2$ )；
- (6)  $P_k(i, j)$  ( $i=1, 2, \dots, M; j=1, 2, \dots, N; k=1, 2$ ) 分别反映了图像信号经过行和列扫描降维后经过双稳态系统的随机共振响应，因此本文通过判别器选取两者对应位置中的较大值，以增强随机共振的效果，此时可以认为噪声向图像弱信号进行了最大化的能量转移，图像信号、噪声与非线性系统三者之间达到了最大的协同作用。其中判别器的规则如下：

$$S(i, j) = \begin{cases} P_1(i, j) & |P_1(i, j)| \geq |P_2(i, j)| \\ P_2(i, j) & |P_1(i, j)| < |P_2(i, j)| \end{cases} \quad (6.7)$$

其中， $S(i, j)$  表示判别器的输出信号。

- (7) 对经过判别器择优输出信号  $S(i, j)$  按照式 (6.8) 进行范围映射，使其满足灰度图像的像素值范围  $[0, 255]$ ，即得到增强后的图像，记为  $I'(i, j)$


$$I'(i, j) = \frac{255 * (S(i, j) - \min(S(i, j)))}{\max(S(i, j)) - \min(S(i, j))} \quad (6.8)$$

其中， $\min(S(i, j))$  表示  $S(i, j)$  ( $i=1, 2, \dots, M; j=1, 2, \dots, N$ ) 中的最小值， $\max(S(i, j))$  表示  $S(i, j)$  ( $i=1, 2, \dots, M; j=1, 2, \dots, N$ ) 中的最大值。

### 6.2.3 实验结果与分析

双稳态模型参数设置如下： $a=0.01$ ， $b=1$ ，求解步长为 1。以图 6.1 所示的低剂量肺部 CT 图像作为研究对象，分别选择局部直方图均衡化、全局直方图均衡化和小波变换增强方法作为双稳态随机共振图像增强的比较对象，其图像增强的结果分别如图 6.2、6.3 和 6.4 所示。

从图中可以看出, 6.2 的(a)图、6.3 的(a)图和 6.4 的(a)图是局部直方图均衡化图, 与 6.2 的(b)图、6.3 的(b)图和 6.4 的(b)图全局直方图均衡化图相比, 图像增强效果有所改善, 目标区域和背景区域的对比度得到了提升, 但是它们在增强图像的同时也将噪声增强了, 在局部直方图均衡化和全局直方图均衡化的图像中仍旧存在较多的噪声, 甚至将噪声信号进一步的凸显了, 与原图相比, 尤其在肺部内出现了大量颗粒状的噪声, 从而不利于医生对病灶的诊断, 甚至会引起误诊。而 6.2 的(c)图、6.3 的(c)图和 6.4 的(c)图均为小波变换增强图, 该方法属于频域图像增强方法, 该方法虽然在一定程度上能够有效的抑制噪声, 但是目标区域和背景区域整体的灰度值得到了加强, 从而弱化了图像整体的对比度, 图像边缘轮廓等变得较模糊, 而本文方法的图像增强效果与其他三种传统方法相比, 具有显著的优势, 在目标区域和背景区域的对比度拉伸能力上要强于其他方法, 图像较清晰, 且轮廓边缘等细节信息也得到了进一步的加强, 而在图像增强的同时又有效地削弱了噪声信号, 并未在肺部出现多余的颗粒状噪声, 从而该方法可为临床上医生对肺部病灶的准确诊断提供可靠的参考。




(a)No1 低剂量肺部 CT 图

(b)No2 低剂量肺部 CT 图

(c)No3 低剂量肺部 CT 图

图 6.1 低剂量肺部 CT 原始图



(a)局部直方图均衡化图

(b)全局直方图均衡化图

(c)小波变换增强图

(d)本文方法增强图

图 6.2 No1 低剂量肺部 CT 不同方法图像增强图




图 6.3 No2 低剂量肺部 CT 不同方法图像增强图




图 6.4 No3 低剂量肺部 CT 不同方法图像增强图

不同方法低剂量肺部 CT 图像增强的定量评价指标 DSM 和标准差  $\sigma$  分别如表 6.1 和表 6.2 所示。从表 6.1 可以看出，本文方法的 DSM 值要普遍高于其他三种传统方法，说明本文方法图像增强的效果要明显优于其他方法。从表 6.2 的标准差中可以看出，本文方法的标准差值也普遍要高于其他三种方法，反映了本文方法在对比度上也得到了显著的提升，同时能更好的显示图像中的细节信息。对表中数据的分析可以看出，图像增强的定量评价指标基本上与主观定性分析相一致，这也进一步说明了本文双稳态随机共振方法在图像增强效果上要优于其他图像增强方法。

究其原因，在图像增强原理上有所不同，传统图像增强的方法将噪声作为有害的成分，通过削弱噪声来间接的增强有用信号。而随机共振机制是基于噪声、输入信号和非线性系统三者之间的协同作用，将噪声转变为弱信号中的有用信息，以此直接增强图像中的有用信号，达到消除噪声的目的。本文方法利用双稳态模型和淹没在图像背景中的肺部细节以及可视为噪声干扰的非均匀背景之间的协同作用，利用随机共振机制从而达到低剂量肺部 CT 图像的增强，从而改善了视觉效果。本文方法有效的实现了目标区域和背景区域的对比度拉伸，凸显了图像的对比度，使肺部结构更加清晰，轮廓边缘结构和细节信息得到了加强，同时在一定程度上有效的削弱了噪声，从而有利于临床医生对肺部病灶做出准确的诊断。



表 6.1 不同方法的图像增强 DSM 对比表

图像	DSM			
	局部直方图均衡化	全局直方图均衡化	小波图像增强	本文方法
No1	49.2675	39.0036	78.8931	<b>95.0665</b>
No2	46.6327	35.5225	83.0024	<b>91.1119</b>
No3	47.4528	35.3457	80.4188	<b>89.4168</b>

表 6.2 不同方法的图像增强标准差对比表

图像	标准差 $\sigma$			
	局部直方图均衡化	全局直方图均衡化	小波图像增强	本文方法
No1	72.3644	66.7931	73.1324	<b>83.7239</b>
No2	73.2307	66.9979	76.2345	<b>84.9907</b>
No3	73.8442	67.0016	75.4662	<b>85.3823</b>

### 6.3 基于方向响应的 IF 神经元模型低剂量肺部 CT 图像边缘检测

在第 5 章的原理基础上,本小结将基于方向响应的 IF 神经元模型应用于低剂量肺部 CT 图像的边缘检测。本小结以图 6.1 所示的三幅低剂量肺部 CT 图像作为实验原图,探究该方法在低剂量肺部 CT 图像边缘检测的效果,并选择 Prewitt 算子、Roberts 算子和 Log 算子三种传统的图像边缘检测方法作为比较对象,其实验结果如图 6.5、图 6.6 和图 6.7 所示。

从图中可以看出,6.5 的(b)图、6.6 的(b)图和 6.7 的(b)图为 Roberts 算子低剂量肺部 CT 边缘检测图,该方法图像边缘轮廓较模糊,且肺结点等内部细节信息基本被忽略了,而且噪声信号被大量检测出来,整体边缘检测效果较差,而相比之下,6.5 的(c)图、6.6 的(c)图和 6.7 的(c)图 Log 算子达到了过边缘检测的效果,在肺部出现了过量的类似于肺结点的细节信息,而且大量的噪声细节也被检测出来,明显处于过检测状态,不利于肺结点后续特征参数的计算。Prewitt 算子图像边缘检测的轮廓细节较清晰,但是丢失了一些肺部内关于肺结点的细节信息,且边缘检测中存在少量的噪声,而本文方法与其他传统图像边缘检测效果相比,具有显著的优势,图像边缘轮廓得到了凸显,肺部内的肺结点细节得到了加强,在一定程度上有效的抑制了噪声的检测,该模型能够有效的利用神经元脉冲发放特性与特定方向选择特性的结果,使其符合视觉神经元图像边缘检测的真实生理特性。




图 6.5 No1 低剂量肺部 CT 不同方法图像边缘检测图




图 6.6 No2 低剂量肺部 CT 不同方法图像边缘检测图




图 6.7 No3 低剂量肺部 CT 不同方法图像边缘检测图

表 6.3 不同方法的图像边缘检测的最大香农熵对比表

图像	<i>MSE</i>			
	Prewitt 算子	Roberts 算子	Log 算子	本文方法
No1	0.1234	0.1001	0.1783	<b>0.1791</b>
No2	0.1214	0.0983	0.1791	<b>0.1902</b>
No3	0.1188	0.0970	0.1741	<b>0.1942</b>

不同图像边缘检测方法的定量评价指标最大香农熵如表 6.3 所示。从表中可以看出，本文方法的最大香农熵值要普遍高于其他传统方法，而其中 Roberts 算子的最大香农熵值最小，这与前面的定性分析结果相吻合，也进一步说明了本文方法对低剂量肺部 CT 图像的边缘检

测效果要优于其他传统方法的图像边缘检测。

#### 6.4 双稳态随机共振机制的方向响应 IF 神经元低剂量肺部 CT 图像边缘检测

前面分别分析了双稳态随机共振方法和基于方向响应的 IF 神经元模型在低剂量肺部 CT 图像增强和图像边缘检测中的作用,从上述分析可知,两个模型分别在低剂量肺部 CT 图像增强和图像边缘检测中具有显著的优势,而本小结针对低剂量肺部 CT 图像的特点(图像内部具有一定的噪声),将双稳态模型和基于方向响应的 IF 神经元模型结合起来,先采用双稳态模型对低剂量肺部 CT 图像进行增强,在增强的基础上然后采用基于方向响应的 IF 神经元模型对其进行边缘检测,这样就能获得理想的效果。本文以图 6.1 所示的三幅低剂量肺部 CT 图作为实验原图,分别选取只采用基于方向响应的 IF 神经元模型低剂量肺部 CT 图像边缘检测(方法 1)、基于双稳态随机共振增强后采用 Prewitt 算子进行边缘检测(方法 2),基于双稳态随机共振增强后采用 Robert 算子进行边缘检测(方法 3)和基于双稳态随机共振增强后采用 Log 算子进行边缘检测(方法 4)作为比较对象,其结果如图 6.8、图 6.9 和图 6.10 所示。

从图中可以看出,图 6.8、图 6.9 和图 6.10 中的(b)图、(c)图和(d)图三组图的图像边缘检测效果相类似,图像边缘轮廓模糊,其中(b)图和(c)图肺部内的肺结点细节信息丢失严重,基本上只剩下外部肺形状轮廓,这对于后续计算肺部内结点特征参数将会产生不利的影响,而(d)图中虽然检测出了肺内部的结点细节信息,但是外部仍旧出现了类似于肺结点的颗粒状噪声,这将会对内部肺结点的特征检测产生干扰,而本文方法与上述三种方法相比,具有明显的优势:一方面有效的凸显了肺部轮廓边缘,并且对轮廓边缘进行了加强,而且有效的保留了肺内部的结点细节信息,有利于后续关于肺结点特征参数的提取,另一方法对噪声在一定程度上进行了有效的抑制,在图像中并未出现类似于肺结点的颗粒状噪声,图像边缘检测效果较理想。而与未采用的双稳态模型增强的 IF 神经元模型图像边缘检测(方法 1)的(a)图相比,虽然丢失了最外围的轮廓,但是外围轮廓对视觉效果和后续的特征参数提取的研究影响不大,本文方法得到的轮廓边缘与方法 1 的轮廓相比,更加的连续且得到了强化,而且相比较噪声在一定程度上得到了有效的抑制,图像边缘检测效果更加理想。




图 6.8 No1 不同方法低剂量肺部 CT 图像边缘检测图

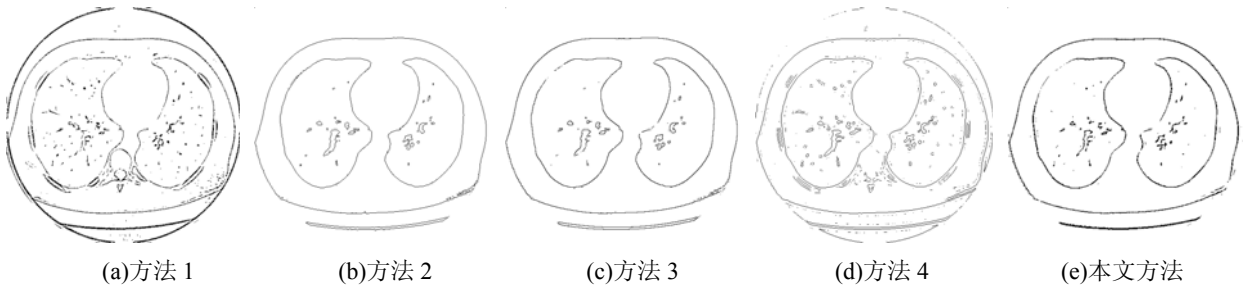


图 6.9 No2 不同方法低剂量肺部 CT 图像边缘检测图




图 6.10 No3 不同方法低剂量肺部 CT 图像边缘检测图

## 6.5 小结

本章结合视觉感知表现出的随机共振特性和方向选择特性，以低剂量肺部 CT 图像为研究对象，分别探究在图像增强和图像边缘检测中的应用。首先提出了基于双稳态随机共振机制的图像增强方法。该方法采用光栅扫描方法将二维图像信号进行降维，将其作为双稳态随机共振的输入信号，利用双稳态非线性系统、有用信号和噪声三者之间的协同作用，使噪声信号的能量向有用信号进行转移，从而实现低剂量肺部 CT 图像的增强。与其他传统图像方法相比，本文方法具有提升目标区域和背景区域之间的对比度，同时有效的保留了图像中的细节信息且在一定程度上有效的抑制噪声。其次，在第五章基于方向响应的 IF 神经元模型研究基础上，将其运用于低剂量肺部 CT 图像的边缘检测，实验结果表明：与传统图像边缘检测方法相比较，本方法能够有效的凸显图像的轮廓边缘，并且强化图像中的细节信息，在肺部结点处并未出现多余的颗粒状噪声，有效的抑制了噪声，图像边缘检测效果更佳。最后，结合双稳态随机共振机制模型和方向响应的 IF 神经元模型用于低剂量肺部 CT 图像的边缘检测，分别利用了双稳态随机共振机制图像增强和方向响应的 IF 神经元模型图像边缘检测的优势。实验结果表明：本方法有效的增强图像的边缘，使图像边缘变得连续，凸显图像中的细节，有效抑制肺内部类似于肺结点的颗粒状噪声，能够获得较理想的图像边缘检测效果。

## 第 7 章 总结与展望

### 7.1 总结

目前对于视觉神经系统的研究往往侧重于验证或揭示视觉信息加工过程中所表现出来的心理或生理现象，而对于信息技术领域而言，如何将这种特性或现象所蕴含的内在机制应用于智能信息处理显得尤为重要。本文以视觉感知系统所表现出来的随机共振特性、神经元的方向选择特性以及脉冲序列编码为例，研究利用生物视觉感知计算模型在实现图像处理典型应用时的新思路。

视觉神经系统在弱信号感知中，表现出了噪声敏感的随机共振特性。但其在视觉信息流加工中扮演了什么样的重要作用，以及如何将其内在机制应用于图像增强，并未有深入的研究和分析。本文既考虑到了视皮层神经元之间的互连性以及层次性，又考虑到了图像处理算法实时性的需求，构建了级联双稳态模型和阵列级联 FHN 神经元模型，尝试从信号增强的角度对随机共振机制进行研究，提出并实现了一种强噪声背景下图像增强的随机共振新方法。

同时，神经电生理实验也证实视皮质神经元在感知图像信息时，表现出对于边缘方向的选择特性以及一定的脉冲序列编码规律。但上述特性是否能给智能信息处理提供一种新途径，例如是否可以应用于图像边缘检测，可能由于计算神经具有较高的学科交叉性，所以这类问题一直以来未受到足够多的关注。本文利用典型的神经元电生理模型，构建基于方向响应的 IF 神经元模型，反映视皮质神经元的方向选择性以及脉冲编码过程，并以图像的边缘检测为具体应用，给出并实现了一种基于视觉机制的图像边缘检测新方法。

最后，论文将新方法应用于医学图像处理的实际应用。以低剂量肺部 CT 图像为例，验证双稳态模型在图像随机共振增强中的有效性和优势；利用方向响应的 IF 神经元模型，实现了 CT 影像边缘细节的检测；论文还将上述图像增强和边缘检测新方法有效的结合，实现了在随机共振增强基础上的弱细节检测，证实了生物视觉感知计算模型在图像处理应用中的可行性。论文具体研究工作总结如下：

- (1) 本文首先考虑信号连续级联传递特性，提出了一种级联双稳态模型，将随机共振机制应用于强噪声背景下的弱信号增强。以特定强噪声背景下的一维弱信号为研究对象，给出了利用定量评价指标选取模型最优参数的方法，实现一维弱信号的增强。进而将研究对象扩展到灰度图像，结合光栅扫描法实现图像的降维，给出了灰度图像增强应用的实现步骤和过程。实验结果表明：级联双稳态模型具有低通滤波特性，有效的去除峰值处的毛刺，使信号更光滑且能够凸显信号的轮廓。
- (2) 在级联特性基础上，考虑了神经元突触多输入连接以及动作电位的连续传递特性，提出

了一种基于阵列级联 FHN 神经元模型的弱信号随机共振增强方法。以一维含噪信号为例, 尝试从定性和定量角度研究新方法在强噪声背景下的弱信号增强效果, 并将其拓展应用于强噪声背景下的二值弱图像增强, 结合光栅扫描和 Hilbert 扫描法实现图像降维, 有效的解决了图像空间结构特性保留问题, 并给出了应用于二值图像增强的基本思路 and 操作流程。实验结果表明: 新方法使输出信号更光滑, 信号轮廓与细节得到凸显, 噪声在一定程度上得到了有效的抑制, 且对内噪声强度具有较强的鲁棒性和自适应性, 输出图像质量得到了显著改善。

- (3) 针对视觉感知中神经元对激励具有的方向选择特性, 提出了一种基于方向响应的 IF 神经元模型的图像边缘检测方法。采用 Log-Gabor 滤波器对图像进行多方向分解, 以充分反映视觉系统的方向选择性, 并结合 IF 神经元模型的动作电位脉冲发放以及序列编码特性, 用于图像的边缘检测。实验结果表明: 本文方法图像边缘检测效果更理想, 能够丰富图像的细节, 凸显图像的轮廓, 加强图像的层次感。
- (4) 最后从具体应用着手, 以低剂量肺部 CT 图像为例, 首先给出了双稳态随机共振机制模型用于低剂量肺部 CT 图像增强的实现方法, 结果表明: 新方法能够有效的提升背景和目标区域的对比度, 凸显图像中目标区域, 有效的降低噪声。其次, 尝试将基于方向响应的 IF 神经元模型应用于低剂量肺部 CT 图像的边缘检测, 结果表明, 新方法能够有效的凸显图像的轮廓边缘, 强化图像中的细节信息, 在肺部结点处并未出现多余的颗粒状噪声, 在一定程度上有效的抑制噪声。最后, 将上述图像增强和边缘检测新方法有效的结合, 实现了在随机共振增强基础上的弱细节边缘检测。实验结果表明: 新方法能够检测出连续的边缘轮廓, 加强图像中的细节信息, 有效的抑制内部颗粒状噪声的产生, 能够获得较理想的图像边缘检测效果。

## 7.2 展望

论文首先将计算模型应用于随机共振信号增强的研究, 证实了该方法的可行性和优越性。对于级联双稳态模型, 可以进一步深入研究模型参数的自适应选取以及噪声类型对信号增强的影响; 对于阵列级联 FHN 神经元模型可以引入神经电生理中的延时反馈、侧抑制等生理特性, 更加真实的反映生物特性。

另外, 对于图像信号, 本文采用降维方式处理, 这不可避免的增加了处理的时间代价和复杂性, 同时不利于图像空间结构特性的保留, 后续可以引入二维模板扫描法直接在图像上处理, 从而避免了图像降维操作, 有效的提升时间效率, 更好的保留图像的结构特性。

其次, 将视觉感知系统中神经元表现出的生理特性(方向选择性和动作电位脉冲发放机制)模型应用于图像的边缘检测, 探究了该模型的有效性和准确性。本文引入了最简单的 IF 神经元模型, 后续可以针对构建复杂的互联神经网络作进一步的深入研究。

最后, 本文结合双稳态随机共振机制和神经元模型对低剂量肺部 CT 图像进行初步应用研究。后续可以将应用扩展到语音复原、故障检测、信息编码等领域。

## 致谢

在这篇毕业论文即将完成之际，也昭示着我近二十年的求学之路画上了圆满的句号。这二十年的求学生涯将会留下美好的记忆，也将会成为我人生中的一笔巨大的财富。

在学业即将完成之际，我衷心地感谢我的导师范影乐教授。能成为范老师的学生，是我这一生中最大的幸运。在这两年半的求学时间里，敬爱的范老师在学习、生活和思想等方面都给与了无微不至的指导和关心。在学习科研中，范老师严谨的治学态度、敏锐的科研洞察力、一丝不苟的为师之道，时时刻刻影响和感染着我。从晦涩难懂的 MFC 学习指导，到图像处理编程遇到的 Bug 调试，到实验方案的讨论交流，再到小论文十几遍的修改完善，都倾注了范老师大量的精力和心血。在生活上，范老师就像一位亲密无间的朋友，聆听我们的抱怨，时刻关心我们的生活。在思想上，当我对工作对生活迷茫时，范老师总能以他丰富的人生经历和高尚的人格魅力，为我排忧解难，让我有了继续前进的信心和勇气。范老师是一位能够善于挖掘学生能力的好老师，他给与我足够的空间发挥自己的才能，而在我遇到困难的时候总能伸出援助之手。无论是为人还是为学，范老师都将是以后学习的榜样。虽然与范老师相处学习的时间只有两年半，但是我相信范老师对我的影响将会是一辈子的。在范老师的带领下，两年半的研究生生涯是快乐且充实的。再次衷心感谢范老师对我的培养，祝愿范老师健康平安、快乐幸福！

感谢武薇老师，她让我明白学生与老师之间不存在隔阂，感谢她对我科研中提出的宝贵建议和指导。感谢詹跃荣师兄、王佳师姐、沈学丽师姐、赵磊师兄和王海玲师姐，在生活和学习上给与的无私帮助，感谢同窗好友郭芳芳，感谢在学习上的交流和帮助，同时感谢师弟廖进文、罗佳骏、李丹菁、王迪、王典，师妹陆晓娟、王梦蕾、方芳，有了你们实验室充满了欢声笑语，给读研生活增添了许多乐趣。

最后，我要感谢我的家人。谢谢父母多年来对我付出的一切，给与我的无私帮助与奉献。是他们的支持与鼓励，让我坚定追逐梦想的步伐，走向属于自己的人生道路。

下沙.杭州电子科技大学  
二零一三年十一月二十日

## 参考文献

- [1] Karpenka N V, Feroz F, Hobson M. A simple and robust method for automated photometric classification of supernovae using neural networks[J]. Monthly Notices of the Royal Astronomical Society, 2013, 429(2): 1278-1285.
- [2] Sadok A, Teghem J, Chabcoub H. Grouping genetic algorithms for a bi-objective inventory routing problem[J]. International Journal of Multicriteria Decision Making, 2013, 3(2): 256-276.
- [3] Yin Z H, Yu B, Lin J. Security Risk Evaluation on Long Span Bridge Structure Based on Grey Fuzzy Theory[J]. Applied Mechanics and Materials, 2013, 433: 1005-1008.
- [4] Liska C, Petrun E L, Sellnow T L, et al. Chaos theory, self-organization, and industrial accidents: crisis communication in the Kingston coal ash spill[J]. Southern Communication Journal, 2012, 77(3): 180-197.
- [5] Kier L B, Tombes R, Hall L H, et al. A Cellular Automata Model of Proton Hopping Down a Channel[J]. Chemistry & biodiversity, 2013, 10(3): 338-342.
- [6] Winkler I, Czigler I. Evidence from auditory and visual event-related potential (ERP) studies of deviance detection (MMN and vMMN) linking predictive coding theories and perceptual object representations[J]. International Journal of Psychophysiology, 2012, 83(2): 132-143.
- [7] Dosenbach N U, Nardos B, Cohen A L, et al. Prediction of individual brain maturity using fMRI[J]. Science, 2010, 329(5997): 1358-1361.
- [8] Helmchen F, Denk W. Deep tissue two-photon microscopy[J]. Nature methods, 2005, 2(12): 932-940.
- [9] Cheung K C, Djupsund K, Dan Y, et al. Implantable multichannel electrode array based on SOI technology[J]. Microelectromechanical Systems, Journal of, 2003, 12(2): 179-184.
- [10] 江梅. 基于生物视觉感知模型的目标识别[D]. 江苏: 南京理工大学, 2011.
- [11] 杨文璐. 视觉感知模型与编码算法研究[D]. 上海: 上海交通大学, 2008.
- [12] 孙昊, 郭爱克. 视觉颜色感受野的自组织生成[J]. 中国科学(B 辑), 1995, 25(11): 1178-1185.



- [13] Grossberg S, Mingolla E, Ross W D. Visual brain and visual perception: How does the cortex do perceptual grouping?[J]. Trends in neurosciences, 1997, 20(3): 106-111.
- [14] 胡德昆. 基于生物视觉感知机制的图像理解技术研究[D]. 四川: 电子科技大学, 2012.
- [15] Linsker R. Self-organization in a perceptual network[J]. Computer, 1988, 21(3): 105-117.
- [16] Lamme V A, Super H, Spekreijse H. Feedforward, horizontal, and feedback processing in the visual cortex[J]. Current opinion in neurobiology, 1998, 8(4): 529-535.
- [17] Zemel R S, Sejnowski T J. A model for encoding multiple object motions and self-motion in area MST of primate visual cortex[J]. The Journal of Neuroscience, 1998, 18(1): 531-547.
- [18] Yen S-C, Finkel L H. Extraction of perceptually salient contours by striate cortical networks[J]. Vision research, 1998, 38(5): 719-741.
- [19] Douglass J K, Wilkens L, Pantazelou E, et al. Noise enhancement of information transfer in crayfish mechanoreceptors by stochastic resonance[J]. Nature, 1993, 365(6444): 337-340.
- [20] Braun H A, Wissing H, Schäfer K, et al. Oscillation and noise determine signal transduction in shark multimodal sensory cells[J]. Nature, 1994, 367(6460): 270-273.
- [21] Levin J, Miller J. Stochastic resonance enhances neural encoding of broadband stimuli in the cricket cercal sensory system[J]. Nature, 1996, 380: 165-168.
- [22] Sakumura Y, Ishii S. Stochastic resonance with differential code in feedforward network with intra-layer random connections[J]. Neural networks, 2006, 19(4): 469-476.
- [23] Hennig M H, Kerscher N J, Funke K, et al. Stochastic resonance in visual cortical neurons: does the eye-tremor actually improve visual acuity?[J]. Neurocomputing, 2002, 44: 115-120.
- [24] Aihara T, Kitajo K, Nozaki D, et al. Internal noise determines external stochastic resonance in visual perception[J]. Vision research, 2008, 48(14): 1569-1573.
- [25] Sasaki H, Sakane S, Ishida T, et al. Suprathreshold stochastic resonance in visual signal detection[J]. Behavioural brain research, 2008, 193(1): 152-155.
- [26] Funke K, Kerscher N J, Wörgötter F. Noise - improved signal detection in cat primary visual cortex via a well - balanced stochastic resonance - like procedure[J]. European Journal of Neuroscience, 2007, 26(5): 1322-1332.
- [27] Rallabandi V. Enhancement of ultrasound images using stochastic resonance-based wavelet transform[J]. Computerized medical imaging and graphics, 2008, 32(4): 316-320.
- [28] Rallabandi V, Roy P K. Magnetic resonance image enhancement using stochastic resonance

- in Fourier domain[J]. *Magnetic Resonance Imaging*, 2010, 28(9): 1361-1373.
- [29] Ryu C, Kong S G, Kim H. Enhancement of feature extraction for low-quality fingerprint images using stochastic resonance[J]. *Pattern Recognition Letters*, 2011, 32(2): 107-113.
- [30] 冷永刚, 赵尔华, 石鹏等. 二维随机共振参数调节的图像处理[J]. *天津大学学报*, 2011, 44(10): 907-913.
- [31] Hong S W, Tong F, Seiffert A E. Direction-selective patterns of activity in human visual cortex suggest common neural substrates for different types of motion[J]. *Neuropsychologia*, 2012, 50(4): 514-521.
- [32] Rochefort N L, Narushima M, Grienberger C, et al. Development of direction selectivity in mouse cortical neurons[J]. *Neuron*, 2011, 71(3): 425-432.
- [33] Govenlock S W, Taylor C P, Sekuler A B, et al. The effect of aging on the orientational selectivity of the human visual system[J]. *Vision research*, 2009, 49(1): 164-172.
- [34] Xia J, Tang Y, Liang Z, et al. GABA increases stimulus selectivity of neurons in primary visual cortices of cats chronically treated with morphine[J]. *Neuroscience*, 2013.
- [35] Priebe N J, Ferster D. Direction selectivity of excitation and inhibition in simple cells of the cat primary visual cortex[J]. *Neuron*, 2005, 45(1): 133-145.
- [36] Fried S I, Werblin F S. Directional selectivity is formed at multiple levels by laterally offset inhibition in the rabbit retina[J]. *Neuron*, 2005, 46(1): 117-127.
- [37] Barlow H. Visual experience and cortical development[J]. *Nature*, 1975, 258(5532): 199-204.
- [38] Huang L, Pashler H. Reversing the attention effect in figure-ground perception[J]. *Psychological Science*, 2009, 20(10): 1199-1201.
- [39] 陈可. 弱信号随机共振检测机制及其在图像增强中的应用研究[D]. 浙江: 杭州电子科技大学, 2011.
- [40] Leng Y-g, Wang T-y, Guo Y, et al. Engineering signal processing based on bistable stochastic resonance[J]. *Mechanical Systems and Signal Processing*, 2007, 21(1): 138-150.
- [41] Tai C, de Groat W C, Roppolo J R. Simulation of nerve block by high-frequency sinusoidal electrical current based on the Hodgkin-Huxley model[J]. *Neural Systems and Rehabilitation Engineering, IEEE Transactions on*, 2005, 13(3): 415-422.
- [42] 梁军利, 杨树元, 唐志峰. 基于随机共振的微弱信号检测[J]. *电子与信息学报*, 2006, 28(6): 1068-1074.

- [43] Feng J. Behaviors of spike output jitter in the integrate-and-fire model[J]. Physical review letters, 1997, 79(22): 4505.
- [44] Izhikevich E M. Which model to use for cortical spiking neurons?[J]. Neural Networks, IEEE Transactions on, 2004, 15(5): 1063-1070.
- [45] Wu Z L, Wang Z J. The Simulation of Retinal Inner Plexiform Layer Based on Parallel Algorithm[J]. Advanced Materials Research, 2013, 680: 509-514.
- [46] Carson Pun K, Nguyen T Q. Widely linear filter bank equalizer for real STBC[J]. Signal Processing, IEEE Transactions on, 2008, 56(9): 4544-4548.
- [47] Souden M, Benesty J, Affes S. On the global output SNR of the parameterized frequency-domain multichannel noise reduction Wiener filter[J]. Signal Processing Letters, IEEE, 2010, 17(5): 425-428.
- [48] Villa J, Rodríguez-Vera R, Antonio Quiroga J, et al. Anisotropic phase-map denoising using a regularized cost-function with complex-valued Markov-random-fields[J]. Optics and Lasers in Engineering, 2010, 48(6): 650-656.
- [49] Nasri M, Nezamabadi-pour H. Image denoising in the wavelet domain using a new adaptive thresholding function[J]. Neurocomputing, 2009, 72(4): 1012-1025.
- [50] Bulsara A R, Gammaitoni L. Tuning in to noise[J]. Physics Today, 1996, 49: 39.
- [51] Heneghan C, Chow C, Collins J, et al. Information measures quantifying aperiodic stochastic resonance[J]. Physical Review E, 1996, 54(3): R2228.
- [52] Fetterly K A, Schueler B A. Physical evaluation of prototype high-performance anti-scatter grids: potential for improved digital radiographic image quality[J]. Physics in Medicine and Biology, 2009, 54(2): N37.
- [53] Juang L-H, Wu M-N. Image noise reduction using Wiener filtering with pseudo-inverse[J]. Measurement, 2010, 43(10): 1649-1655.
- [54] 王海玲, 范影乐, 陈可等. 基于 FHN 神经元随机共振的低剂量肺部 CT 图像增强[J]. 航天医学与医学工程, 2012, 25(2): 121-125.
- [55] 陈金龙, 范影乐, 武薇等. 基于阵列级联 FHN 神经元的弱信号随机共振复原研究[J]. 航天医学与医学工程, 2013, 26(4): 317-322.
- [56] Khalid N, Ahmad S, Noor N, et al. Parallel approach of Sobel Edge Detector on Multicore Platform[J]. International Journal of Computers and Communications Issue, 2011, 4:

236-244.

- [57] Maini R, Aggarwal H. Study and comparison of various image edge detection techniques[J]. International Journal of Image Processing (IJIP), 2009, 3(1): 1-11.
- [58] Bao P, Zhang L, Wu X. Canny edge detection enhancement by scale multiplication[J]. Pattern Analysis and Machine Intelligence, IEEE Transactions on, 2005, 27(9): 1485-1490.
- [59] Zhou L, Sun Y, Zheng J. Automated color image edge detection using improved PCNN model[J]. WSEAS transactions on computers, 2008, 7(4): 184-189.
- [60] Paik J K, Park Y C, Park S W. An edge detection approach to digital image stabilization based on tri-state adaptive linear neurons[J]. Consumer Electronics, IEEE Transactions on, 1991, 37(3): 521-530.
- [61] Liu H. Force field convergence map and Log-Gabor filter based multi-view ear feature extraction[J]. Neurocomputing, 2012, 76(1): 2-8.
- [62] Brink A. Using spatial information as an aid to maximum entropy image threshold selection[J]. Pattern Recognition Letters, 1996, 17(1): 29-36.
- [63] Ichikawa T, Erturk S M, Araki T. Multiphasic contrast-enhanced multidetector-row CT of liver: contrast-enhancement theory and practical scan protocol with a combination of fixed injection duration and patients' body-weight-tailored dose of contrast material[J]. European journal of radiology, 2006, 58(2): 165-176.
- [64] Zhu H, Chan F H, Lam F K. Image contrast enhancement by constrained local histogram equalization[J]. Computer Vision and Image Understanding, 1999, 73(2): 281-290.
- [65] Eltoukhy M M, Faye I, Samir B B. Breast cancer diagnosis in digital mammogram using multiscale curvelet transform[J]. Computerized Medical Imaging and Graphics, 2010, 34(4): 269-276.
- [66] Yang G-Z, Hansell D M. CT image enhancement with wavelet analysis for the detection of small airways disease[J]. Medical Imaging, IEEE Transactions on, 1997, 16(6): 953-961.
- [67] Singh S, Bovis K. An evaluation of contrast enhancement techniques for mammographic breast masses[J]. Information Technology in Biomedicine, IEEE Transactions on, 2005, 9(1): 109-119.
- [68] Chang D-C, Wu W-R. Image contrast enhancement based on a histogram transformation of local standard deviation[J]. Medical Imaging, IEEE Transactions on, 1998, 17(4): 518-531.

## 附 录:

### 作者在读期间发表的学术论文及参加的科研项目

#### 发表(录用)学术论文:

1. 基于阵列级联 FHN 神经元的弱信号随机共振复原研究[J]. 航天医学与医学工程, 2013, 26(4): 317-322. (一级期刊), 1/4
2. 基于小波包分解的含噪语音时频特性分析及端点检测[J]. 数据采集与处理, 已录用, 待发表. (核心期刊), 1/4

#### 授权(申请)专利:

##### 发明专利

1. 一种皮层脑电信号的网络系统随机共振复原方法, 已授权, ZL201110294900.8, 4/5。
2. 基于时频瞬时能量谱的低信噪比语音端点检测方法, 已公开, 201310017877.7, 2/5。
3. 阵列级联 FHN 模型随机共振机制的二值图像增强方法, 已公开, 20120437954.X, 2/6。
4. 一种 OCT 影像质量客观无参考型评价方法, 已公开, 201310189305.7, 2/5。
5. 基于皮层神经元视觉方向响应的图像边缘检测方法, 已公开, 201310290419.0, 2/6。

##### 实用新型专利

1. 一种基于机器视觉的 PCB 板缺陷自动检测装置, 已授权, ZL201320201077.6, 2/4。

#### 参与的科研项目:

1. 基于双稳态随机共振非周期阈上响应的强噪声图像增强技术研究(60872090), 国家自然科学基金。