

杭州电子科技大学

硕 士 学 位 论 文

题目：基于青光眼 OCT 影像的眼前房角 闭合程度评估研究

研 究 生 王梦蕾

专 业 控制工程

指导教师 范影乐 教授

完成日期 2015 年 3 月

杭州电子科技大学硕士学位论文

基于青光眼 OCT 影像的眼前房角
闭合程度评估研究

研 究 生： 王梦蕾

指导教师： 范影乐 教授

2015 年 3 月

**Dissertation Submitted to Hangzhou Dianzi University
for the Degree of Master**

**Study on assessment of the angular width of
the anterior chamber in Glaucoma OCT Imaging**

**Candidate: Wang Menglei
Supervisor: Prof. Fan Yingle**

March, 2015

杭州电子科技大学 学位论文原创性声明和使用授权说明

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

论文作者签名：日期： 年 月 日

学位论文使用授权说明

本人完全了解杭州电子科技大学关于保留和使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属杭州电子科技大学。本人保证毕业离校后，发表论文或使用论文工作成果时署各单位仍然为杭州电子科技大学。学校有权保留送交论文的复印件，允许查阅和借阅论文；学校可以公布论文的全部或部分内容，可以允许采用影印、缩印或其它复制手段保存论文。（保密论文在解密后遵守此规定）

论文作者签名：日期： 年 月 日

指导教师签名：日期： 年 月 日

摘 要

依据眼前房角光学相干断层扫描技术(OCT)进行房角自动评估,是青光眼早期诊断和治疗的关键手段。但目前临床上医生更多的还是从眼前房角的具体结构参数测量出发,不仅测量任务繁重,而且评价主观性强。本文尝试利用图像特征对眼前房角 OCT 成像进行描述,进而利用分类器对眼前房角闭合程度进行评估。本文首先利用特征边缘提取眼前房角感兴趣区域,对图像的重点房角隐窝区域进行划分。其次利用梯度方向直方图(HOG)、共生梯度方向直方图(COHOG)等特征分别描述感兴趣区域,并且通过支持向量机(SVM)进行房角评估。最后,从点、线、面三个层次分别考虑合适的特征描述算法,综合利用多个特征全面描述房角隐窝区域,并且以 Shaffer 评级方法为依据,对房角状态进行多级分类。本文主要工作和研究成果如下:

- (1) 提出了一种基于特征边缘的感兴趣区域自动提取方法。首先,考虑到各类型图像噪声及失真情况后,提出了一种多层级的图像分割算法,为感兴趣区域的精确定位提供了前提。然后,采取基于像素灰度方向连续性的边缘检测算法,简单快速定位虹膜、角膜边缘。最后,通过对边缘进行线性拟合,确定拟合直线相交点,根据相交点定位感兴趣区域。
- (2) 提出了一种基于感兴趣区域及 HOG 特征的眼前房角分类方法。利用图像分割结合基于灰度方向连续性的边缘检测算法找出基准点,定位出感兴趣区域。通过提取 HOG 特征,结合支持向量机进行分类器训练与图像最终分类。实验结果表明,第一,本文感兴趣区域自动提取方法定位快速、准确,为特征提取、样本分类提供了保障;第二,HOG 特征与支持向量机的结合较好的区分出闭合、开放状态,分类效果较佳且稳定。
- (3) 提出了一种基于 COHOG 改进方法的眼前房角 OCT 图像分类方法。利用一对像素点之间空间位置信息的同时,采用一种余弦定理方式计算加权值,增加梯度幅值信息的利用,重新统计 COHOG 特征。然后对高维的 COHOG 特征采用 PCA 方法降维。最后仍然结合 SVM 方法实现眼前房角闭合状态的两级分类。实验结果证明,利用本文方法两级分类正确率达到了 84.7%,增强分类效果显著。
- (4) 提出了一种基于多特征的眼前房角图像多级评估方法。从点、线、面三个层面全面描述感兴趣区域,通过融合特征描述提升各类别图像的区分信息,为增强多分类效果提供可靠性。同时,本文采用了二叉树的多分类模型,在两分类的基础上,依据 shaffer 评级标准进行五级分类,实验结果表明,在高质量图片中利用本文方法进行五级分类,各类样本分类结果均高于 70%,验证了青光眼图片的计算机多级分类的可行性。

关键词: 光学相干断层扫描, 前房角成像, 感兴趣区域, 支持向量机, 图像分类

ABSTRACT

It is a key technology to diagnose and treatment glaucoma that automatically assessment anterior chamber angle timely in OCT images. Now, researchers measure and analyze the detailed data of all kinds of structural parameters mainly in term of the specific structure of anterior chamber angle , which leads to the facts that not only the measurement tasks are arduous, but also the evaluation is highly subjective. This paper tries to use of the image feature to describe eye anterior chamber Angle in OCT images, and then using the support vector machine (SVM) to evaluate the degree of anterior chamber Angle . First, interested front corner area is extracted with the feature edge, angle of key areas of the image is divided crypt in the paper, then describe the interested areas with features such as HOG, COHOG, and use SVM for image classification. Finally, appropriate characterization algorithm were considered in the point, line, surface three levels, and use multi-features to describe angle recess area, and classify the image to multi-levels with the Shaffer rating methodology.

The main work and research results of this thesis are summarized as follows:

- (1) A method for extraction the region of interest based on edge features automatically was proposed. First, considering the various types of image noise and distortion , we proposed an algorithm for image segmentation with multi-level, which provided a premise for pinpoint the area of interest. Then, aimed at the characteristics of the front angle structure and the situation that there only the iris and the corneal region exist in the image, hence an edge detection algorithm was adopted which based on the direction of the continuity of pixel. for positioning the iris and the cornea edge quickly and easily. At last, we determined the intersection point of fitting a straight line through the edge liner fit and located the areas of interest according to the point of intersection.
- (2) This thesis puts forward a classification method for anterior chamber angle based on Region of Interest and HOG feature. The Region of Interest is located through the reference point calculated on the basis of image segmentation. The classifier training and image are finally classified by the combination of HOG feature and support vector machine. The test results show that firstly the region of interest automatic extraction methods proposed locate quickly and accurately, which provided a guarantee for feature extraction and the classification of samples, second, the combination of HOG feature and the support vector could distinguish closed and open state better, which made the classification better and stable.

- (3) This thesis puts forward a classification method for OCT images of anterior chamber angle based on COHOG. While using the information of the pixels' space position, I adopt a law-of-cosines method to calculate the weighed value, for the purpose of increasing the use of gradient magnitude and re-counting the COHOG feature. Then, COHOG characteristics of high-dimensional method of dimension reduction using PCA. At last, a SVM method classifying OCT images of anterior chamber into two groups is achieved. The test results show that the above-mentioned method has an obvious effect on improving the classification.
- (4) Based on the needs of sub-dividing the chamber angle, this thesis puts forward a multi-level assessment method for glaucoma images. To describe the Region of Interest from gradient, EDGELET feature and COHOG feature can improve the differentiating information of all kinds of images and provide more reliability for multi-classification. In the meanwhile, this thesis adopts binary-tree SVM multi-classification algorithm. Based on this method and using the SVM, images are classified into five levels. The test results show that the effects of using this classification method in high-quality photographs are good

Keywords: optical coherence tomography (OCT), anterior chamber angle imaging, region of interest(ROI), support vector machine(SVM), image classification

目 录

摘 要	I
ABSTRACT	II
第 1 章 绪论	1
1.1 选题背景及研究意义	1
1.2 国内外研究现状和发展趋势	3
1.3 本文主要工作及创新点	5
1.4 本文的组织结构	6
第 2 章 图像特征提取与图像分类方法	7
2.1 感兴趣区域提取	7
2.1.1 感兴趣区域提取研究现状	7
2.1.2 医学图像感兴趣区域提取	8
2.2 常用图像特征	10
2.3 支持向量机基础	11
2.3.1 线性可分	11
2.3.2 线性不可分	11
2.4 分类评价指标	12
2.5 小结	13
第 3 章 基于感兴趣区域及 HOG 特征的眼前房角分级评估	14
3.1 眼前房角 OCT 图像特点	14
3.2 眼前房角图像 ROI 提取	15
3.2.1 图像分割过程分析	16
3.2.2 边缘检测过程分析	18
3.2.3 感兴趣区域提取过程分析	19
3.3 HOG 特征提取	19
3.4 评估过程及结果分析	21
3.4.1 特征提取参数选择实验分析	22
3.4.2 分级评估及结果分析	23
3.5 小结	23
第 4 章 基于 COHOG 及其改进方法的眼前房角分级评估	25
4.1 COHOG 方法介绍	26

4.2 改进的 COHOG 方法	27
4.3 PCA 降维方法	28
4.4 评估过程及结果分析	29
4.4.1 特征提取参数选择过程及结果分析	29
4.4.2 分级评估及结果分析	30
4.5 小结	31
第 5 章 基于多特征的青光眼前房角 OCT 图像多级评估	32
5.1 特征选择	33
5.2 特征提取过程	33
5.2.1 梯度计算	33
5.2.2 EDGELET 特征计算	34
5.3 特征融合与降维	35
5.3.1 特征融合方法概述	35
5.3.2 串行特征融合与降维	36
5.4 多类分类器设计	36
5.5 两级评估及结果分析	37
5.6 多级评估及结果分析	38
5.6.1 实验样本选取	38
5.6.2 多级评估结果	39
5.7 小结	40
第 6 章 总结与展望	41
6.1 本文总结	41
6.2 未来展望	42
致谢	43
参考文献	44
附 录	49

第 1 章 绪论

1.1 选题背景及研究意义

青光眼是病因极其复杂型眼科疾病，在四大致盲性眼科疾病中位列第二^[1]，仅次于白内障。在全球范围内，目前青光眼患者已经超过 7000 万人，在这些患者中约 10% 最终双眼失明。预计到 2020 年世界青光眼患者将上升至 7960 万^[2]。在医学上，青光眼主要分为三大类，分别是原发性、先天性和继发性青光眼。本文仅对患病比例较高的原发性青光眼进行实验研究。其中原发性青光眼又可分为开角型和闭角型两种^[3]，主要判断依据是房角的开、合状态。原发性闭角型青光眼(PPrimary Angle Closure Glaucoma,PACG)患者眼压、房角、前房均会出现异常，并且伴随有视力减退和头晕、头疼。原发性开角型青光眼(PPrimary Open-Angle Glaucoma,POAG)发病属慢性，前期症状并不明显，其临床特点有视野损坏、视神经萎缩等。因地域环境差异和种族遗传问题，PACG 的高发区域为亚洲地区，约占发病人数的 87%，其中以中国的发病率最高，平均患病率在 1.5% 左右，约 1009 万人，占总发病数的 47.5%^[2]。

青光眼的明显特征为眼压持续性或者间断性升高。过高的眼压水平致使患者视神经逐渐萎缩，眼球各部分组织及视觉功能将受到严重损坏及影响，进而导致视野逐步缩小以及视觉能力减退，最终视觉能力丧失^[4]。青光眼临床上的特征主要表现在眼前房角区域。眼前房角是角膜和虹膜之间的夹角，也是房水流通的区域。正常情况下，房水产生后流入后房，通过瞳孔进入前房，经小梁网、Schlemm 氏管和集液管，最后进入巩膜表层的睫状前静脉^[3]。房角内部在眼压正常情况下，保持房水流通的动态平衡。一旦平衡被打破，眼睛功能将受到严重损坏。开角型青光眼患者，房角始终呈现开放状态，房水的流出受到小梁网-Schlemm 管系统阻拦，房水积压致使眼压升高^[5]。与此相反，闭角型青光眼患者则是因为房角周边虹膜与小梁网产生粘连，前房变浅，房角变窄，致使房水外流受阻，眼压逐渐升高。

青光眼的严重后果表现为不可恢复的视力丧失，但早期诊断和细心积极的治疗，可使大部分患者仍保有视觉功能。虽然现在青光眼依然不能治愈，但随着医疗水平的提升，通过药物治疗或者手术手段，大部分的青光眼病情可得到稳定控制。所以提升青光眼检查手段对于青光眼的及早发现、及时治疗是非常重要的。

眼科检查手段的发展依赖于医学检查手段的发展更新，最初直接检查，再到借助医疗器械接触检查，现在影像学检查已经成为医学领域广泛使用的检查手段。1895 年，医学影像学发展的大幕拉开，德国物理学家伦琴发现了 X 线并将其在医学上应用。近年来，随着计算机网络以及医学影像学硬件技术的不断提高，医学影像学的发展阔步前进。目前，医学影像学已经形成了比较完善的体系，包括常规 X 线成像(X-ray Imaging)^[6]、计算机断层扫描(Computed Tomography,CT)、磁共振成像(Magnetic Resonance Imaging)、超声成像(Ultrasonography,USG)等。这些检查手段^[7]在临床应用中均发挥了重要价值，解决了复杂型眼科疾病的深入检查需要，弥补了临床检查的不足。以下几种为常用的眼科检查方法：

(1)房角镜检查

房角镜在二十世纪初始由 Trantas 和 Salzmann 所研发^[8], 二十世纪 60 年代被广泛应用于眼科检查。目前眼前房角评估中房角镜检查结果是评判标准。1936 年, 针对闭角型和开角型青光眼, Barkan 采用直接房角镜进行了分类^{[9][10]}。直接前房角镜和间接前房角镜是在房角镜在光学原理下所分类得出的, 前者利用光线折射原理, 后者利用光线反射原理。利用直接房角镜检查时需被检查者平躺, 医生手持生物显微镜, 再辅助使用眼撑器才可对房角解剖结构展开观察, 但是其观察的信息较为全面且连续。间接前房角镜检查利用镜面反射观察房角, 相对方便, 但需配合裂隙生物显微镜使用。按照所运用的镜面数不同, 间接房角镜分为单面、双面、三面以及四面反射镜。Goidmann 三面反射镜和 Zeiss 四面反射镜是其中最具代表性的。间接的方法缺点是得到的图像片面、倒像, 还可能由人为原因对检查结果造成干扰。总体来说房角镜检查对操作者的要求很高, 需要经过专门的专科医生训练, 所以检查效率并不高。

(2) 超声显微镜

眼部超声自 1956 年起逐渐被应用于各类眼科疾病诊断中。眼部超声成像是使用探头将高频率的声波发送至眼睛内部。当声波从眼内组织反射回时将其转换为电信号并以图像的形式重构与显示。该成像方法可以用于对眼部病症的动态评估与病理图像存档。其主要分为 A 型超声扫描和 B 型超声扫描两种模式。20 世纪 90 年代初, 加拿大的 Foster 和 Pavlin 共同研制了眼科超声显微镜(Ultrasound Biomicroscopy, UBM)^[11], 并将其成功地运用于眼科临床研究。

UBM 能够对房角、虹膜、睫状体和眼后节等结构进行成像, 其可以为眼科研究与临床提供常规仪器所不能获得的信息与参数, 但是这个检查是一个耗时的过程。传统的 UBM 成像时首先需要将眼部浸入水浴中, 将放置于巩膜上的眼杯, 或置于角膜上的探头与眼部进行直接接触, 从而将声波传入眼部。该侵入性的操作不仅会使受检查者感到不适, 且会对眼球造成压力引起图像中的伪影, 甚至有可能使受检者角膜擦伤和感染, 而使视觉功能受到损害。因此, 该项成像技术需要检查者具有专业技术及丰富的经验才能获得质量较高的眼部成像。

(3) 磁共振成像

对于青光眼患者不仅表现为视神经纤维层变薄, 多项研究表明, 其视神经甚至视皮质都会发生病变。原因在于青光眼导致的长期高眼压阻碍了轴浆运输, 致使上级神经元发生病变。但是很多“正常眼压性青光眼”临床上有很多患者也会出现此类病变。这是因为此类患者眼压不高, 但是颅内压过低, 导致眼压与颅内压压差过大, 破坏了神经组织, 神经组织一旦压坏就不会再恢复。普通的青光眼检查很难发现这种情况, 但通过磁共振成像检查可发现。目前, 有的医院已经将磁共振成像应用于青光眼患者的检查了, 尤其是检查眼压正常型的青光眼。随着技术的不断成熟与进步, 磁共振成像势必会成为检查青光眼一个很常规的项目。

(4) 光学相干断层成像技术(Optical Coherence Tomography, OCT)

OCT 的工作原理类似于超声波, 只是用光代替声波产生图像。其工作原理是利用近红外弱相干光打到待检测组织表面, 根据光的相干干涉特性, 采用超外差探测技术, 测量反射回

来的光强，从而达到组织浅表层层析成像的目的。OCT 检查操作简便、检查快速、非接触眼球、不需扩瞳、无任何创伤，但是却可以为眼科医生提供分辨率高、类似组织切片的清晰的视网膜断层影像，所以成为深入研究各种眼底疾病的有力武器。尤其通过眼前房角 OCT 图片，可以定性定量分析眼前房角区域各种结构参数，对于青光眼的评估诊断十分有利。

OCT 成像的优点使其在临床诊断与研究中的应用越来越多。与此同时，大量的成像数据随之生成，倘若仅靠医生手工测量相关解剖结构参数，对这些图像进行分析以实现 PACG 的评估与诊断，将会是一个非常耗时耗力的工作，同时该过程受主观因素影响较大。另一方面，由于 OCT 成像质量受噪声或眼动影响较大，易造成前房角内解剖结构细节不明显。而已有的评级方法对于成像质量较差的图像，无法正确地对房角闭合状态做出评估。因此，研究基于图像特征的房角分类算法具有重要的意义。

1.2 国内外研究现状和发展趋势

目前，临床对于青光眼的检查，主要还是依赖于房角镜观测，并根据相关评级方法对房角闭合程度进行评级。关于评级的方法，业界已经提出多种方式。最早期的有 1967 年 Gorin 和 Posne 提出的“宽角、中角、窄角”方法，分类非常简单。后期提出的，也是现在比较常用的一些分级方法有 Scheie^[12]，Shaffer^[13]，和 Spaeth^[14]等分类方法，使用最广泛的是 Shaffer 评级方法。本文实验所需的图片，医生也是依据此方法进行评级的。Shaffer 以角膜-小梁网和虹膜前表面两条假象切线的夹角宽度作为评级标准，其详细标准如表 1.1。

表 1.1 房角 Shaffer 评级方法

分级	房角宽度	描述
0	关闭	关闭
Slit	裂隙	极其狭窄呈裂隙状
1	$\leq 10^\circ$	极其狭窄
2	20°	窄角
3	$35^\circ \sim 20^\circ$	宽角开放
4	$45^\circ \sim 35^\circ$	宽角开放

基于影像的前房角评估目前只作为临床辅助手段，由于技术都还不够成熟，暂时替代不了房角镜直接观测的主导地位。而已取得的通过图像评价房角的方法，尚处于研究阶段，一般是对眼前房角内一些解剖结构参数进行测量，评估房角闭合程度。这些参数包括房角开放距离(AOD)、房角隐窝面积(ARA)、虹膜厚度(IT)和面积(IA)，以及虹膜曲率半径(IC)等(图 1.1)。其中 AOD 的测量一般是以巩膜突(scleral spur)或 Schwalbe 线为解剖标志的。但在 OCT 成像中巩膜突的可辨识度较低，而 Schwalbe 线在频域 OCT 成像明显，始终可见。因此，很多研究选取 Schwalbe 线作为 OCT 图像中测量相关房角参数 AOD 的解剖标志^[15]。




图 1.1 眼前房角组织结构相关参数

(1) 手动测量方法。

通常，房角的评估还是基于手工测量或者半自动测量方式获得，效率明显不高，且主观性强。通过手工操作对解剖结构相关参数测量的研究有，1997 年戴惟葭博士等采用图像处理软件 photoshop 做直线描绘出房角后再直接测量房角度^[16]。Qin 等在 2010 年使用 RTVue OCT 成像软件中自带的标尺功能通过手工选取两个端点以测量得到相应的房角开放距离。

(2) 半自动测量方法。

半自动测量的早期实现得益于 Ishikawa 等研发的 UBM 设备，通过它可获取眼前房角超声图像。然后手工输入巩膜突位置，即可自动检测出相应的前房角角膜和虹膜边缘，进而通过测量 ARA 与 AOD 两个参数以确定患者病情。到 2006 年，一种基于边缘拟合与阈值分割的方法被提出。该方法首先对眼前房角图像进行阈值分割，再提取角膜后边缘与虹膜前边缘并且进行拟合。然后手动输入特征点，通过计算获取相应房角参数。但是根据拟合后的边缘进行参数计算使得该方法存在较大误差^[17]。类似通过半自动方式测量房角参数的研究还有以下一些：Radhakrishnan 等在研究 2007 年 Radhakrishnan 等的研究中也需手动输入角膜前后边缘和虹膜前边缘以及巩膜突地位置^[18]，才能进行 AC 的测量。同样，由中山大学研究的 Zhongshan Angle Assessment Program^[19]和 Li 等^[20]所提出的测量方法也是需手动输入巩膜突位置。而 Cheung 等^[21]在 2010 年提出的方法虽然实现了折射的自动校正，但仍需手动输入巩膜突等标记点才可计算得到相应房角参数。以上这些半自动测量方法在使用时均需人工输入特征点，因此其测量结果仍具有一定的主观性。

(3) 全自动测量方法。

自 Jing 等实现了在高清 OCT 图像中自动测量基于 Schwalbe 线的房角开放距离的方法^[22]，前房角相关解剖结构参数真正进入了自动测量阶段。但方法仍然具有一定的局限性，例如当图像中背景区域位于虹膜下方或角膜上方区域时，该算法无法完成自动测量；另外，在描述 Schwalbe 线时是基于突起点这一特征的，但在很多图像中该突起特征并不明显；最后，此方法并不具有普遍性，因为普通的 OCT 成像图像分辨率低于高清图像，解剖结构的细节也并不

明显，显然无法开展测量。在武薇提出的房角开放距离自动测量方法中，基于高清图像、普适性不强等问题也同样存在^[23]。2012 年 Xu 等^[24]提出了一种利用前房角图像特征信息对前房角开放、闭合状态进行分类，从而实现对原发性开角性与闭角型青光眼的分类。但其是基于高清图像的，对于普通图像依然不适用，而且分析闭合、开放状态在临床中是太粗略的划分，实际意义不大。

由以上可得，现有的各种前房角评估方法都取得了一些成就，但都有各自的局限性。基于手工方法或者半自动方法，效率不够高，又带有主观性。基于自动化测量的技术还不成熟，仅能对高质量样本进行简单划分。因此，如何通过图像处理与分析的方法自动测量相关解剖结构参数，以及对眼前房角闭合程度进行分类与评级，从而更为快速、准确和客观地实现青光眼的计算机自动诊断与评级是一个值得深入研究的问题。

1.3 本文主要工作及创新点

本文研究的主要内容是围绕基于多特征的眼前房角图像分级评估来进行展开。首先，针对眼前房角 OCT 图像特性探究了自动提取感兴趣区域的方法，并在后续图像分类过程中验证了该提取方法的有效性。其次，为了全面描述房角隐窝区域，研究了多种特征提取方法，通过提取 HOG、COHOG、EDGELET 等特征，从多角度对眼前房角区域进行了描述，并结合支持向量机方法对图像进行闭合、开放分类。最后，在闭合、开放两分类的研究基础上尝试了多级分类，对眼前房角状态进行了五级评估。论文具体研究内容包括以下几个方面：

(1) 本文提出了一种基于特征边缘的感兴趣区域自动提取方法。首先，考虑到各类型图像噪声及失真情况后，使用了一种多层级的图像分割算法，为感兴趣区域的精确定位提供了前提。然后，针对眼前房角结构特点，图像中仅存在虹膜、角膜区域，故采取一种基于像素灰度方向连续性的边缘检测算法，简单快速定位虹膜、角膜边缘。最后，通过对边缘进行线性拟合，确定拟合直线相交点，根据相交点定位感兴趣区域。

(2) 由于 AOD、ARA、IA、IT、IC 等解剖结构特征难以全面描述房角隐窝区域信息，本文在现有图像特征基础上，经过分析比对，先采用 HOG 特征对眼前房角区域进行特征提取，同时在参数调优上反复实验以选取最佳参数。然后利用支持向量机方法进行分类，并在训练分类器过程中多次将错分数据加入到训练集中，增强分类器。

(3) 针对 HOG 方法仅使用了单点梯度信息，并未利用到点与点之间像素空间位置关系，本文引入 COHOG 特征来描述眼前房角区域。COHOG 特征中采用了梯度对形式，并且针对原有 COHOG 特征放弃梯度幅值信息的利用问题，提出了一种改进方法，更加全面的利用梯度信息。但是 COHOG 特征方法比较为人诟病的问题是维数过高，致使训练过程较慢且容易发生内存溢出。为此，本文采用 PCA 降维方法，仅对数据主要成分进行分析，数据分析效率大大提高。

(4) 仅对眼前房角状态进行闭合与开放状态只能从大体上区分闭角型青光眼和开角型青光眼，而相对于医生主观评价达到的多级细分的评估精度，想要实现自动诊断需要研究

的内容还有很多。本文尝试结合多个图像特征对眼前房角图像进行多级评定，采用梯度、EDGELET、COHOG 三个特征，分别从点、线、面三个方面全面描述房角隐窝区域，同时构造了多分类支持向量机的方法，实验结果证明，在角度正确、成像清晰以及症状相对明显的高质量图片中，进行多级分类评估能够获得较为理想的效果。

1.4 本文的组织结构

本文的主要结构及各章节内容安排如下：

第一章绪论，首先对本文的研究背景及意义进行了概述，介绍了青光眼及眼科检查手段，阐述了青光眼及眼前房角计算机辅助诊断的国内外研究现状及进展；给出了本文的主要研究内容和创新点；最后列出了论文的组织结构和各章节内容的安排。

第二章对本文图像分类过程进行介绍，并阐述了采用的相关技术及理论基础。主要包括感兴趣区域提取、特征提取方法和支持向量机三个方面相关知识，同时介绍了本文实验所采取的评价指标。

第三章提出基于特征边缘的感兴趣区域提取方法提取房角隐窝区域，采用 HOG 特征进行描述，最后利用支持向量机方法训练分类器并进行两级分类。

第四章采用 COHOG 及改进的 COHOG 方法重新对房角隐窝区域进行特征提取探究了像素点空间位置信息对分类的影响。并且引入了 PCA 方法对数据进行降维。

第五章探究了眼前房角 OCT 图像的多级分类评估课题，采用多特征对房角隐窝区域进行描述，结合多特征融合并构造多分类支持向量机进行分类，在高质量图片中取得了理想结果。

第六章对本文的研究工作进行全面归纳总结，并结合本课题进展及热点对后续的研究内容进行展望。

第 2 章 图像特征提取与图像分类方法

医学图像信息的准确分析对于医生诊断病情具有十分重要的影响。而医学图像的分类则是对于图像信息的分类归纳，是精准读取图像内容的关键环节。医学图像不同于普通图片，一般主要内容点只有一个。例如，癌症患者医学图片主要内容为癌变部位，炎症图片中医生关注点尽在发炎部位，骨折图片中骨头异常区域则是重点关注部位。与普通图像背景与内容点纹理、颜色等变化较大不同，医学图像感兴趣区域隐藏在复杂背景之中，所以需要根据研究内容有针对性的设计感兴趣区域提取方法。另外医学图像由于受成像手段影响，普遍含有大量噪声，计算机进行图像处理前都要进行去噪及增强处理。处理后的图像可通过提取图像特征对图像进行描述，继而通过对特征送入分类器进行最终分类。本文对于青光眼前房角图像分类研究以上述分析为依据，首先提取感兴趣区域，再提取图像特征，最后训练分类器对图像进行分类，思路主流程如图 2.1 所示。在这一章，主要介绍整个流程所涉及内容的研究现状及理论基础。

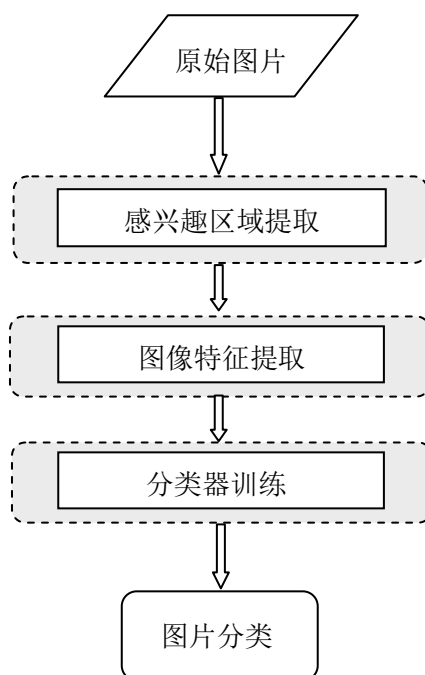


图 2.1 本文图像分类流程

2.1 感兴趣区域提取

2.1.1 感兴趣区域提取研究现状

图像是承载信息的重要手段，其表达信息多元而又使用方便，因而在现实及网络信息传递中占据重要地位。但就一般而言，图像的关键信息大部分集中在少数区域，其余部分则多为冗余信息。感兴趣区域(Regions of Interest, ROI)即为这少数区域，它以尽量小的区域涵盖

了图像最重要的内容，除此以外的部分则称为背景或者非感兴趣区域。感兴趣区域既是图像浏览时关注的焦点，也是图像分析处理时的重点区域。尤其对于机器视觉，对图像提取感兴趣区域进行操作，一方面，可以大幅减少待处理的像素数，降低图像处理复杂度，避免计算浪费；另一方面，还减少了无谓的噪声及失真影响，对提高图像处理效率十分有利。

感兴趣区域提取分析在图像压缩与编码^[25]、图像检索^[26]、目标检测识别^{[27][28]}等领域的突出表现，极大地体现了其研究及应用价值。近年来,国内外研究者对图像感兴趣区域的提取研究成果较为显著。从前期基于交互的和基于变换的提取算法，逐步发展到基于视觉特征的提取算法，现在，用于图像感兴趣区域提取的经典算法已经有多种。其中比较有代表性的图像感兴趣区域的方法有以下几种：

(1) 基于人工交互的 ROI 提取^{[29][30]}。

这种方法以用户为中心，通过用户来选择感兴趣区域，可以准确捕捉用户注意焦点，有简单、灵活的特点。但这种方法比较适于内容单一的图像，同时数据量不能太大。而对于图像内容较丰富及海量图像数据的操作处理显得过于无力。基于自动化操作需求及图像处理的高速度需求，感兴趣区域的提取需要摒弃人工参与，实现自动化。

(2) 基于变换的 ROI 提取方法。

比较常用的有两种：基于拐点的 ROI 提取^{[31][32]}和基于灰度变换的 ROI 提取^[33]。前者将反应图像物体轮廓的拐点作为图像中传递有用信息的感兴趣点，通过对感兴趣点定位进而得到感兴趣区域。但这种方法过于依赖图像纹理的分布，因而应用有限。后者则意在克服前方法的缺点，依据图像中灰度的变化确定感兴趣点，避免感兴趣点集中在图像纹理复杂区域，并且提取效果得到显著提高。但这跟人工观察获取的感兴趣区域还是有相当差距。

(3) 基于人眼视觉注意的感兴趣区域提取方法。

视觉注意机制，是指位于视觉系统上层的观察者所具有的对视觉场景中最相关区域进行选择和处理能力，这是人类视觉的一项重要的心理调节机制。一般认为，物体具有的引起注意的特征有颜色、纹理、亮度、对比度、运动等，人观察图像的过程就是以上多个特征融合的过程。视觉注意模型可分为两大类：自底向上（bottom-up）和自顶向下(top-down)的模型。自底向上的注意模型属于低级、快速的认知过程，是由视觉刺激驱动的感兴趣区域定位过程。其代表性的经典模型有 Itti 模型^[34]、光谱剩余假说模型^[35]、Stentiford 模型^[36]以及 Hu-Rajan-Chia 模型^[37]。自顶向下模型由任务驱动的，研究较少，且多以改进自底向上模型得到。

2.1.2 医学图像感兴趣区域提取

目前比较经典的一些感兴趣区域提取算法对于普通图像普适性较好，但是对于医学图像，提取效果并不能让人满意。普通图片内容与背景一般在颜色、纹理等特征上有较明显差异，而医学图像感兴趣区域一般隐藏在复杂的背景结构当中，另外医学图像由于成像设备及技术的限制，图像一般含有大量噪声、伪影，甚至倾斜、不同图像或者同一图像不同区域亮度差

异较大。所以，根据所研究的图像内容及成像特点针对性的设计感兴趣区域提取方法是必须的。近几年来，一些医学图像的感兴趣区域提取方法被提出，比如：滑动窗口法、阈值分割法、区域生长法、数学形态学方法及分水岭法等等。虽然他们依然不能适用于所有图像，但其算法设计思想比较具有指导意义，我们可在实际研究中稍加改进，以应用于自己的项目当中。下面介绍几种有代表性的算法原理：

(1) 基于区域生长的 ROI 提取。

进行区域生长 ROI 定位之前，需要对图像进行前期处理。采取去噪、分割、腐蚀等操作，增强感兴趣区域对比度，为区域生长操作提供可行环境^[38]。区域生长的基本思想是将具有相似性质的像素集合起来构成区域^[39]。首先选定生长起点，在待分割区域选定一个种子点作为生长起点，比较种子点与周围像素点，符合判定标准的像素点合并到种子点所在的区域中，判定标准为根据事先确定的生长或相似准则。将这些新像素当作新的起点继续上面的过程，直到整个区域内没有像素更新，新区域生长结束。事先给定的判断标准是决定区域生长结果的关键因素，一般需要根据实际情况实验获取。

(2) 基于显著图的 ROI 提取。

基于显著图的 ROI 提取方法将视觉注意机制在感兴趣区域提取方向的应用。其 ROI 提取关键步骤在于显著图的生成，目前较典型的是 Itti 的显著图模型。处理流程可分为两个阶段：

阶段一：采用高斯金字塔对图像进行分解，多尺度提取颜色、亮度、方向特征，并分别计算各特征显著图。

首先对图像进行高斯金字塔处理，可采用线性滤波器进行卷积运算获得新的采样图像，一般计算 0-8 九级图像。尺度为 σ 图像可用公式(2.1)进行表示。

$$I(\sigma+1)=I(\sigma)/2 \quad i=[0,1,\dots,8] \quad (2.1)$$

亮度显著图计算。公式(2.2)为亮度特征计算方法，其中 R、G、B 为图像 3 个颜色通道。

$$I(\sigma)=(R+G+B)/3 \quad (2.2)$$

根据公式(2.3)计算得出亮度特征图，计算时引入了中央-周边差(c-s)计算方法，其中 $s=c+\sigma, c \in \{2,3,4\}, \sigma \in \{3,4\}$ 。

$$I(c,s)=|I(c)\ominus I(s)| \quad (2.3)$$

共得出 6 个亮度特征图，根据公式(2.4)叠加后得亮度显著图，其中 $N(\)$ 采用局部迭代法的合并策略。

$$C_I = \bigoplus_{c=2}^4 \bigoplus_{s=c+3}^{c+4} N(I(c,s)) \quad (2.4)$$

颜色特征图计算。每一级高斯图像分别计算四个颜色通道，(2.5)、(2.6)、(2.7)、(2.8)为计算公式。

$$R'(\sigma)=R-(G+B)/2 \quad (2.5)$$

$$G'(\sigma) = G - (R + B) / 2 \quad (2.6)$$

$$B'(\sigma) = B - (R + G) / 2 \quad (2.7)$$

$$Y(\sigma) = R + G - 2(|R - G| + B) / 2 \quad (2.8)$$

根据颜色抗拒理论及 L.M.Hurvich 的证明, 并采用 c-s 计算方法, 通过公式(2.9)、(2.10)得到颜色特征图。

$$R'G'(c, s) = |(R'(c) - G'(c)) \ominus (G'(s) - R'(s))| \quad (2.9)$$

$$B'Y(c, s) = |(B'(c) - Y(c)) \ominus (Y(s) - B'(s))| \quad (2.10)$$

共得出 12 个颜色特征图, 根据公式(2.11)叠加后得颜色显著图。

$$C_c = \bigoplus_{c=2}^4 \bigoplus_{s=c+3}^{c=4} N(R'G'(c, s) + B'Y(c, s)) \quad (2.11)$$

方向特征图计算。采用 Gabor 方向滤波器, 选择 $\theta \in \{0^\circ, 45^\circ, 90^\circ, 135^\circ\}$, 根据公式(2.12)计算方向信息。

$$O(\sigma, \theta) = \|I(\sigma) * G_0(\theta)\| + \|I(\sigma) * G_{\pi/2}(\theta)\| \quad (2.12)$$

根据 c-s 计算得方向特征图, 如公式(2.13)。

$$O(c, s, \theta) = |O(c, \theta) \ominus O(s, \theta)| \quad (2.13)$$

共得出 24 个方向特征图, 根据公式(2.14)叠加后得方向显著图。

$$C_o = \sum_{\theta \in \{0^\circ, 45^\circ, 90^\circ, 135^\circ\}} N\left(\bigoplus_{c=2}^4 \bigoplus_{s=c+4}^{c=4} N(O(c, s, \theta))\right) \quad (2.14)$$

阶段二: 生成综合显著图。

Itti 模型假设不同特征对显著性贡献完全均等, 则综合显著图取三特征平均值即可, 即:

$$S = \frac{1}{3}(N(C_I) + N(C_c) + N(C_o)) \quad (2.15)$$

显著图得到后, 对图像进行阈值分割、边缘提取、依据显著区域轮廓在原图定位感兴趣区域。

2.2 常用图像特征

在图像的分类研究中, 提取的图像特征用来作为图像分类的依据, 可见图像特征是一种在原始像素值上生成的可以用来最大化表达图像的数据信息。常见的图像特征类型有颜色、纹理、形状及空间关系特征以及边缘、角点、区域、脊等特征。这些类型特征经常单独或综合运用于图像分类。

近年来, 基于梯度与直方图的图像特征受到广泛应用。典型的特征如 SIFT 特征与 HOG 特征。本文即采用了这一类图像特征。所采用的特征各章都有详细说明步骤, 就不一一细说。

2.3 支持向量机基础

目前分类可供选择使用的算法有很多，而且分类效果都能达到不错的水平。比如常用的贝叶斯分类器^[40]、神经网络分类器以及决策树、粗糙集分类方法等。传统的分类方法将经验风险最小化(ERM)原理视为出发点，泛化能力较差。1995 年,Vapnik 等^[41]人提出支持向量机(Support Vector Machine,SVM)，SVM 的提出很好的替代了传统分类器，在实际应用中得到了快速的推广及广泛的好评。SVM 最大的特点在于对于解决高维复杂的非线性系统中样本量较少的分类与预测表现效果优异。支持向量机方法是建立在统计学习理论的 VC 维理论和结构风险最小化原理基础上的。现在,SVM 以其优越的性能的在模式识别中的应用相当广泛。SVM 在人脸检测应用方向、语音识别应用方向及手写字体识别应用方向等都有不错的表现。另外在生物医学信息处理以及数据挖掘等领域应用效果也相当出色。

支持向量机基本思想是首先通过非线性变换将输入空间变换到一个高维空间，然后在高维空间寻找最优分类面以解决分类问题。

2.3.1 线性可分

设线性可分样本集为 $(x_i, y_i), i = 1, \dots, n, x \in R^d, y \in \{+1, -1\}$ 是类别标签。 d 维空间中线性判别函数及分类线方程分别为 $g(x) = w \cdot x + b$ 、 $w \cdot x + b = 0$ 。将判别函数进行归一化，使两类所有样本都满足 $|g(x)| = 1$ ，也就是使离分类面最近的样本的 $|g(x)| = 1$ ，此时分类间隔等于 $2/\|w\|$ ，因此使间隔最大等价于使 $\|w\|$ (或 $\|w\|^2$) 最小。使样本正确分类的分类线需满足

$$y_i[(w \cdot x) + b] - 1 \geq 0, i = 1, 2, \dots, n \quad (2.16)$$

满足上述条件(2.16)，并且使 $\|w\|^2$ 最小的分类面就叫做最优分类面。

利用 Lagrange 优化问题，即：在约束条件^[42]，

$$\sum_{i=1}^n y_i \alpha_i = 0, \alpha_i \geq 0, i = 1, 2, \dots, n \quad (2.17)$$

下面对 α_i 求解下列函数的最大值：

$$Q(\alpha) = \sum_{i=1}^n \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) \quad (2.18)$$

若 α^* 为最优解，则

$$w^* = \sum_{i=1}^n \alpha^* y_i \alpha_i \quad (2.19)$$

求解转化后的二次函数极值问题，最优分类函数为：

$$f(x) = \text{sgn}\{(w^* \cdot x) + b\} = \text{sgn}\left\{\sum_{i=1}^n \alpha_i^* y_i (x_i \cdot x) + b^*\right\} \quad (2.20)$$

2.3.2 线性不可分

线性可分的情况下提出的最优分类面，在线性不可分时，就是某些训练样本不能满足式(2.16)的条件，因此可以在条件中增加一个松弛项参数 $\varepsilon_i \geq 0$ ，变成：

$$y_i[(w \cdot x_i)] - 1 + \varepsilon_i \geq 0, i = 1, 2, \dots, n \quad (2.21)$$

对于足够小的 $s > 0$ ，只要使

$$F_\sigma(\varepsilon) = \sum_{i=1}^n \varepsilon_i^\sigma \quad (2.22)$$

最小就可以使错分样本数最小。对应线性可分情况下的使分类间隔最大，在线性不可分情况下可引入约束：

$$\|w\|^2 \leq c_k \quad (2.23)$$

在约束条件(2.21)、(2.23)下对式(2.22)求极小，就得到了线性不可分情况下的最优分类面，称作广义最优分类面。为方便计算，取 $s=1$ 。

为使计算进一步简化，广义最优分类面问题可以进一步演化成在条件(2.11)的约束条件下求下列函数的极小值：

$$\phi(w, \varepsilon) = \frac{1}{2}(w, w) + C \left(\sum_{i=1}^n \varepsilon_i \right) \quad (2.24)$$

求解这一优化问题的方法与求解最优分类面时的方法相同，都是转化为一个二次函数极值问题，其结果与可分情况下得到的(2.16)到(2.19)几乎完全相同，但是条件(2.17)变为：

$$\sum_{i=1}^n y_i \alpha_i = 0, 0 \leq \alpha_i \leq C, i = 1, 2, \dots, n \quad (2.25)$$

当样本集线性不可分时，可以通过非线性变换转换到高维空间，寻求最优分类面。而这种方法的实现可以转换成仅使用空间中的点积来完成。那么，寻找函数 K 使得

$$K(x_i \cdot x_j) = \phi(x_i) \cdot \phi(x_j) \quad (2.26)$$

采用适当的内积函数 $K(x_i \cdot x_j)$ 将非线性问题转化为线性问题。目标函数变为：

$$Q(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j K(x_i \cdot x_j) \quad (2.27)$$

最终得分类函数为

$$f(x) = \text{sgn} \left\{ \sum_{i=1}^n \alpha_i^* y_i K(x_i \cdot x_j) + b^* \right\} \quad (2.28)$$

2.4 分类评价指标

为了验证本文各方法对眼前房角图像的分级效果，采用混淆矩阵与总体分类正确率作为评价指标，对眼前房角闭合、开放分类以及 0-1 五级分类结果进行评价。

(1) 混淆矩阵:

表 2.1 混淆矩阵分类方法

		Predicted	
		Negative	Positive
Actual	Negative	a	b
	Positive	c	d

混淆矩阵中详细统计了每一类测试样本的正确分类和错误分类。表示形式如表 2.1。第一行表示正测试样本的分类结果，a 为正确分类统计，b 为错误分类统计，同理，第二行 c 与 d 分别表示负测试样本被划分为正测试样本与负测试样本的结果统计。统计结果可用样本数和百分比两种形式表示。

(2) 分类正确率:

$$Accuracy = \frac{a + d}{a + b + c + d} \quad (2.29)$$

计算形式如式(2.29),分类正确率等于正确分类的测试样本数除以总样本数,正确分类的测试样本总数为各类测试样本正确分类数总合,即表 2.1 中分布在混淆矩阵对角线上的数值总合。样本总数表示所有测试集样本的数量。

2.5 小结

本章主要介绍了本文图像分类涉及的各个模块所采用的相关技术,以及各技术的研究现状和理论基础。三个模块分别为感兴趣区域提取、图像特征提取和训练分类器及图像分类。

(1)感兴趣区域提取。本文的研究对象是眼前房角 OCT 图像,医学图像的感兴趣区域提取与普通图像有很大不同,大部分的常用图像感兴趣区域提取算法并不适用于医学图像,故对特定医学图像提出针对性的感兴趣区域提取算法是现在医学图像处理领域常用的方法。(2)图像特征提取。现有的常用图像特征各有优缺点,本文在考虑了眼前房角结构特征及成像特征之后,选取在行人检测领域使用效果较好的 HOG、COHOG、EDGE LET 特征作为本文图像分类的特征描述方法。(3)支持向量机。分类器的选取对于分类结果影响重大,支持向量机作为近 20 年最受欢迎的分类器,具有支持小样本、泛化能力强、鲁棒性好等突出优点,自然也是本文分类器的首选。最后,介绍了本文用于评价实验结果的分类评价指标,混淆矩阵和分类正确率。

第 3 章 基于感兴趣区域及 HOG 特征的眼前房角分级评估

青光眼的图像研究一直以来都是围绕解剖结构参数的测量来进行，常用的解剖结构参数有 AOD、ARA、IA、IT、IC 等。初期手动测量结构参数，完全凭借医生的主观认知进行操作。后来在手工标记巩膜突、虹膜隐窝最深点或角膜前后边缘等特征点的基础上，可借助计算机进行半自动参数测量。最近三年刚实现的基于 Schwalbe 线的自动测量房角开放距离的方法，虽然完全没有手工辅助操作，彻底实现了计算机自动测量，但是结合临床观测可知，仅靠 1-2 个医学解剖特征描述青光眼患者眼前房角闭合程度是远远不够的。引入高维视觉特征是未来可尝试的方向，本章利用近些年比较成功的图像特征和分类器进行分类方面研究。

基于感兴趣区域及 HOG 特征的图像分级评估过程结构图如下：

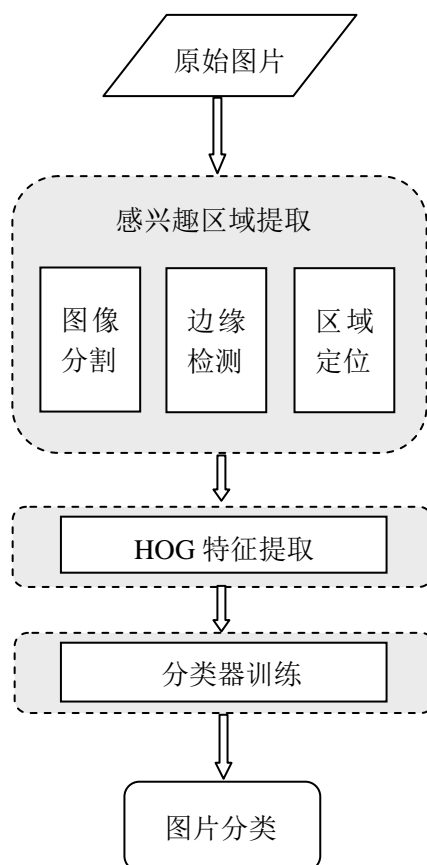


图 3.1 利用 HOG 特征分类流程图

3.1 眼前房角 OCT 图像特点

OCT 图像成像较其他手段的成像技术在清晰度上有较高层次的提升。眼前房角 OCT 图像优点较为突出，其成像分辨率及解剖结构细节都较清晰，图像对于细微组织结构的展现较

为全面。但是其缺点同样明显，受成像设备及相干成像原理限制，眼前房角 OCT 图像中含有大量噪声，降低了图像清晰度，这些噪声包括热噪声、光子散粒噪声及占主导作用的斑点噪声。图 3.2(a)、(b)分别为清晰图像与含斑点噪声图像。除此之外，成像过程中的扰动也会对图像质量造成干扰。图 3.2 包含了常见的受干扰的图像，图 3.2(c)夹角部分图像信息丢失；图 3.2(d)形成了伪影区域；图 3.2(e)存在低对比度区域；图 3.2(f)中白色部分为反射光带。




图 3.2 眼前房角 OCT 图像成像特点

3.2 眼前房角图像 ROI 提取

感兴趣区域提取是医学图像处理中的重点，感兴趣区域的精确定位对于特征提取及分类结果有直接影响。眼前房角 OCT 影像中的感兴趣区域就是眼前房角的隐窝区域，具体为眼前房角角膜与虹膜夹角区域。

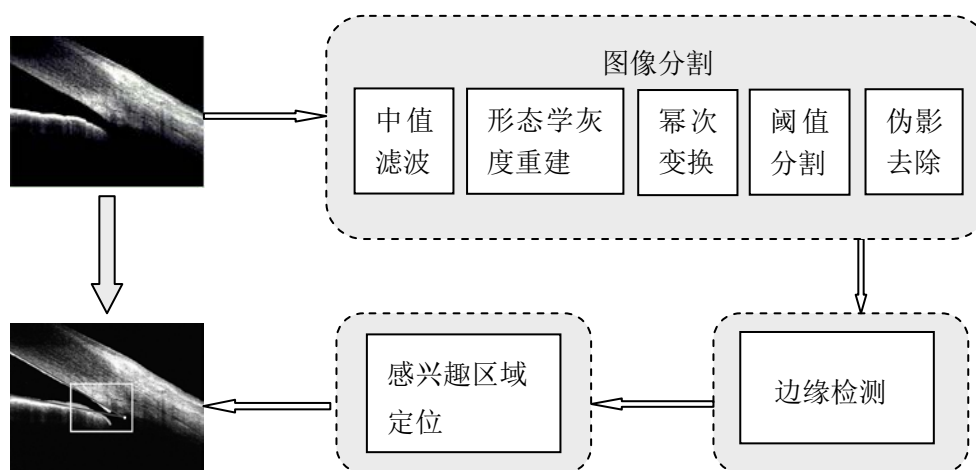


图 3.3 感兴趣区域提取过程

考虑到前房角 OCT 原始图像中所存在的斑点噪声，阴影遮挡、伪影，低对比度区域等问题。基于对眼前房角结构特征和成像特征考虑，本研究提出了一种基于特征边缘的感兴趣区

域自动提取算法。另外，为了准确定位眼前房角隐窝区域，本文对图像分割与边缘检测也做了相应研究，根据虹膜与角膜的成像情况，采用了一种基于形态学灰度重建增强的图像分割方法和基于像素灰度方向连续性的边缘检测方法。在感兴趣区域提取之前先对图像进行灰度变换以及对房角开角向右的图像先进行镜像变换。感兴趣区域提取过程如图 3.3。

3.2.1 图像分割过程分析

(1) 中值滤波去噪。

利用中值滤波去噪的基本原理，一般图像中噪声区域灰度值异于周围像素灰度值，或高或低，而取当前像素点周围固定区域像素灰度值的中间值替代当前像素灰度值，可以很好地忽略斑点噪声，从而达到去噪的目的。去噪步骤为固定大小的滑动窗口作为滤波模板逐个扫描图像像素点，对模板中像素灰度值进行排序，将中间值赋给模板中心所在的像素点。经多组实验对比验证，采用 7×3 大小的模板去噪效果最佳，图 3.4 为中值滤波效果图。




图 3.4 中值滤波效果图

(2) 形态学灰度重建。

进行形态学灰度重建的主要目的在于提亮图像中虹膜与角膜的暗区域部分，使角膜、虹膜部分灰度值差异减小，显得区域更加完整。效果图 3.5(b)即是最终得到的形态学灰度重建图。




图 3.5 形态学灰度重建效果图

形态学灰度重建主要操作流程可分三步：

- 确定初始重建图像 I_0 ，方法为将不是边界的像素点灰度值置为原图 I 中灰度值的最大值。


- b) 确定中间图像 $Temp$ 。 $Temp$ 图像中像素点的灰度值为对应 I_0 图像中该位置像素点 4 邻域的最小值。
- c) 更新重建图像 I_0 。将图像 I_0 与 $Temp$ 逐个像素点比较，取较大值作为图像 I_0 中该像素点的值。重复进行步骤 b、c，当图像 I_0 中像素值停止更新时终止。即可获得最终形态学灰度变换后图像。

(3) 幂次变换。

对眼前房角 OCT 图像进行幂次变换的主要目的则是区分背景区域与虹膜、角膜区域，增大两区域对比度从而为阈值分割创造良好前提。幂次变换基本形式如公式(3.1)， I 为输入图像， I_m 为幂次变换后图像， c 与 γ 为正常数，当 $\gamma < 1$ 时扩展低灰度级，压缩高灰度级，使图像变亮。当 $\gamma > 1$ 时扩展高灰度级，压缩低灰度级，使图像变暗。

$$I_m = cI^\gamma \quad (3.1)$$

本文所采用的图像各区域亮度差异较大，所以取 $\gamma < 1$ ，均衡整体亮度，同时基于虹膜、角膜区域与背景区域灰度值有一定区分度，可对幂次变换的输入图像做灰度值限制，仅对高于固定值 h 的像素进行处理。本文幂次变换图像为图 3.6。




(a)形态学灰度重建后图像

(b)幂次变换后图像

图 3.6 幂次变换效果图

(4) 阈值分割。



(a)幂次变换后图像

(b)阈值分割后图像

图 3.7 阈值分割效果图

经过以上多步处理后，前房角 OCT 成像图像中完整的房角区域已经形成，且灰白色虹膜、角膜区域与几近纯黑的背景反差极大，对比度显著提升。接下来进行分割操作，我们采用 Otsu

算法, 该算法利用图像中的灰度直方图进行计算, 根据虹膜、角膜区域和背景区域之间的方差最大值自动确定阈值, 进行分割操作。分割图像如图3.7。

(5) 伪影去除及房角填充。

伪影在图像中没有确定的位置, 但是一般来说面积不会太大, 同时还有一些面积较小的颗粒状噪声, 可以采用统一方法进行去除, 本文采用比较面积大小的方法。该方法对图像进行连通区域提取, 并且分别标记, 同时对不同标记的连通区域进行面积计算, 当连通区域面积小于设定的阈值 A_h , 即当做噪声将其去除。本文根据大量实验得出 $A_h=1200$ 大小时效果最好。伪影去除后如图3.8(a)。

另外, 由于兼顾角膜、虹膜重点区域的完整, 在对图像进行幂次变换时会造成分割区域的部分次要区域缺失, 常见的情况为角膜出现空洞, 如图 3.8(a)左上方。基于边缘检测需要, 对图像进行填充操作。在填充时, 将(a)图中的前两行置为 1, 通过观察前房角 OCT 图像, 在前两列中选取适宜的最大纵坐标, 将前两列中小于最大纵坐标的区域都置为 1, 空洞区域完全连通, 对其填充, 最后恢复前两列及前两行原值。房角填充效果图如图 3.8(b)。




图 3.8 伪影去除效果图


3.2.2 边缘检测过程分析

为了定位房角隐窝区域, 需要检测出房角角膜后边缘与虹膜前边缘。我们采用基于像素灰度方向连续性的边缘检测算法, 此处将边缘定义为图像垂直方向上连续的 k 个取值为 0 的像素和连续的 k 个取值为 1 的像素之间的分界线^[23]。

具体检测步骤如下:

- (1) 从分割后图像顶端到底部逐行扫描, 检测得到第一条连续 k 个 0 紧连 k 个 1 的像素分界线即为角膜前边缘(图3.9(a)、(b)中位于上方的边缘)。
- (2) 从图像底部向上至第一条边缘逐行扫描检测得到的第一条连续 k 个 1 紧连 k 个 0 的像素分界线即为虹膜前边缘。

(3) 在图像中从虹膜前边缘向上至角膜前边缘边缘逐行扫描，即可检测得到角膜后边缘



(图3.9(a)、(b)中位于下方的边缘)。在检测过程中有可能出现如图3.9(a)所示的情况，所以我们限定角膜下边缘检测的时候只检测到虹膜上边缘最右侧像素点横坐标处。

(a)初始边缘检测结果

(b)改进后边缘检测结果

图 3.9 边缘检测结果

3.2.3 感兴趣区域提取过程分析

对边缘检测得到的角膜后边缘和虹膜前边缘分别进行直线拟合，拟合后的线段如图 3.10 所示，边缘部分两条粉色实线即为拟合直线。求得两条拟合直线的交点 (x,y) (图 3.10 中红色圆点)，取 $[x-a, y-b, w_e, h_e]$ 的区域作为感兴趣区域 $G(i, j)$ ，其中 $(x-a, y-b)$ 为感兴趣区域左上角坐标， (w_e, h_e) 为感兴趣区域宽度和高度，后续工作只在此区域展开。




图 3.10 感兴趣区域提取

3.3 HOG 特征提取




图 3.11 HOG 特征值计算步骤

本文进行 HOG 特征计算的步骤:

首先计算感兴趣区域,即房角隐窝区域内各像素点的梯度值并对梯度方向进行量化,再对房角隐窝区域进行细胞单元(Cell)和块单元(Block)划分以及 Cell、Block 内梯度方向直方图统计,最后对整个房角隐窝区域的直方图进行连接得到高维 HOG 特征值。其计算流程图如图 3.11 所示。其具体步骤如下:

(1) 计算梯度。

采用一阶算子 $[-1,0,1]$ 计算感兴趣区域像素点梯度值,像素点 (x,y) 水平与垂直梯度计算如式(3.2)、(3.3):

$$F_x(x, y) = I(x+1, y) - I(x-1, y) \quad (3.2)$$

$$F_y(x, y) = I(x, y+1) - I(x, y-1) \quad (3.3)$$

像素点 (x,y) 梯度值计算如式(3.4):

$$F(x, y) = \sqrt{F_x(x, y)^2 + F_y(x, y)^2} \quad (3.4)$$

像素点 (x,y) 梯度方向计算如式(3.5):

$$\theta(x, y) = \tan^{-1} \left(\frac{F_y(x, y)}{F_x(x, y)} \right) \quad (3.5)$$

(2) 梯度方向量化。




图 3.12 梯度方向量化图

由梯度计算公式(3.5)知像素点梯度方向为区间 $[-90^\circ, 90^\circ]$ 内的取值。方向量化即把 180° 范围内按照方向量化图的角度平均划分为 9 个区间, 构成 9 个量化方向, 分别以 0-8 这 6 个数字表示。每一个像素点都按照此方式进行量化。

(3) Cell内直方图统计。

感兴趣区域内像素数为 $m*n$, 按照固定的大小划分为细胞单元(Cell), 将Cell大小表示为 $cellsize*cellsize$, 则每个感兴趣区域共有 $(m/cellsize)*(n/cellsize)$ 个Cell。部分感兴趣区域内Cell划分如图7所示, 其中一个蓝色小格为一个Cell。在每一个Cell内分别构建梯度方向直方图, 其方法为: Cell内的每一个像素点都来给量化方向进行加权投票, 加权值采用梯度幅值大小, 0-8的9个方向上分别统计最终票数, 即可生成一个9维向量。

(4) Block内直方图统计及归一化梯度方向直方图。

把各个细胞单元组合成大的、空间上连通的区间(Block)。每 $nblock*nblock$ 个cell组成一个Block, 一个Block内所有Cell的特征拼接组合, 这样就可统计出一个Block内的原始HOG特征, 其特征维数为 $nblock \times nblock \times 9$ 。另外, 我们Block的划分如图3.13所示, 蓝色和红色方框表示相邻两个Block, 这两个Block是互有重叠的, 红色为相邻的前一个Block, 黄色为相邻的后一个Block, 它与红色的有两个Cell的重叠。 $blocksize$ 的取值减去重叠区域的大小我们称之为步长, 步长大小一般采用 $blocksize$ 取值的一半大小。Block的重叠意味着: 同一个Cell的特征会被使用多次, 且在每个Block出现时由于归一化计算将会被重新定值。




图 3.13 Cell 和 Block 的划分

对同一Block内的HOG特征值进行归一化处理, 本文采用L2-norm的归一化方法, 同时加一个极小的小数以避免出现分母为零的情况。归一化能够进一步的对光照、阴影和边缘进行压缩。由Cell与Block的划分知道, 每个Cell由多个不同的Block共享, 因此, 最后的特征中会统计多次一个Cell的特征。

(5) 感兴趣区域内直方图连接

将感兴趣区域的所有Block的HOG特征值串在一起构成眼前房角隐窝区域特征向量。

3.4 评估过程及结果分析

本次实验采用的图像数据集为来自 15 个人的 180 幅眼前房角 OCT 图像, 图像格式均为 JPG 格式。数据集中包括眼前房角闭合、开放两种分类类别, 并且实验前所有图片均由医生

进行主观分类评定，其中眼前房角闭合状态的图片 85 幅，开放状态的图片 98 幅。实验环境为 windows 7 系统，用 MATLAB R2014a 编程实现。

3.4.1 特征提取参数选择实验分析

考虑到特征提取过程中 Cell 和 Block 的取值即(*cellsize* 和 *blocksize* 的大小)将影响到特征值的提取及后续的分类，故采取以下实验手段寻求最佳参数值的大小。首先将随机选取数据集中 80% 图片作为训练样本，共 144 幅图片，为了保持两类样本的均衡，选取眼前房角闭合与开放图片各 72 幅；数据集中剩下的 20% 图片作为测试集，共 36 幅，包括眼前房角闭合图片 13 幅和开放图片 23 幅。然后，选取两个参数 *cellsize* 与 *blocksize* 的多种值进行配对实验。每次确定参数取值后提取所有图片的 HOG 特征，并且按照上述比例分配训练集和测试集，训练得到支持向量机分类模型，并用来对测试集图片进行分类。

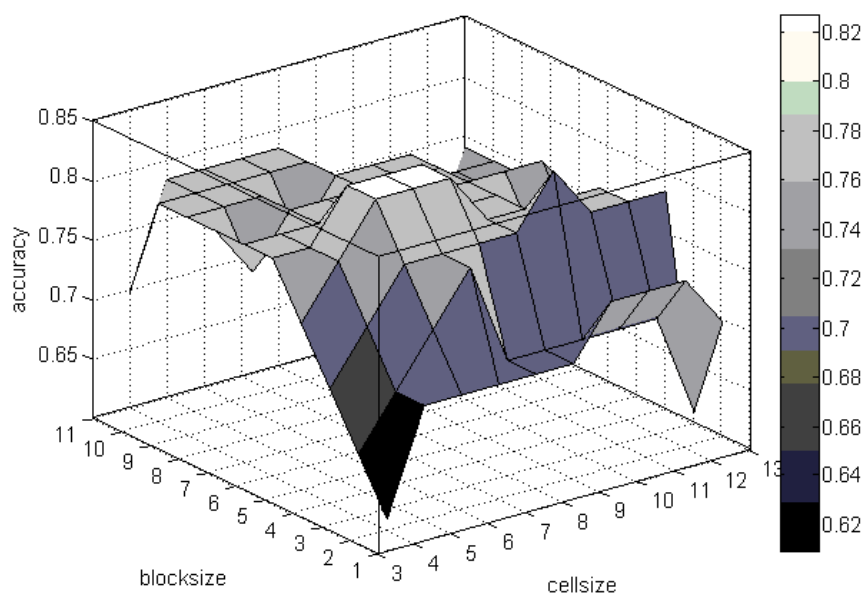


图 3.14 Cell 和 Block 不同大小时分类正确率

表 3.1 10 组实验中最优参数统计结果

	cellsize 取值			blocksize 取值	
	6	7	8	5	6
各取值选为最优参数次数	7 次	9 次	10 次	10 次	8 次

初步选取参数值，*cellsize* 取值范围设为[4,40]，*blocksize* 取值范围设为[2,16]。实验过程中发现，两个参数过大、过小的取值都将使分类正确率降到很低，仅在 *cellsize*、*blocksize* 取值范围为[5,13]、[4,11]时分类正确率保证在 70% 以上。图 3.12 展示了 *cellsize* 和 *blocksize* 在分类最优情况时的取值，很明显，在 *cellsize* 取值为 6、7、8 和 *blocksize* 取值为 5、6 时，分

类正确率最高，达到 83.3%。而选择其他参数时，分类结果明显下降。

为了进一步精确选择参数，在整个数据集中按照前述比例随机抽取训练样本和测试样本，随机进行 10 组实验，统计每组实验最优参数。由表 3.1 可得出， $cellsize=8$ ， $blocksize=5$ ，在 10 组实验中得票率最高，故我们选取这一组参数作为继续实验的固定参数。

3.4.2 分级评估及结果分析

为了验证我们的算法分类最终的效果，同样按照前述比例选取训练集和测试集，随机选取 20 组，进行训练、测试，统计每一组分类正确率，如图 3.13。由结果可得，20 组分类正确率相对稳定，分类效果也不错。最高一组正确率达到了 88.9%，最低的一组为 75.0%，大部分集中在 83.3% 和 80.6% 两个数值，平均正确率为 81.8%。




图 3.15 20 组测试集分类正确率

选取其中第 5 组与第 17 组，详细分析其分类情况，由表 3.2 可见，HOG 对第 5 组图片的两个类别的分类正确率分别为 76.9% 与 82.6%，都达到了较高的准确率，而总体分类正确率也达到 80.6%，第 17 组分类情况也较好。可见，利用 HOG 特征描述感兴趣区域，再进行分类，在总体训练样本并不高的情况下取得了较好的分类效果。

表 3.2 第 5 组、第 17 组测试样本分类结果

		第5组分类结果		第17组分类结果	
		闭合	开放	闭合	开放
实际类别	闭合	10	3	11	2
	开放	4	19	5	18

3.5 小结

本章首先对眼前房角 OCT 图像进行了感兴趣区域提取，在结合成像特点与眼前房角解剖结构特征的基础上，依据现实需求提出了基于特征边缘的感兴趣区域自动提取方法。算法先是利用中值滤波、形态学灰度重建、幂次变换、阈值分割等方法对图像进行分割处理，分割出房角隐窝区域；再利用灰度方向连续性的边缘检测算法检测出虹膜、角膜边缘，以边缘拟合直线的交点为基准点划定感兴趣区域。细致的操作步骤保证了感兴趣区域的精准定位。在

提取感兴趣区域之后，利用 HOG 特征对感兴趣区域进行描述，选取优良分类样本进行分类器训练，最终进行图像分类。同时探究了提取 HOG 特征时不同参数选取对分类结果的影响。在最优参数情况下的实验结果表明，两类样本分类正确率均较高，利用感兴趣区域结合 HOG 特征进行眼前房角 OCT 图像分类效果优良。

第 4 章 基于 COHOG 及其改进方法的眼前房角分级评估

考虑到 HOG 进行特征提取，仅使用了单个像素点的梯度幅值、方向，并未对具体像素点间的空间关系进行考虑，而空间关系的引入可以更加有效地描述边缘信息及纹理信息。目前 watanabe 提出的 COHOG 特征^[43]巧妙地运用了梯度对这一描述形式，使两像素点之间空间关系在梯度直方图中得以体现。不过 COHOG 在实际应用中也有一定的局限性，其一，它放弃了像素点梯度幅值的应用，只考虑像素点梯度方向及其空间关系的应用，从而忽略了图像本身的大量信息^{[44][45]}；其二，梯度对的引入让原本维数就不低的特征数据更加庞大，超高维数极易引起维数灾难，计算过慢和内存溢出问题都将使 COHOG 特征的应用受到极大限制。在此基础上，我们又采用了两点改进方法，第一，对梯度对直方图统计过程加入幅值的计算，以更全面的利用图像信息。第二，采用 PCA 降维方法，降低计算的数据量，提高计算效率。另外，本章及下一章各种特征的提取依然都是在感兴趣区域上进行，感兴趣区域提取采用与上一章相同方法进行，将不再赘述。

本章图像分级过程结构图如下：

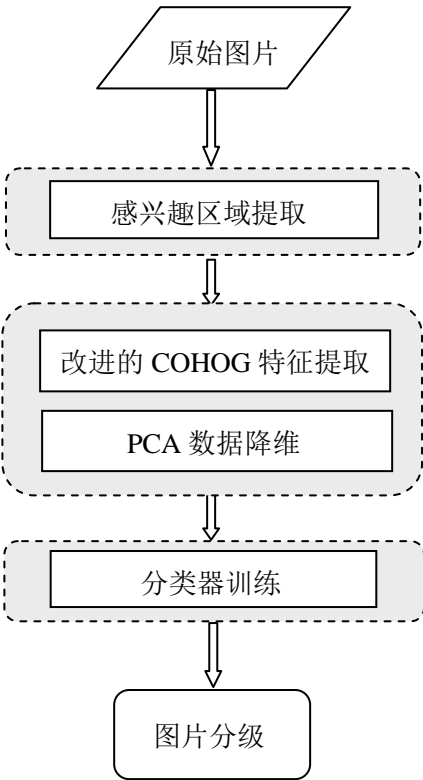


图 4.1 利用 COHOG 特征分类流程图

4.1 COHOG 方法介绍

COHOG(Co-Occurrence Histograms of Oriented Gradients)方法是对 HOG 方法的继承与改进，对梯度方向与空间关系的利用更加全面，它统计的是模块中每一种梯度对的个数。梯度对的概念如图 4.2。图 4.2(a)为单个梯度，8 个方向是量化后的方向表示值。与之前统计 HOG 特征时相同的是，梯度方向直方图统计前需将梯度方向进行量化，所不同的是，COHOG 是将 360° 内的角度按照 45° 进行量化，如图 4.3，最终量化为 8 个方向，分别用 0-7 表示。不考虑两个像素点的位置偏移关系，梯度对形式有 $8 \times 8 = 64$ 种。图 4.2(b)为在不同偏移位置下将两个方向的梯度组成一个组合，即构成一个梯度对。偏移关系是指构成梯度对的两个像素点的空间偏移位置，以偏移坐标表示。COHOG 采用的偏移位置关系为一个像素点与以其为中心、半径为 4 的圆内的所有像素点的构成的位置偏移关系。抛弃重复计算，每个点与周围及其本身共 31 个点组成 31 种偏移位置关系，如图 4.4 所示。




图 4.2 不同偏移位置关系下梯度对组合




图 4.3 梯度方向量化图




图 4.4 COHOG 矩阵的偏移关系图。

(白色为当前像素点，灰色为其计算 COHOG 时所参考的偏移坐标位置)

COHOG 详细计算方法如下：

- (1) 计算梯度，使用 sobel 算子进行计算。
- (2) 梯度方向量化。将梯度方向按 45° 进行量化，可以得到 8 个角度，分别用 0-7 表示。
- (3) 将图像的感兴趣区域分割为多个互不重叠的边长为 $N \times M$ 的子区域 Block。
- (4) 在每一个子区域 Block 内根据公式(4.1)计算 COHOG 特征值 C 。其中， (p, q) 为子区域 Block 内的像素坐标， (i, j) 为共生矩阵 C 的坐标， i 和 j 取值分别为 8 个角度 0,1,...,7， (x, y) 为像素点 (p, q) 的偏移坐标，其取值范围如图 4.3 中灰色圆圈所示位置。

$$C(x, y, i, j) = \sum_{p=1}^N \sum_{q=1}^M \begin{cases} 1, & \text{if } G(p, q) = i \text{ and } G(p+x, q+y) = j \\ 0, & \text{otherwise.} \end{cases} \quad (4.1)$$

- (5) 将每个子区域的共生矩阵 C 串接构成感兴趣区域的 COHOG 特征向量。

4.2 改进的 COHOG 方法

COHOG 特征利用对梯度对概念的引进更加充分的利用了像素点与其周围点的相对信息，更好地反映了图像的局部信息与全局信息。但是相对于 SIFT、HOG 等特征对幅值信息的充分利用，COHOG 对梯度幅值信息的丢弃也是很大的缺陷。为此，我们采用一种对 COHOG 的改进的方法，利用余弦定理计算一个梯度对的加权值^[43]，使特征同时兼顾方向信息与幅值信息。

对于一个梯度对，为了充分利用其幅值与角度信息，根据余弦定理形式计算加权值。计算公式如(4.2)，其中 $F(p, q)$ ， $F(p+x, q+y)$ 分别为梯度对中两像素点的梯度幅值， θ_w 为两像素点的梯度方向差值，计算如公式 (4.3)。

$$w_F = \sqrt{F(p, q)^2 + F(p+x, q+y)^2 - 2F(p, q)F(p+x, q+y) \times \cos(\theta_w)} \quad (4.2)$$

$$\theta_w = \theta(p, q) - \theta(p+x, q+y) \quad (4.3)$$

加入了加权值运算的 COHOG 特征计算公式变为公式 (4.4) 形式。

$$C(x, y, i, j) = \sum_{p=1}^N \sum_{q=1}^M \begin{cases} w_F, & \text{if } G(p, q) = i \text{ and } G(p+x, q+y) = j \\ 0, & \text{otherwise.} \end{cases} \quad (4.4)$$

4.3 PCA 降维方法

采用梯度对结合幅值作为加权值的方式描述图像,可以尽量全面的提取图像的主要特征。但是这样做最大的缺点就是,数据维数超高,对于分类器的训练及后续分类都十分不利。为了降低后续计算的复杂度,我们采用一种通用的降维工具,主成分分析方法(Principal Component Analysis, PCA)对数据进行降维^{[46][47]}。PCA 方法使复杂数据去除冗余与噪声,剩下最有效的关键数据,这些关键数据足以替代原始复杂数据进行后续实验分析,以此达到数据降维的目的。具体方法如下:

将所有图像 COHOG 特征构成输入矩阵:

$$Y = (c_1, c_2, \dots, c_N)^T \quad (4.5)$$

计算主成分矩阵 Y 的平均向量:

$$\psi = \frac{1}{N-1} \sum_{i=1}^N y_i \quad (4.6)$$

计算差值向量:

$$d_i = y_i - \psi, i = 1, 2, \dots, N \quad (4.7)$$

构建协方差矩阵:

$$G = \frac{1}{N} \sum_{i=1}^N d_i d_i^T, i = 1, 2, \dots, N \quad (4.8)$$

假设协方差矩阵为:

$$G = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \vdots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nn} \end{pmatrix} \quad (4.9)$$

对上述矩阵中元素进行标准化处理,标准化后的矩阵记为 G^* :

$$G_{ij}^* = \frac{g_{ij} - \bar{g}_j}{\sqrt{\text{var}(x_j)}} (i, j = 1, 2, \dots, n) \quad (4.10)$$

其中 $\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$, $\text{var}(x_j) = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$ 。

计算相关系数矩阵 R 中的元素:

$$r_{ij} = \frac{1}{n-1} \sum_{i=1}^n x_{ii}^* x_{ij}^* \quad (i, j = 1, 2, \dots, n) \quad (4.11)$$

R 的特征值 $(\lambda_1, \lambda_2, \dots, \lambda_n)$ 和特征向量 $\partial_i = (\partial_{i1}, \partial_{i2}, \dots, \partial_{in})$ 根据 Jacobi 方法求得, $i = 1, 2, \dots, n$ 。把特征值按照升序排列, 并根据式(19)计算主成分的贡献率 roc :

$$roc = \frac{\lambda_i}{\sum_{i=1}^n \lambda_i} \quad (4.12)$$

根据贡献率确定主成分的价值, 本文中选取累积贡献率达到 90% 时的主成分个数 k , 将标准化后的矩阵 x^* 代入前 k 个主成分表达式, 计算得输出矩阵将由 n 维变换到 k 维, 降维后的数据计算量大幅下降, 有利于后续实验开展。

4.4 评估过程及结果分析

为了方便进行分类结果的比较, 我们依然采用与上一章相同的数据集, 在相同的训练集与测试集下进行分类实验。

4.4.1 特征提取参数选择过程及结果分析

COHOG 特征提取过程中子区域的划分对特征中有效信息量有较大影响, 分类结果也会因此有较大的变化。那么寻求最佳参数值的大小在本次试验中也是第一优先级的。依然随机选取数据集中 80% 图片作为训练样本, 眼前房角闭合与开放图片各 72 幅; 数据集中剩下的 20% 图片作为测试集, 共 36 幅, 包括眼前房角闭合图片 13 幅和开放图片 23 幅。然后, 选取参数 $Msize$ 与 $Nsize$ 的多组数值进行实验。




图 4.5 $Msize$ 与 $Nsize$ 不同大小时分类正确率

实验结果如图 4.5, 子区域取不同边长时提取的特征分类结果差别较大, 当 $Msize=50$, $Nsize=50$ 时, 能够得到最好的分类效果。所以我们的子区域边长使用 50×50 的大小。

4.4.2 分级评估及结果分析

依然采用与HOG方法相同的数据集，把180幅眼前房角图片按照3:1的比例选取训练集与测试集，进行20组实验，测试COHOG方法的分类效果。为了与之前方法进行比较，我们采用利用HOG特征分类时的训练样本与20组测试样本。利用COHOG特征分类的实验结果如表4.1，分类结果显示，有11组分类正确率较高，达到了达到86.1%以上，另外有6组因高出仅一个错分数据而导致分类正确率下降到83.3%，但是也高于利用HOG分类81.8%的平均值。

表 4.1 20 组实验分类正确率

组别	分类正确率	组别	分类正确率
G1	0.861	G11	0.833
G2	0.861	G12	0.861
G3	0.833	G13	0.889
G4	0.861	G14	0.833
G5	0.833	G15	0.861
G6	0.861	G16	0.806
G7	0.806	G17	0.861
G8	0.861	G18	0.833
G9	0.833	G19	0.889
G10	0.806	G20	0.861

图4.6为利用HOG特征与COHOG特征分类的结果比较。图中可明显看出两特征对于相同测试集的分类效果，曲线走向相对一致。两特征分类结果都相对稳定，浮动较小，对于同一测试集改用COHOG特征进行分类后大部分分类效果有提升，20组实验均无分类效果比HOG较差的情况出现。




图 4.6 20 组测试集分类正确率

为了详细查看分类情况，依然选取测试样本第5组与都12组，对其进行详细分析其分类情况。由表4.2可见，采用COHOG特征之后，两组图片分类正确率均有所提高，尤其各组内的闭

合图片集、开放图片集的分类都上升到了80%以上的较高准确率。

表4.2 第5组、第17组测试样本分类结果

		第5组分类结果		第17组分类结果	
		闭合	开放	闭合	开放
实际类别	闭合	11	2	11	2
	开放	4	19	3	20

4.5 小结

本章在上一章的基础之上，采用一种新的 HOG 方法，共生梯度方向直方图方法，增加了对梯度方向信息的利用，实验数据表明，改进的 COHOG 方法结合 SVM 分类器显著提高了眼前房角图片开放、闭合状态分类效果。本章从特征提取过程考虑，探究了梯度对方向信息与像素点空间位置信息对于丰富特征描述，从而增强分类效果的意义。首先，从 HOG 特征提取过程出发，考虑到梯度方向信息与两个像素点空间位置信息利用，采用了 COHOG 方法。然后基于 COHOG 本身的弱点，增加幅值信息作为梯度对统计加权值。最后基于数据高维不利于计算的问题，采用了经典的 PCA 方法对数据进行降维。分类实验结果表明，本文方法在对眼前房角闭合、开放两分类的研究中能够取得较好的分类效果，并且与之前方法相比，分类效果有显著的提升，十分利于眼前房角的开放程度评估。

第 5 章 基于多特征的青光眼前房角 OCT 图像多级评估

由前两章可知，眼前房角隐窝区域提取特征的质量好坏是影响眼前房角闭合程度评价结果的重要因素。因此如何提取能够提供充分区分信息的图像特征是青光眼眼前房角图像评估的关键。就眼前房角图像的评估而言，不论是早期的基于结构参数的分类方法，还是近来的基于图像特征的分类方法，应该说任何单一的特征都只是眼前房角成像的部分信息。如果试图获得更精确的评估效果，势必应该利用前述多个特征，全方位描述图像属性。基于多特征描述眼前房角成像的充分性以及眼前房角图像评估准确性的需求，本文提出一种结合梯度、COHOG、EDGELET 特征^{[48][49]}的图像描述方法，由于 COHOG 的特征值与前房角评估中极为重要的边缘信息密切相关，并且其可以利用梯度方向从局部和全局对形状复杂的物体进行描述，因此算法中考虑使用该特征对局部区域信息进行描述。同时，采用梯度描述图像的局部点信息，以及 EDGELET 描述局部边缘信息。这三个特征向量包含了细节到局部整体的图像信息，从点、线、面三个层次上描述眼前房角隐窝区域，保证房角分类的准确性与可靠性。另外，本文在对眼前房角图像进行闭合、开放分类的基础上，探究了眼前房角的多级评估，以实现房角状态更为细致、准确的描述。

青光眼图像多级评估流程图如图 5.1 所示。

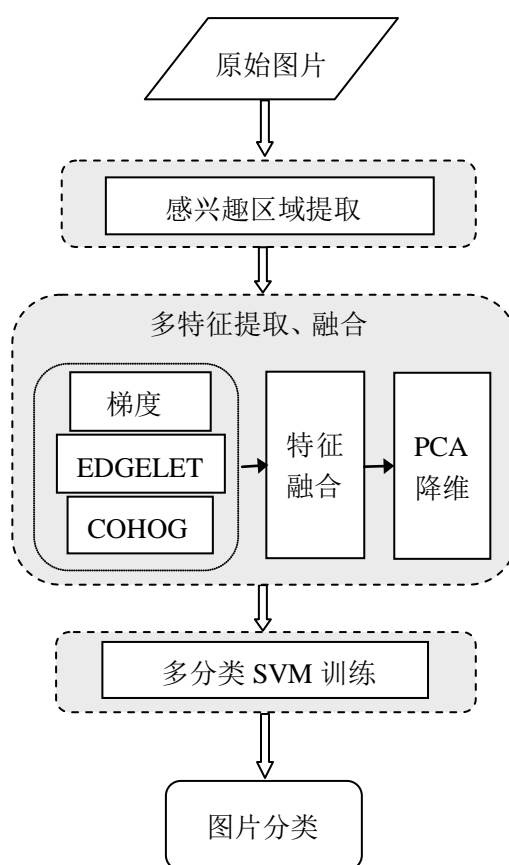


图 5.1 多特征分类流程图

5.1 特征选择

根据视觉特征分类可以将图像特征分为局部和全局特征。而由于图像中各部分所表达的图像内容的重要性是不同的,因此相对于全局特征而言,局部特征能够更好地反映图像内容。所以,在对眼前房角图像进行分级评估中,局部特征描述算法也是本文重点考虑的特征算法。

显著点为局部特征的一种,其定义为所获取的图像中亮度变化比较剧烈的点或图像边缘上曲率为极大值的点,常用的获取感兴趣点的算法包括 Harris 和 SUSAN 算子等。而对边缘特征的检测通常基于 Canny、Prewit 等检测算子。在众多的局部特征提取方法中, SIFT(Scale-Invariant Feature Transform)算法是应用最广泛的,它通过计算图像中的特征点及其有关的尺度和方向性,从而得到最终的特征描述子。但是 SIFT 算子计算数据量较大,特征提取消耗时间过长是很大的缺点。Bay 等^[50]基于 Hessian 矩阵对 SIFT 算法进行了改进,提出了 SURF(Speeded-Up Robust Features)算法,该算法的提出不仅保证了特征点提取的质量,同时更是大大降低了运算时间,不过,提高部分性能的同时,尺度和旋转的变换比 SIFT 又差了许多。除此外,本人在前期研究阶段还对一部分局部特征算法进行了深入的分析比较,例如 SIFT、PCA-SIFT、微分不变量、复杂滤波器、不变矩、互相关等,结果为基于 SIFT 的梯度位置方向直方图算法性能最好,而方向可调滤波器和不变矩算法对于低维的特征描述性能最好。另外, HOG 的方法最近比较流行,并且与 SIFT 有些相似,以至于很多使用者误以为 HOG 是 SIFT 的一种,其实他们只是具体操作有类似,在实际应用目标和处理惩罚细节有很大的区别。最重要的就是 SIFT 需要求极值点, HOG 只是均匀划分区域模块,并统计各模块梯度方向直方图。

前两章的研究当中,本文已经采用了 HOG、COHOG 特征提取方法,这也是近几年比较流行的使用梯度与直方图结合的形式特征提取算法,通过它们,可以很好的描述局部信息,在本章的研究中,依然选取此特征描述为想要选取的多个特征之一,根据之前的实验分析,我们选择改进的 COHOG 特征。另外,基于我们试图从局部点信息、局部边缘信息、局部区域信息三个层面来描述眼前房角隐窝区域,还要选择优秀的可以描述点与线的特征。梯度便是其中一个很好的描述点信息的方法,梯度运算后根据强度信息能方便找出边界点信息,操作简便且描述能力强。最后,对于边缘的描述,我们采用 EDGE LET 特征,它在描述局部轮廓信息的能力上较强。由于之前章节已经详细介绍了 COHOG 计算方法,因此下面只给出另两个特征的计算原理及过程。

5.2 特征提取过程

5.2.1 梯度计算

依然在提取的感兴趣区域上进行特征计算。

- (1) 采用 Sobel 梯度算子获得感兴趣区域 G 的梯度图 g_1 。
- (2) 计算出各像素点在 $\{0^\circ, 45^\circ, 90^\circ \text{ 和 } 135^\circ\}$ 四个方向上的梯度强度。四个方向的 Sobel 算子如图 5.2 所示。

- (3) 对于每一个像素点计算出四个方向上的梯度强度的均值，作为梯度特征进行后续计算。

-1	0	1
-2	0	2
-1	0	1

(a)0° 方向

-1	-2	-1
0	0	0
1	2	1

(b)90° 方向

-2	-1	0
-1	0	1
0	1	2

(c)45° 方向

0	1	2
-1	0	1
-2	-1	0

(d)135° 方向

图 5.2 四个方向 Sobel 算子模板

5.2.2 EDGELET 特征计算

为了计算 EDGELET 特征值，需采用一边长为 d (d 为奇数，且取值应较小) 的方形窗口 w 在感兴趣区域 g_1 内滑动，令 w 内的像素坐标为 (x, y) , $x=1, 2, \dots, d$, $y=1, 2, \dots, d$; EDGELET 特征计算步骤如下：

- (1) 根据梯度图中局部亮度极值处最接近于边缘的原理，在感兴趣区域 G 内逐行对图像 g_1 进行扫描以获取位于边缘位置的像素，从而获得该区域内角膜后边缘与虹膜前边缘的坐标位置。




图 5.3 方向量化图

- (2) 令方形子窗口 w 在检测到的边缘上逐点滑动，并计算其中心点 $c(x, y)$ 处的法线方向角 $\theta_E(x, y)$ ；。由于 d 取值较小，故该计算可近似为计算窗口内边缘两端所连接得到的直线与纵坐标的交角。并将 $\theta_E(x, y)$ 根据图 1 中方向量化图所示量化为 6 个角度，并分别以 0-5 这六个数字表示，得到角 $\beta_E(x, y)$ 。
- (3) 根据 g_1 中 $c(x, y)$ 点处的纵向和横向梯度值，计算出该点处的梯度方向角 $\theta_I(x, y)$ 。并将 $\theta_I(x, y)$ 根据图 5.3 中方向量化图所示量化为 6 个角度，并分别以 0-5 这六个数字表示，得到角 $\beta_I(x, y)$ 。

(4) 由式(5.1)可计算出点 $c(x, y)$ 处的 EDGELET 特征值 f 。

$$f(E, I, w) = \frac{1}{k} \sum_{i=1}^k M^I(u_i + w) \left| \left\langle n^I(u_i + w), n_i^E \right\rangle \right| \quad (5.1)$$

其中, k 为选取的边缘片段长度, $k=1, 2, \dots, d$; u_i 为子窗口中的坐标值 (x, y) , $x=1, 2, \dots, d$, $y=1, 2, \dots, d$; M^I 为 G 中像素点 $c(i, j)$ 的亮度; w 为子窗口在原图像中的坐标位移 (x, y) ; n^I 为像素点 c 的梯度向量; n_i^E 为像素点 c 的法向量; 将两个法向量的点由式(5.2)近似表示, 即可由式(5.3)得到点乘结果, 从而计算得到最终的 EDGELET 特征值 f 。

$$\left| \left\langle n^I(u_i + w), n_i^E \right\rangle \right| = L(\beta_I(u_i + w) - \beta_E) \quad (5.2)$$

$$L[n] = \begin{cases} 1 & n = 0 \\ \frac{4}{5} & n = \pm 1, \pm 5 \\ \frac{1}{2} & n = \pm 2, \pm 4 \\ 0 & n = \pm 3 \end{cases} \quad (5.3)$$

5.3 特征融合与降维

5.3.1 特征融合方法概述

对图像进行融合运算是为了最大化的利用图像纷繁复杂的数据, 图像融合分为三个层次, 像素级的融合、特征级的融合、决策级的融合。

目前, 特征融合的方法可大体分为三类: 一种是直接进行特征拼接, 串行拼接或并行拼接^[51], 拼接后得到新的融合特征, 这是使用最普遍的两种形式。串行特征融合方法一般要求特征能够具有较高的可靠性以及区分性; 并行特征融合方法要求待融合的特征具有较好的抗干扰能力, 同时也要求特征具有非常好的稳定性。另外一种是采用最优或智能计算方法通过特征选择, 对新组合的特征向量每一维选择出最优数据, 组合作为特征数据^[52]。最后一种是特征变换, 即使用一定的数学方法变换图像或者原始特征为一种全新的特征表达方式^[53]。

(1) 串行特征融合。

串行特征融合算法是对图像特征直接进行串联, 原理与操作都很简单, 公示表示如式(5.4), f_1, f_2, \dots, f_n 分别表示多个高维的特征, f_{new} 为串行操作后的新的特征。新的特征拥有更丰富、更详细的图像信息, 对于后期图像处理价值更高。而串行拼接的缺点就是数据直接连接容易造成维数灾难, 所以一般串行拼接融合之后需要采用降维方法对数据进行低维特征转换。

$$f_{new} = (f_1, f_2, \dots, f_n)^T \quad (5.4)$$

(2) 并行特征融合。

并行拼接特征融合算法是将需要融合的特征分别乘以权值然后在复向量空间相加，但是使用并行拼接融合算法需要注意三点，第一，要求参加融合的特征必具有相同的维数才能操作，如果维数不同需采用补零方式填充；第二，以复向量形式相加决定了只能融合两个特征，三个及以上特征无法实现；第三，其特征相加之前需作归一化处理，统一两特征的度量。并行特征融合计算方法如式(5.5)，

$$f_{new} = f_1 + f_2 \quad (5.5)$$

由于并行特征融合仅支持两类样本融合的局限性，现在不少学者改进多特征并行融合，其中也有不少成果，但是相对的集中在人脸检测、指纹识别等领域，且特征冗余严重，分类精度有待提高。

5.3.2 串行特征融合与降维

结合本研究三特征的特点，本文采用第一类经典的特征融合算法，对之前提取的梯度、EDGELET、COHOG 特征进行串行融合，并且在串行之后进行归一化，本文选用高斯归一化方法，以消除特征取值极大、极小造成的分布不均。最后进行数据降维，方便后续实验。

主要步骤为：

(1) 合并梯度、EDGELET、COHOG 特征形成特征矩阵，形式如式(5.6)。

$$T = \begin{bmatrix} \bar{T}_1 \\ \bar{T}_2 \\ \vdots \\ \bar{T}_n \end{bmatrix} = \begin{bmatrix} t_{11} & t_{12} & \cdots & t_{1p} \\ t_{12} & t_{22} & \cdots & t_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ t_{1n} & t_{2n} & \cdots & t_{nn} \end{bmatrix} \quad (5.6)$$

(2) 对 T 进行归一化。由于每个特征量纲不同，且维数不同，为了避免数据拼凑无实际意义以及过大的数据占据主导地位，我们需要对数据先进行归一化，以使每个特征发挥同等作用价值。 T 的第 $j(j=1,2,\cdots,p)$ 个列向量表示为 \bar{T}_j ，其均值 u_j 与方差 σ_j 计算如式(5.7)、(5.8)。

$$u_j = \frac{1}{n} \sum_{i=1}^n t_{ij} \quad (5.7)$$

$$\sigma_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (t_{ij} - u_j)^2} \quad (5.8)$$

然后进行归一化，每一个元素通过式(5.7)进行计算得到归一化结果。

$$t_{ij}^N = \frac{t_{ij} - u_j}{3\sigma_j} \quad (5.9)$$

(3) 降维。同样采用 4.3 节 PCA 降维方法进行降维，形成最终的低维综合特征。

5.4 多类分类器设计

支持向量机本是针对两类分类问题，但实际应用中面对的较多的是多分类问题。目前，

针对多分类问题提出多分类支持向量机^{[54][55]}算法已经很多，比较经典的有一对多方法^[56]、一对一方法、以及二叉树法等。而这些方法的根本无非是构建多个分类器来对样本数据进行多次多级分类。考虑本文面临的情境，我们的实验数据集是根据 shaffer 评级标准进行评级，闭合类中包含了 0、1、2 三个类别的样本，开放类包含了 3、4 级的样本，另外由于我们对于两分类问题已经取得了不错的成果，所以在此基础之上在考虑进行下一步细分，前提条件较好，操作的可行性更高。故我们采用二叉树分类方法。主要思路如图 5.4 所示，通过设计四个分类器完成最终五级的分类。通过分类器 1 区分闭合、开放两类，然后对两类分别通过分类器 2 与分类器 3 进行分类，开放类通过分类器 2 可细分出 3、4 级的房角，而闭合类通过分类器 3 区分出 0 级与 1、2 级的合类，合类再通过分类器 4 实现 1、2 级的分类。

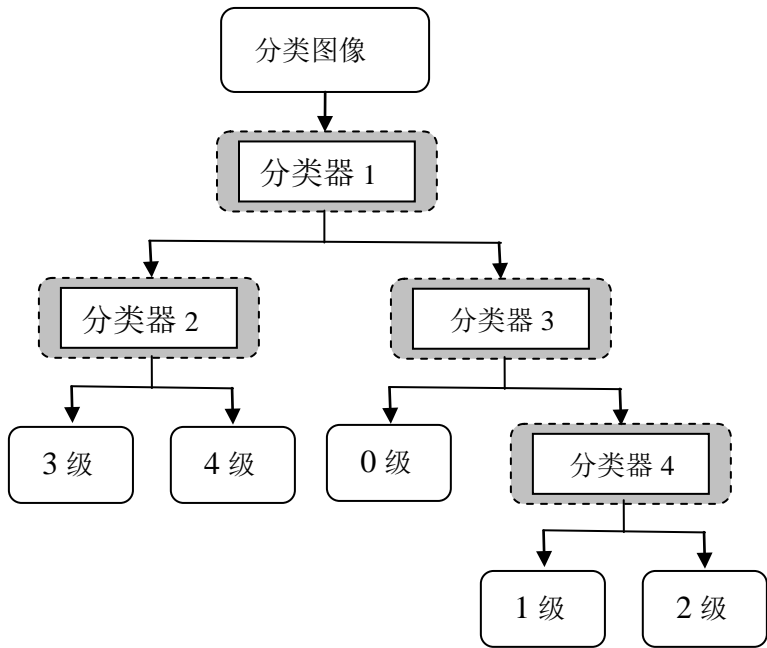


图 5.4 基于二叉树分类器设计

5.5 两级评估及结果分析

采用综合图像特征对眼前房角图片进行分类是一个新的尝试，首先将其应用于眼前房角闭合、开放两分类实验，通过与单一特征分类结果对比，验证新算法的有效性。在分类效果良好的基础之上再对图像进行多级分类。

这部分实验我们仍然沿用之前的数据集，采用相同的训练集与测试集进行分类。采用最初的 20 组样本进行分类测试，统计分类结果，将分类结果与之前方法进行比较，结果如图 5.5。




图 5.5 三种方法分类结果对比

三个方法实验结果对比可得，多特征的方法在分类效果上明显强于单一特征分类。平均正确率上来分析，利用HOG、COHOG、多特征分类三个方法，结果分别为81.8%、84.7%、和90.8%，多特征的利用对分类结果的提升高出不少。

对于第5组与第17组的分类详细结果如表5.1可见，多特征对第5组、第17组图片的两个类别的分类正确率分别为88.9%与94.4%，都达到了较高的准确率。可以在此基础上进行更加细致的五级分类。

表 5.1 第 5 组、第 17 组多特征分类结果

		第5组分类结果		第17组分类结果	
		闭合	开放	闭合	开放
实际类别	闭合	11	2	13	2
	开放	2	21	0	21

5.6 多级评估及结果分析

5.6.1 实验样本选取

首先考虑到细分分类时样本的均衡性，先对数据集合适的样本进行筛选。本文所采用的数据集五级房角分类根据 shaffer 方法评级如表 5.2。由表格可看出，对于大类划分，样本相对均衡，而对于五级划分，样本采集并不平均。尤其在训练分类器 3 时，需要用到 0 级与 1、2 级的合级进行训练分类器，如果各级按照相同比例划分训练集与测试集，那么训练分类器 3 时两类训练样本比例将会达到 1: 2.4，样本分布的失衡不能正确反映整个类的实际分布，从而使训练的分类器无效。虽然支持向量机能够在有限的样本寻求最佳的分类，但是应用于不平衡数据集时，分类性能也是大打折扣^[57]。为了在训练分类器时能够构成相对均衡的样本分布，我们重新选定测试集与训练集，新的数据集表 5.2 中最后两行。

表 5.2 原始数据集与本次实验选取的数据集

类别	大类	闭合类(PACG)			开放类(POAG)	
	Shaffer	0	1	2	3	4
人数(共 15 人)		2	2	3	4	4
图片数(共 180 幅)		25	24	3	42	53
新划分数据集	训练集	18	10	1	19	19
	测试集	7	7	7	7	7

5.6.2 多级评估结果

接下来进行分类器训练按照图 5.4 中的设计思路结合新选取的训练集，分别训练四个分类器，并且实现多级分类器的连接。对测试集进行分类，统计分类结果如图表 5.3。首先，五个类别的分类正确率都在不算低的范围，证实了本文思路的可行性。虽然每一类都有错分的数据，但整体分类正确率达到了 80%，整体分类具有较好的效果。

表 5.3 多特征分类结果详细分析

		分类结果				
		0	1	2	3	4
实际类别	0级	6	1	1	0	0
	1级	1	5	0	0	1
	2级	0	0	6	0	1
	3级	0	1	0	6	0
	4级	0	0	0	1	5

为了验证分类效果的稳定性，我们依然采取依照预设训练集与测试集随机选取多组情况的实验方式。本文选取 10 组随机实验，每一级的分类正确率统计如表 5.4 与图 5.6。




图 5.6 多特征分类结果

平均正确率来看，五级的分类结果相当，集中在 70% 左右，最高不超过 78%，最低不低

于 68%。另外有结果数据可看的出，第 3 级错误率最高，应该跟其处于闭合与开放两类的分界值处有关，本身信息区分度不高，分类结果也就较低。

表 5.4 多特征分类结果

组别	各类分类正确率				
	0 级	1 级	2 级	3 级	4 级
g1	0.714	0.857	0.571	0.714	0.857
g2	0.714	0.857	0.857	0.714	0.857
g3	0.875	0.714	0.571	0.571	0.857
g4	0.714	0.857	0.714	0.857	0.857
g5	0.571	0.857	0.571	0.714	0.714
g6	0.714	0.857	0.857	0.857	0.714
g7	0.875	0.571	0.714	0.857	0.714
g8	0.714	0.857	0.571	0.714	0.857
g9	0.875	0.714	0.714	0.714	0.571
g10	0.714	0.571	0.714	0.714	0.571
平均	0.743	0.771	0.686	0.743	0.728

5.7 小结

多特征的融合应用已经在图像分类等领域中广泛应用。本章综合考虑后，采用 COHOG 特征对局部区域信息进行描述、采用梯度描述图像的局部点信息以及 EDGELET 描述局部边缘信息。从点、线、面三个层次上描述眼前房角隐窝区域细节到局部整体的图像信息。首先，分别提取三个特征，再融合形成一个特征；然后构造多级分类器用于房角状态五级分类。最后，考虑数据集样本分布的不均衡性，重新选取数据集。最后，通过两级与多级分类证实了多特征提取对于增强分类效果的有效性以及多级分类评估的可行性。不过，临床检测中不允许有失误出现，每一个被检查者需要被告知准确的患病消息。多级分类的实现不是提提想法就有进展的，现实的分类结果还有待提高。

第 6 章 总结与展望

6.1 本文总结

青光眼的高发病率以及高致盲率，使得对青光眼早期的检查提出了更高的要求，对于智能化高速发展的今天，自动化检测是趋势也是必然。依靠 OCT 成像技术的发展，眼前房角区域成像成为可能，青光眼病变的结构信息以图片的形式被复制下来。基于青光眼结构参数测量对房角评级的研究成果不断涌现。然而，青光眼患者房角结构信息本来就丰富多样，紧靠单一的或者几个结构参数很难精确描述房角的状态，况且手工测量结构参数还存在客观操作误差与主观性误差，自动测量又过度依赖图像的质量。所以目前的研究成果都有相当强的局限性，普适性普遍偏低。针对房角区域难以描述的问题，本文引入视觉图像特征进行研究，通过高维的视觉图像特征代替简单的结构参数特征，再结合性能优越的支持向量机分类器进行房角状态分类。

本研究初期进行了两类状态的分级研究，即房角开放与闭合的分类。首先基于只对患病区域进行分析的观点，采用了一种基于特征边缘的感兴趣区域自动提取方法，为精确进行分类提供了前提条件。然后经过对多种图像特征提取方法比较，选择了对局部边缘信息描述较有优势的 HOG、COHOG 特征分别进行实际应用，并在应用过程中根据实际需求进行改进创新，使其更好地描述房角特有的结构。

眼前房角两分类问题的探究仅是青光眼自动检查研究内容的冰山一角，如何保证实际应用中的正确率，如何能像医生一样看一看就知道患者处于哪个阶段、严重程度与否都是进一步研究的重点、难点。基于此，本文进一步探究利用视觉特征对眼前房角进行更加细致的分类。考虑到图像分类中较常采用的多特征方法，本文提出了基于梯度、EDGELET、COHOG 三个特征的房角五级细分方法，并在初步应用中取得了良好的效果，证明了该方法的可行性。

论文具体研究工作总结如下：

- (1) 基于增强操作针对性的需求，提出了一种基于特征边缘的感兴趣区域提取方法。该方法采用多步骤图像预处理操作及自动房角分割、像素灰度连续性边缘检测等手段保证了房角感兴趣区域的精确分割提取。然后利用 HOG 方法进行感兴趣区域特征提取，结合支持向量机方法进行房角闭合、开放状态分类。实验结果表明：采用高维的视觉特征取代医学解剖特征进行房角状态的判断效果优良。
- (2) 在 HOG 成功应用的基础上，考虑了对像素点空间位置信息的利用，从而引入了 COHOG 方法。但是该方法未对像素点梯度幅值信息加以利用，于是本文应用了一种改进的 COHOG 方法，利用余弦定理方式计算梯度幅值与方向信息作为统计直方图时的加权值，弥补了该方法的先天不足。然后基于高维数据特征的计算难度，本文又引入了 PCA 方法对高维数据进行降维分析，以利于后续试验顺利进行，仍然采用支持向量机方法训练、

分类。实验结果表明：空间信息的利用、幅值信息的增加以及数据降维方法的保障，极大的提升了房角闭合、开放状态分类效果。

- (3) 最后，考虑到房角分类在实际应用中更加细致的划分需求。本文又提出一种基于多特征的眼前房角状态多级评估方法。为了更加细致、全面的描述感兴趣区域，本文综合考虑后采用梯度、EDGELET、COHOG 特征描述眼前房角区域，另外，基于多特征分类需要，设计了多分类 SVM 分类方法，保证五级分类的技术实施。实验结果证明，利用多特征进行两分类效果明显优于单特征，进行多分类效果也非常显著。

6.2 未来展望

本文将高维的视觉特征应用于眼前房角状态的分类评估，证实了视觉特征替代医学解剖结构特征的可行性。多种特征的尝试在不断提升分类结果的同时探究了深入研究的可行性。但是仍有诸多不足之处与仍需进一步探究的问题：

首先，感兴趣区域提取工作中，本文提出的自动化提取方法是基于数据集参数最优的方法，并未考虑具体图像参数最优，以致提取的感兴趣区域具有个体迁就整体的特点。是否可提出一种算法，针对具体图片各个参数调优后选取感兴趣区域，是今后值得研究的方向。

其次，对于感兴趣区域的特征提取，本文现在所采用的图像特征大部分来自于行人检测领域，应用效果尚可但相对于更加适合眼前房角结构的改进方法或者依据眼前房角结构专门设计的特征来说业余了许多。另外，多特征的融合技术以及如何选取合适的特征进行融合也值得思考。后续工作可以针对特征提取方面进一步探究。

最后，本文利用了支持向量机分类方法，但仅是采用，并未针对性的改进算法以提高分类效果。两分类的应用效果还不错，但是对于多分类问题，更强分类效果的算法以及增强对分类样本数据不平衡的支持都是有待提升的研究重点。

致谢

在论文即将完成之际，敲下“致谢”两个字，心中无限感慨。转眼间，三年的研究生求学生活即将结束，站在毕业的门槛上，回首往昔，奋斗和辛劳成为丝丝的记忆，甜美与欢笑也都尘埃落定。杭州电子科技大学以其优良的学习风气、严谨的科研氛围教我求学，以其博大包容的情怀胸襟、浪漫充实的校园生活育我成人。值此毕业论文完成之际，我谨向所有关心、爱护、帮助我的人们表示最诚挚的感谢与最美好的祝愿。

回眸过去，一路走来，需要感谢的人太多，实在是这些简单的文字所不能表达和承载的。首先诚挚的感谢恩师范影乐教授对我的严格要求和悉心指导，导师渊博的学识、非凡的气质、敬业的工作作风、独特的人格魅力，始终感染着我、激励着我，这些都将作为宝贵的财富让我享用终身。谢谢您，无论是做人还是做学问，您将是我永远的榜样。

感谢我的师姐，杭州电子科技大学武薇老师，您总是会耐心认真的以您博学的知识为我解答实验中碰到的难题，从我论文的初始思路到实验的实施再到实验数据的分析，每一步都有武老师精深的思想在里面，在此向您表示深切的谢意与祝福！。

感谢我的室友，感谢我实验室的小伙伴，感谢你们在我实验紧张的时候帮我做实验，在我论文写作时提供修改意见，作业交付时陪我通宵熬战，闲暇无事时陪我逛街聊天。轻松愉快的实验室生活、美好温馨的宿舍生活总能带给我一份好心情，让我在杭电求学的日子过的惬意而又充实。愿情谊不散，友谊长存！

感谢我的家人，不管我的人生路上是风雨交加还是阳光灿烂，始终对我的不离不弃。正是你们的关爱让我充满勇气和自信，前行的道路举步维艰，但有你们相伴，我不会畏缩。

感谢所有认识或不认识的善良人们在我撰写论文期间给予我的各种有形或无形的帮助，我的天空因你们而变得精彩和美好，我追寻梦想的脚步因你们而变得轻盈和坚定。

下沙 杭州电子科技大学
二零一四年十二月二十日

参考文献

- [1] Resnikoff S, Pascolini D, Etya'ale D, et al. Global data on visual impairment in the year 2002[J]. Bulletin of the World Health Organization, 2004, 82(11): 844-851.
- [2] Quigley H A, Broman A T. The number of people with glaucoma worldwide in 2010 and 2020[J]. British Journal of Ophthalmology, 2006, 90(3): 262-267.
- [3] 葛坚. 问题和争论是学科发展的动力——原发性闭角型青光眼分类争论的启示[J]. 中华眼科杂志, 2006, 42(11): 964—966.
- [4] 毛文书, 孙信孚. 眼科学, 第三版[M]. 北京: 人民卫生出版社, 1994: 107-108.
- [5] 刘家崎, 李凤鸣. 实用眼科学, 第二版[M]. 人民卫生出版社, 北京, 1984: 414-420.
- [6] Tateno Y, Iinuma T, Takahashi M. Computed radiography[J]. 1987.
- [7] 李文华, 王滨, 王振常, 曹庆选. 眼科影像学[M]. 人民卫生出版社, 2004.
- [8] Dellaporta A. Historical notes on gonioscopy[J]. Survey of Ophthalmology, 1975, 20(2): 137-149.
- [9] Chandler P A. Narrow-angle glaucoma[J]. AMA Arch Ophthalmol, 1952, 47(6): 695-716.
- [10] Ronald F L. A history of primary angle closure glaucoma[J]. Survey of Ophthalmology, 1995, 40(2): 163-170.
- [11] Pavlin C J, Harasiewicz K, Foster F S. Ultrasound biomicroscopy of anterior segment structures in normal and glaucomatous eyes[J]. American Journal of Ophthalmology, 1992, 113(4): 381-389.
- [12] Scheie H G. Width and pigmentation of the angle of the anterior chamber - a system of grading by gonioscopy[J]. AMA archives of Ophthalmology, 1957, 58(4): 510-512.
- [13] Shaffer R N. A new classification of the glaucomas[J]. Transactions of the American Ophthalmological Society, 1960, 58: 219-225.
- [14] Spaeth G L. The normal development of the human anterior chamber angle: A new system of descriptive grading[J]. Transactions of the Ophthalmological Societies of the UK, 1971, 91: 709-739.
- [15] Qin B, Francis B A, Li Y, et al. Anterior Chamber Angle Measurements Using Schwalbe's Line With High-resolution Fourier-Domain Optical Coherence Tomography[J]. Journal of glaucoma,

2013, 22(9): 684-688.

- [16]戴惟葭, 杨惠清, 潘秀云. Stratus 相干光断层扫描仪检测激光虹膜切开术前后的房角变化[J]. 眼科, 2007, 16(4): 273-275.
- [17]Leung C K, Yung W, Yiu C K, et al. Novel approach for anterior chamber angle analysis: anterior chamber angle detection with edge measurement and identification algorithm (ACADEMIA)[J]. Archives of ophthalmology, 2006, 124(10): 1395-1401.
- [18]Radhakrishnan S, See J, Smith S D, et al. Reproducibility of anterior chamber angle measurements obtained with anterior segment optical coherence tomography[J]. Investigative ophthalmology & visual science, 2007, 48(8): 3683-3688.
- [19]Console J W, Sakata L M, Aung T, et al. Quantitative analysis of anterior segment optical coherence tomography images: the Zhongshan Angle Assessment Program[J]. British Journal of Ophthalmology, 2008, 92(12): 1612-1616.
- [20]Li H, Leung C K S, Cheung C Y L, et al. Repeatability and reproducibility of anterior chamber angle measurement with anterior segment optical coherence tomography[J]. British Journal of Ophthalmology, 2007, 91(11): 1490-1492.
- [21]Cheung C Y, Zheng C, Ho C L, et al. Novel anterior-chamber angle measurements by high-definition optical coherence tomography using the Schwalbe line as the landmark[J]. British Journal of Ophthalmology, 2010: bjo. 2010.189217.
- [22]Tian J, Marziliano P, Baskaran M, et al. Automatic anterior chamber angle assessment for HD-OCT images[J]. Biomedical Engineering, IEEE Transactions on, 2011, 58(11): 3242-3249.
- [23]武薇. 基于 OCT 图像的房角开放距离计算机辅助测量研究[D]. 浙江大学, 2012.
- [24]Xu Y, Liu J, Tan N M, et al. Anterior chamber angle classification using multiscale histograms of oriented gradients for glaucoma subtype identification[C]. Proc. Engineering in Medicine and Biology Society (EMBC), 2012 Annual International Conference of the IEEE. IEEE, 2012: 3167-3170.
- [25]Itti L. Automatic foveation for video compression using a neurobiological model of visual attention[J]. IEEE Transactions on Image Processing, IEEE Transactions on, 2004, 13(10): 1304-1318.
- [26]Stejic Z, Takama Y, Hirota K. Relevance feedback-based image retrieval interface incorporating region and feature saliency patterns as visualizable image similarity criteria[J].

- IEEE Transaction on Industrial Electronics, IEEE Transactions on, 2003, 50(5): 839-852.
- [27] Siagian C, Itti L. Biologically-inspired robotics vision monte-carlo localization in the outdoor environment[C].Proc. IEEE/RSJ International Conference on. IEEE, 2007: 1723-1730.
- [28] Soyer C, Bozma H I, Istefanopulos Y. Attentional sequence-based recognition: Markovian and evidential reasoning[J].IEEE.Transactions on Systems, Man, and Cybernetics, Part B: Cybernetics, 2003, 33(6): 937-950.
- [29] Moghaddam B, Biermann H, Margaritis D. Defining image content with multiple regions-of-interest[C].Proc.IEEE Wokshop on Content-Based Access of Image and Video Libraries,1999:89-93.
- [30] Das M, Riseman E M, Draper B A. FOCUS: Searching for multi-colored objects in a diverse image database[C].Proc.IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 1997: 756-761.
- [31] Schmid C, Mohr R, Bauckhage C. Evaluation of interest point detectors[J]. International Journal of computer vision, 2000, 37(2): 151-172.
- [32] Loog M, Lauze F. The improbability of Harris interest points[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 32(6): 1141-1147.
- [33] Sebe N, Lew M S. Salient Points for Content-Based Retrieval[C].Proc.BMVC. 2001, 1: 401-410.
- [34] Itti L, Koch C, Niebur E. A model of saliency-based visual attention for rapid scene analysis[J]. IEEE Transactions on pattern analysis and machine intelligence, 1998, 20(11): 1254-1259.
- [35] Hou X, Zhang L. Saliency detection: A spectral residual approach[C]Computer Vision and Pattern Recognition, 2007.. IEEE Conference on CVPR'07, 2007: 1-8.
- [36] Stentiford F W M. Attention-based image similarity measure with application to content-based information retrieval[C].Proc.Electronic Imaging 2003. International Society for Optics and Photonics, 2003: 221-232.
- [37] Hu Y, Rajan D, Chia L T. Adaptive local context suppression of multiple cues for salient visual attention detection[C].Proc. IEEE International Conference on Multimedia and Expo, 2005: 4 pp.
- [38] 刘恒. 虚拟背景照相实时人像分割技术及应用[D]. 重庆大学, 2004.

- [39]舒添慧, 胥布工, 胡战虎. 基于区域生长法的医学图像分割[J]. 微计算机信息, 2008, 24(18): 284-285.
- [40]Friedman N, Geiger D, Goldszmidt M. Bayesian network classifiers [J]. Machine Learning, 1997, 29: 131-163.
- [41]Cortes C, Vapnik V. Support-vector networks[J]. Machine learning, 1995, 20(3): 273-297.
- [42]Vapnik V. The nature of statistical learning theory[M]. springer, 2000.
- [43]Watanabe T, Ito S, Yokoi K. Co-occurrence histograms of oriented gradients for human detection[J]. IPSJ Transactions on Computer Vision and Applications, 2010, 2: 39-47.
- [44]邓君坪. 基于共生与非共生梯度直方图的人体检测[D]. 天津大学, 2010.
- [45]闫贺. 基于共生梯度方向直方图的实时人手检测系统[D]. 天津大学, 2012.
- [46]Smola A J, Schölkopf B. A tutorial on support vector regression[J]. Statistics and computing, 2004, 14(3): 199-222.Smola A J, Schölkopf B. A tutorial on support vector regression[J]. Statistics and computing, 2004, 14(3): 199-222.
- [47]Turk M, Pentland A. Eigenfaces for recognition[J]. Journal of cognitive neuroscience, 1991, 3(1): 71-86.
- [48]Wu B, Nevatia R. Detection and tracking of multiple, partially occluded humans by bayesian combination of edgelet based part detectors[J]. International Journal of Computer Vision, 2007, 75(2): 247-266.
- [49]Wu B, Nevatia R. Detection of multiple, partially occluded humans in a single image by bayesian combination of edgelet part detectors[C]. Tenth IEEE International Conference on Computer Vision, 2005, 1: 90-97.
- [50]Bay H, Ess A, Tuytelaars T, et al. Speeded-up robust features (SURF)[J]. Computer vision and image understanding, 2008, 110(3): 346-359.
- [51]Yang J, Yang J, Zhang D, et al. Feature fusion: parallel strategy vs. serial strategy[J]. Pattern Recognition, 2003, 36(6): 1369-1381.
- [52]Wang D, Ge W, Wang Y. Using bidirectional Binary Particle Swarm Optimization for feature selection in feature-level fusion recognition system[C]. 4th IEEE Conference on Industrial Electronics and Applications, 2009: 3810-3814.
- [53]王大伟.基于特征级图像融合的目标识别技术研究[D].中国科学院研究生院博士学位论

文, 2010:39-67.

- [54] Weston J, Watkins C. Multi-class support vector machines[R]. Technical Report CSD-TR-98-04, Department of Computer Science, Royal Holloway, University of London, May, 1998.
- [55] Hsu C W, Lin C J. A comparison of methods for multiclass support vector machines[J]. IEEE Transactions on Neural Networks, , 2002, 13(2): 415-425.
- [56] Kreßel U H G. Pairwise classification and support vector machines[C]. Proc. Advances in kernel methods. MIT Press, 1999: 255-268.
- [57] Maldonado S, Montecinos C. Robust classification of imbalanced data using one-class and two-class SVM-based multiclassifiers[J]. Intelligent Data Analysis, 2014, 18(1): 95-112.

附 录

作者在读期间发表的学术论文及参加的科研项目

发表(录用)学术论文：

- 基于 HOG 的眼前房角 OCT 图像分类[J]，工业控制计算机，已录用，待发表。

申请发明专利：

- 基于 OCT 影像的眼前房角开放程度多特征分类方法，已公开，201410252480.0，2/4。

参与的科研项目：

- 基于图像特征分类的眼前房角开放程度评估(Y201328513)，浙江省教育厅科研项目。