

◎图形图像处理◎

基于生物视觉机制的图像特征点检测方法

李嘉祥, 范影乐, 武 薇

LI Jiaxiang, FAN Yingle, WU Wei

杭州电子科技大学 自动化学院, 杭州 310018

College of Automation, Hangzhou Dianzi University, Hangzhou 310018, China

LI Jiaxiang, FAN Yingle, WU Wei. Image feature point detection method based on biological vision mechanism. *Computer Engineering and Applications*, 2018, 54(7): 182-187.

Abstract: The feature point detection plays an important role in the sequential process of image analysis and understanding. This paper proposes a new method of image feature point detection, which is based on the mechanism of visual receptive field and information flow feedback. By using the simple photoreceptor cell layer of the receptive that has a self-adaptive structure, a gross detection of the feature points of Gaussian differences acquired with convolution operation is conducted; redundant points are removed with the feedback mechanism of pulse information flow, and representative feature points are finally obtained under the visual attention mechanism. Although there are significantly fewer final feature points in the new algorithm than the traditional, when the image is rotated by 30°, 60°, 90° and the scale transformation is 0.8, 0.9, 1.1 and 1.2 respectively, image feature points in the new algorithm show more stable consistency. The method of feature point detection discussed in the paper provides a brand-new and effective idea for image processing based on visual physiological characteristics.

Key words: feature points detection; self-adaption receptive field; feedback of neurons; visual attention mechanism

摘 要: 特征点检测性能对于后续图像分析和理解起着关键的作用, 基于视觉感受野以及信息流反馈等视觉机制, 提出了一种图像特征点检测新方法。利用感受野自调节特性构造简单细胞感光层, 对卷积运算所获取的高斯差异结果进行特征点粗检测; 利用脉冲信息流的反馈机制进行冗余点的剔除, 最终获得视觉注意机制下的代表性特征点。在图像旋转角度为 30°、60°、90°, 尺度变换因子为 0.8、0.9、1.1 和 1.2 时, 新方法在最终特征点数量均显著少于传统算法的情况下, 图像特征点一致性稳定性结果较优, 该方法将为生物视觉机制及其在图像处理中的应用提供崭新而有效的思路。

关键词: 特征点检测; 自调节感受野; 神经元反馈; 视觉注意机制

文献标志码: A **中图分类号:** TP317.4 **doi:** 10.3778/j.issn.1002-8331.1611-0186

1 引言

图像特征点检测是图像配准、拼接或分析处理的关键步骤之一, 传统的特征点检测方法^[1]主要包括: (1) 基于图像灰度信息的方法, 例如 Susan 算子^[2], 虽然其定位检测速度快, 但是简单的阈值法筛选结果较差。(2) 基于相关性的方法, 例如 Moravec 算子^[3], 由于其窗口的移动

方向有限, 所以其误检率偏大。(3) 基于方向梯度的方法, 例如传统 DOG 算子^[4], 由于单一的筛选阈值导致存在边缘冗余点较多的缺陷。

随着视觉神经计算研究的深入, 基于视觉注意机制的海量数据特征检测方法受到了关注。例如, 尺度不变特征变换 Sift 算法^[4-5]和基于视觉优先选择的数据驱动

基金项目: 国家自然科学基金(No.61501154)。

作者简介: 李嘉祥(1991—), 男, 硕士研究生, 研究方向: 视觉神经计算与图像处理; 范影乐(1975—), 通讯作者, 男, 博士, 教授, 研究方向: 机器视觉与机器认知, E-mail: fan@hdu.edu.cn; 武薇(1979—), 女, 博士, 讲师, 研究方向: 医学图像处理。

收稿日期: 2016-11-09 **修回日期:** 2017-02-23 **文章编号:** 1002-8331(2018)07-0182-06

CNKI 网络优先出版: 2017-05-18, <http://kns.cnki.net/kcms/detail/11.2127.TP.20170518.1758.006.html>

视觉注意机制^[6]等研究,它们虽然从生物视觉的角度来考虑数据的特征提取问题,但更多的只是对视觉神经系统的黑箱模拟。而本文认为包括感受野等特性在内的视觉信息处理机制,在视觉特征点检测中扮演着重要角色。因此,本文提出并实现了一种利用视觉感受野对图像全局或局部特征调节机制;在剔除边缘冗余点时,提出了一种视皮层(Primary Visual Cortex, V1)神经信息层间反馈机制的实现方法,并最终基于视觉注意机制实现特征点的提取。

2 基本原理

2.1 视觉感受野调节机制

考虑到外膝体神经元对快速连续变化的均匀亮度刺激有显著的反应^[7],因此可以认为在变化的局部均匀亮度刺激(差异性小)时,感受野的兴奋性更强,其兴奋区敏感度增强,其抑制区半径变小,高斯卷积差异变小,特征点存在概率小;在不均匀的亮度刺激(差异性大)的情况下,则有相反的结论。

根据模型参数随图像局部亮度方差变化的规则,本文提出了一种根据局部特征自调节参数的DOG感受野模型。考虑图像亮度方差的输入数据范围与感受野兴奋区域敏感度、抑制区域半径的输出数据范围,通过一种改进的sigmoid模型来实现模型的参数调节。改进后的感受野模型如式(1)~(3)所示:

$$G(x) = A_1 e^{-(x^2+y^2)/\sigma_1^2} - A_2 e^{-(x^2+y^2)/\sigma_2^2} \quad (1)$$

$$A_1 = r_{b_1} + \frac{r_{oc}}{(1 + \exp((l \times Dif + m)))}, A_2 = a_{12} \cdot A_1 \quad (2)$$

$$\sigma_2 = r_{b_2} + r_{b_2} - A_1, \sigma_1 = \frac{1}{a_{12}} \cdot \sigma_2 \quad (3)$$

其中, $G(x, y)$ 为感受野模型, A_1 为兴奋区敏感度, A_2 为抑制区敏感度, σ_1 为兴奋区半径, σ_2 为抑制区半径, a_{12} 为最优关系因子, Dif 为局部像素亮度值方差, r_{oc} 、 r_{b_1} 与 r_{b_2} 为输出调整基数, l 为输入调整, m 为平移调整。本文选取 Dif 作为图像的一个局部特征,根据特征差异性对DOG感受野的兴奋区域敏感度与抑制区域半径进行不同取值,以达到对图像局部自适应调整的目的。

2.2 视觉感受野与成像

感受野对光的接收传递,可认为是对图像局部光信息的视觉感受野处理传递^[8],所以本文将DOG感受野模型与经灰度化后的图像局部进行卷积遍历的方式来进行模拟,卷积计算利用不同尺度下高斯平滑结果的差异性来实现,具体可将两个不同尺度高斯平滑的效果重叠观察,若其特征点处的差异较明显,即选取其局部差异绝对值最大值点为特征点。高斯模型与图像的卷积示意图如图1所示,其中 σ 为高斯函数的尺度值。




图1 不同尺度高斯模糊与高斯差

2.3 初级视皮层的神经元反馈

神经生理实验表明,位于枕叶皮层的V1,每一层都有密集的侧向连接的神经元,并且不同层次之间具有特定的反馈投射,这将有助于利用视觉信息流的全局理解结果来实现对于局部检测过程的调控。因此本文在图像特征点提取的过程中,引入了视觉神经的信号发放对感受野接受光刺激的反馈过程,将有利于特征点的筛选,使边缘冗余点最大程度地去除。

2.3.1 视网膜神经网络的次序编码

考虑到神经元生理模型的仿真效率,本文选取 izhikevich 神经元模型^[9-10]来构造基于点阵结构的神经网络,网络单元数学表达式如式(4)所示:

$$\begin{cases} \frac{dv}{dt} = 0.04v^2 + 5v + 140 - u + I_{ext} \\ \frac{du}{dt} = a(bv - u) \\ \text{if } v \geq v_{thresh}, \text{ then } v \leftarrow c, u \leftarrow u + d \end{cases} \quad (4)$$

式中, v 、 v_{thresh} 、 u 分别为膜电位、触发电位以及恢复变量, I_{ext} 为外界激励,如果 v 大于等于 v_{thresh} ,神经元发放脉冲,同时 v 被重新设定为 c , u 被重置为 $u + d$;如果 v 未超过阈值 v_{thresh} ,那么神经元不发放动作电位。此模型反映了神经元膜电位与离子通道开合之间的动力学关系,因此模型参数具有明确的电生理意义,通常可设置为 $a = 0.02$, $b = 0.2$, $c = -65$, $d = 6$, $v_{thresh} = 30$ ^[11]。

2.3.2 视神经反馈机制

视觉系统可以看作是一个鲁棒性较强的闭环控制反馈控制系统^[12],通过对光线和其他外界环境的特征来调节视觉系统中的各个环节,使最后的视觉感知效果达到最佳状态。因此,本文提出一种通过计算图像边缘细节的丰富程度,来确定DOG卷积图像中的特征点初步筛选阈值Thresh的方法。其中,边缘丰富程度用边缘像素点个数占原图总像素个数的比例来表示,边缘像素占有比比比较高,则调高初选阈值Thresh,控制特征点数量;边缘像素占有比比比较低,则调低初选阈值Thresh,保证特征点数量,其占有率与阈值设定如式(5)和(6):

$$rat = n_{edge}/n_{all} \quad (5)$$

$$Thresh = \begin{cases} t_a, & rat > r_c \% \\ t_b, & rat < r_c \% \end{cases} \quad (6)$$

其中, n_{edge} 为边缘像素个数, n_{all} 为原图像素总个数, rat 为边缘像素占有率, t_a 与 t_b 为初步筛选阈值, r_c 为占有

率阈值。基于数据图库中 DOG 卷积差异值的统计以及卷积实验,为将大部分的冗余点进行初步剔除,在卷积图中,根据特征点数量程度以及边缘比例程度选定阈值变化区间,通过 rat 大小定义初选阈值 $Thresh$ 的大小。

本文又将边缘矩阵以正负元素矩阵形式(即除了边缘点,矩阵中其他元素均为零)反馈加至灰度原图,以达到更彻底剔除边缘冗余点的目的,判断是否为需要剔除的冗余点的算法,定义如下:

$$\omega = -\frac{i_{\text{edge}}(x_c, y_c) - \text{imean}}{|i_{\text{edge}}(x_c, y_c) - \text{imean}|} \times \sum_{(x, y) \in RF} \frac{(i_{\text{edge}}(x, y) - i_{\text{edge}}(x_c, y_c))^2}{(\text{imax} - \text{imin})^2} \quad (7)$$

$$\text{if } \begin{cases} i_{\text{edge}}(x_c, y_c) = \text{imin} \text{ or } \text{imax} \\ 0 < |\omega| < \omega_a \end{cases},$$

$$\text{then } T(x_c, y_c) = (\text{imax} - \text{imin}) \times \frac{i_{\text{edge}}(x_c, y_c)}{|i_{\text{edge}}(x_c, y_c)|} \\ \text{else } T(x_c, y_c) = 0 \quad (8)$$

其中,将 $i(x, y)$ 定义为原图, $i_{\text{edge}}(x, y)$ 为原图所对应的边缘图, RF 为神经元感受野, $i_{\text{edge}}(x_c, y_c)$ 代表边缘中任意一点为中心的 3×3 矩阵的中心点, imean 为该矩阵对应的原图同位置矩阵元素的平均值, imin 与 imax 分别为矩阵的最小值和最大值, ω 为该矩阵中心点与临近点的差异性值,其绝对值越大,该 3×3 局部中心与周边差异越大,越有可能为真实特征点。满足式(8)两个条件,则该点是需要进行反馈剔除的伪特征点,一为矩阵中心是该局部的极值点;二为局部矩阵差异值 ω 未达到所定的差异, ω_a 为差异阈值。 $T(x_c, y_c)$ 为计算后赋给该中心点的值,若 $T(x_c, y_c)$ 为正数,则为正反馈,用以剔除伪极大值特征点;若为负数,则为负反馈,用以剔除伪极大值特征点。

2.4 视觉注意机制

大脑存在着对视觉信息的滤除或者选择过程,即选择注意机制^[13-14],其可简化外界视觉场,提高神经计算的效率。本文利用视觉注意机制,针对前述获取的特征点,剔除冗余点,筛选出更有代表性的点,具体实现过程如式(9)和(10)所示:

$$\begin{cases} i_{\text{point}}(x, y) = 0, & i_{\text{point}}(x, y) > \text{imin}_{\text{point}} \\ i_{\text{point}}(x, y) = 0, & i_{\text{point}}(x, y) < \text{imax}_{\text{point}} \end{cases} \quad (9)$$

$$\text{if } |\text{imax}_{\text{point}}| > |\text{imin}_{\text{point}}|$$

$$\text{then } i_{\text{point}}(x, y) = \text{imax}_{\text{point}}$$

$$\text{else } i_{\text{point}}(x, y) = \text{imin}_{\text{point}} \quad (10)$$

利用窗口遍历图像的方式进行代表性特征点筛选和冗余点剔除,初步检测后,窗口中的点均为特征点,其中,最小值特征点为 $\text{imin}_{\text{point}}$,最大值特征点为 $\text{imax}_{\text{point}}$, $i_{\text{point}}(x, y)$ 为特征点图。

3 特征点检测算法

首先对 RGB 图像灰度化预处理,利用由局部像素亮度差异计算参数的 DOG 感受野模型与图像卷积,得到 DOG 卷积差异性图;利用神经元首次放电时间以及感受野内各神经元首次放电次序得到图像边缘,从而计算得到图像细节丰富程度,以此决定初步特征点筛选阈值;同时利用边缘提出神经元反馈矩阵以剔除边缘冗余点;最后引入视觉注意机制,筛选出最终代表性特征点。具体检测过程如下所述:

(1) 计算局部亮度差异。根据待处理原始 RGB 图 $i(x, y)$ ($x = 1, 2, \dots, m; y = 1, 2, \dots, n$), 长宽均按图像的 $1/10$ 进行分块处理,提取该局部的亮度矩阵 $I_{\text{lum}}(x, y)$, 局部亮度差异通过计算矩阵内所有亮度值的方差 Dif_n ($n = 1, 2, \dots, n$) 进行表示。

(2) 自适应 DOG 感受野与图像卷积获得卷积差异图。利用式(2)和(3)与步骤(1)得到的各个局部亮度值差异计算得到 DOG 兴奋区敏感度 A_1 , 抑制半径参数 σ_2 , 结合 σ_1 与 σ_2 , A_1 与 A_2 的最佳关系取值,本文取 0.8 倍为最佳因子。将得到的 DOG 模型如式(1)与局部灰度图像进行卷积,得到卷积图。依次计算各局部对应的 DOG 感受野模型,完成对整幅图像的卷积处理,得到最终卷积差异图。

(3) 神经元次序编码得到神经元发放边缘矩阵。对步骤(2)中的卷积图输入到如式(4)所示的点阵神经元 $N(x, y)$ ($x = 1, 2, \dots, m; y = 1, 2, \dots, n$), 统计神经元脉冲,记录下每个神经元的最初发放时间,获得发放后的边缘矩阵 $i_{\text{edge}}(x, y)$ ($x = 1, 2, \dots, m; y = 1, 2, \dots, n$)。

(4) 反馈矩阵获得与初步特征点筛选阈值确定。利用式(7)对步骤(3)所得的边缘点进行判断,若判断为冗余点,则对该边缘点重新按式(8)赋值,进行正负反馈;若判断为非冗余点,则赋值为 0,即不做任何反馈;整体赋值结束得到反馈矩阵 $T(x_c, y_c)$ 。再次利用步骤(3)得到的边缘矩阵,利用式(5)计算其边缘占有率,对初步特征点筛选阈值 i_{th} 进行赋值,根据数据图库中差异值范围选取以及统计结果,式(5)和(6)的参数选择为 $t_a = 5$, $t_b = 4$, $r_c = 5$, 式(8)中的 $\omega_a = 0.4$ 。

(5) 反馈矩阵反馈剔除边缘冗余点。步骤(4)得到的反馈矩阵 $T(x_c, y_c)$, 与待输入灰度图 $i_g(x, y)$ 相加,减小伪极大值点特征点的值,增大伪极小值特征点的值,达到剔除冗余点目的的预处理得到新输入图 $i_{\text{in}}(x, y)$ 。

$$i_{\text{in}}(x, y) = i_g(x, y) + T(x_c, y_c) \quad (11)$$

(6) 特征点的初步筛选。对步骤(2)得到的整体卷积图,利用 3×3 窗口进行遍历,窗口内 9 个矩阵值 $i_{\text{DOG}}(x, y)$ ($x = 1, 2, 3; y = 1, 2, 3$) 中,若矩阵中心点 $i_{\text{DOG}}(2, 2)$ 满足步骤(4),利用式(6)计算所得的初步特征点筛选阈

值 $Thresh$ 进行筛选,为最大值则选取为极大值特征点,若为最小值则为极小值特征点。

(7)代表性特征点的最终筛选。对步骤(6)得到的初步特征点,分别用3个大小不同的窗口遍历,窗口大小以最佳效果经验值选取为 5×5 、 6×6 与 7×7 ,每个窗口在每一个位置均按式(9)和(10)作筛选,剔除窗口内冗余点,保留最具代表性特征点。得到3组特征点 $result_1(x,y)$, $result_2(x,y)$, $result_3(x,y)$ ($x=1,2,\cdots,m; y=1,2,\cdots,n$),最后将3个窗口得到的结果相与,同一位置中3种程度特征点出现次数两次及以上时,则认定该特征点为最终特征点,否则剔除该点,得到最终结果。

$$result(x,y)=\sum_{i=1}^3 result_i(x,y) \tag{12}$$

$$i_{result}(x,y)=\begin{cases} 1, & result(x,y)=2 \text{ or } 3 \\ -1, & result(x,y)=-2 \text{ or } -3 \\ 0, & result(x,y)=0, -1 \text{ or } 1 \end{cases} \tag{13}$$

其中,一个极大值赋值为1,一个极小值赋值为-1,保证一个位置出现一次以上同一类特征点,将该点记作此类最终代表性特征点,式(13)中-2和-3代表同一位置标记为-1的极小值出现两次和三次,2和3代表同一位置标记为1的极大值出现两次和三次,以此类推,最终极大值与极小值特征点重新赋值为1与-1。

4 实验结果与分析

由于建筑图像所具有的丰富特征和细节,因此是特征点检测的经典对象。本文选取华盛顿大学的Ground truth Database中的建筑图像作为实验用图,其中部分用图如图2所示。首先选取前述中的3种主流检测算法(Moravec、Susan与DOG)结果与本文结果进行定性比较,考虑到篇幅,不失一般性,仅针对实验用图的局部特

征进行分析讨论,检测结果图如图3~5所示。然后从数据库中选取6幅图像,采用特征点一致性CCN方法对检测结果进行评价^[15]。

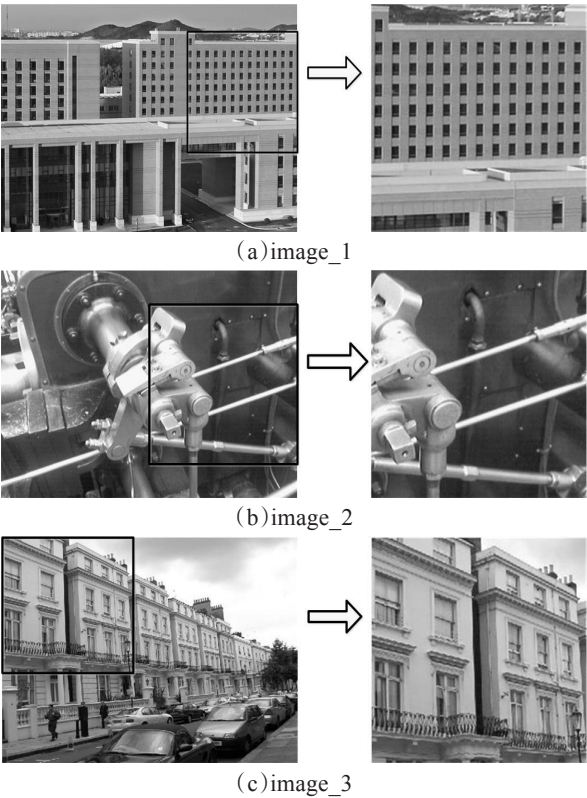


图2 实验图片

图3~5分别是对 image_1~3 进行特征点检测后的结果图。在图3~5中,图(a)是采用Moravec算子检测后的特征点图像,图(b)是采用Susan算子检测后特征点的图像,图(c)是采用传统DOG检测算法获得的结果,图(d)是采用本文方法获得的特征点图像。

观察图3~5,可以发现Moravec方法,对于例如图2




图3 image_1 的处理结果




图4 image_2 的处理结果




图5 image_3 的处理结果

(a)对应的局部特征点多且分布规律性强的图像,简单阈值化操作无法达到最佳效果;Susan方法,存在局部尤其是边缘部分过检,导致特征点密集;DOG方法,其极大值特征点与极小值特征点分布过于紧密甚至重合,简单改变阈值减少伪特征点的同时,真正的特征点也会同时被剔除。而本文方法,检测获得的特征点代表性更强,减少了极大值特征点与极小值特征点的频繁邻接,将有利于后续图像匹配与处理。

特征点检测可以用稳定性的准则来对其进行评价,其中特征点一致性 CCN 方法是一种被广泛认可的评价准则, CCN 定义为式(14):

$$CCN = 1.1^{-|N_t - N_0|} \times 100\% \tag{14}$$

其中 N_0 表示在原图像中检测到的特征点数量, N_t 表示经过各种图像变换之后检测到的特征点数量, CCN 越大,则表示检测算法的稳定性更好。

实验1 对图像进行旋转变换,选定角度为 30° 、 60° 、 90° ,检测记录变换图像的特征点^[16]。

实验2 对图像进行尺度变换,尺度变换因子选定为 0.8、0.9、1.1 和 1.2,检测记录变换图像的特征点。

实验数据结果分别为 CCN 值、总特征点数量与算法运行时间的比较, CCN 是原图像与变化后图像特征点数量的差异体现,根据式(14)定义, CCN 数值越大说明原图像与变化图像的特征点数量差异越小,算法稳定性越高; CCN 数值越小说明原图像与变化图像的特征点数量差异越大。特征点总数量则说明算法的精确性和对特征信息数量的控制,特征点数量较小则精确性越高,有利于提高后续图像处理效率,如表1~4所示。

在传统 DOG 算法基础上,基于图像局部感受野自适应与视觉注意机制,本文提出代表性特征点筛选以及神经元反馈冗余点剔除的新方法,其中自调节的感受野

表1 各图像在旋转角度变换下的 CCN 均值

图像编号	Moravec算法	Susan算法	原始DOG	本文方法
Image1	3.12×10^{-29}	5.03×10^{-6}	3.94×10^{-13}	8.10×10^{-6}
Image2	1.36×10^{-12}	3.33×10^{-6}	1.76×10^{-8}	4.36×10^{-5}
Image3	3.16×10^{-11}	3.83×10^{-11}	4.50×10^{-7}	1.55×10^{-4}
Image4	5.85×10^{-18}	2.80×10^{-5}	0.13	0.97
Image5	2.58×10^{-8}	1.76×10^{-31}	2.92×10^{-10}	4.64×10^{-7}
Image6	1.93×10^{-12}	3.22×10^{-10}	2.06×10^{-8}	1.03×10^{-4}

表2 各图像在尺度变换下的 CCN 均值

图像编号	Moravec算法	Susan算法	传统DOG	本文方法
Image1	2.13×10^{-33}	3.57×10^{-61}	1.32×10^{-12}	3.91×10^{-4}
Image2	3.97×10^{-5}	0.001 2	0.072 0	0.061 0
Image3	8.76×10^{-30}	8.56×10^{-60}	2.58×10^{-8}	2.21×10^{-4}
Image4	1.80×10^{-22}	2.62×10^{-28}	4.49×10^{-7}	0.001 9
Image5	5.65×10^{-22}	2.13×10^{-73}	1.45×10^{-14}	0.004 1
Image6	1.29×10^{-67}	4.21×10^{-95}	3.23×10^{-6}	0.011 3

表3 各方法检测原图的特征点数对比

图像编号	Moravec算法	Susan算法	传统DOG	本文方法
Image1	1 933	3 858	1 488	1 225
Image2	357	664	199	213
Image3	1 961	4 434	1 510	1 243
Image4	1 688	5 156	1 334	1 140
Image5	1 454	2 385	801	672
Image6	2 650	5 943	2 354	1 656

表4 各方法检测原图的运行时间对比

图像编号	Moravec算法	Susan算法	传统DOG	本文方法
Image1	3.2	19.4	4.9	5.8
Image2	2.4	16.6	3.6	4.5
Image3	4.2	24.3	5.3	7.6
Image4	4.3	38.2	6.2	8.3
Image5	2.8	18.2	3.5	4.2
Image6	4.7	39.1	6.5	8.4

DOG 模型能使特征点确定更加精确,视觉注意机制能使特征点检测更加精简,神经元反馈则剔除了一部分冗余点。因此,与 Moravec、Susan 和原始 DOG 方法相比,其特征点一致性 CCN 数值总体上处于最大,大约处于 $10^{-1} \sim 10^{-7}$ 量级之间,表示在图像发生旋转和尺度变换时整体稳定性较好。尤其是在图像尺度变化条件下,本文方法的稳定性远远超过其余3种算法,其 CCN 级别处于 $10^{-2} \sim 10^{-4}$ 之间,意味着将有利于后续图像多尺度和多角度下的配准与处理任务。与之相对应的,对比的三种方法都是单阈值处理,很难在保证特征点的条件下使冗余点数降低到预期数量。对于传统 DOG 的处理结果,可以看出相对于 Moravec 算法和 Susan 算法,在控制特征点堆积数量和图像旋转处理检测稳定性上有一定优势,但是相对于本文方法不具有优势,原因可能在于考虑到了视觉感受野模型的作用,但是仅仅对其进行了单阈值筛选,并未真正实现内部视觉机制的特性。而 Moravec 算法和 Susan 算法在稳定性和特征点堆积的数

据评价上不具优势,这可能是由于两者均未考虑到视觉机制的作用。通过各算法在不同图像上的检测运行时间的分析对比,本文在视觉通路信息流处理过程中以串行方式实现包括感受野在内的视觉机制作用,因此从耗时上来看运行时间与传统 DOG 接近,略微落后于 Moravec 算法, Susan 算法效果较差,综合考虑检测效果与检测效率,本文方法在特征点检测中具有较好的检测优势,因此在两个图像变换的实验数据评价中,上述算法检测效果不如本文方法。

5 结论

本文引入了自调节视觉感受野、次序编码、神经元反馈机制以及视觉注意机制,并对其原理及功能进行介绍,提出了一种基于 RGB 图像自调节感受野的特征点检测方法,通过与 Moravec 算子、Susan 算子以及 DOG 方法的比较分析,表明本文提出的方法在高分辨率图像的特征点检测上能够更精确、更稳定地选出代表性特征点。以多细节建筑图的特征点检测为例,获得的特征点更加精简且更具有代表性。本文提出的基于图像自调节感受野的特征点检测方法,将为 RGB 大图像特征点检测技术提供新的思路,后续可针对生物视觉机制中的网络结构和动态突触互连在图像特征点检测中的作用进一步深入研究。

参考文献:

- [1] Sedaghat A, Ebadi H. Remote sensing image matching based on adaptive binning sift descriptor[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(10): 5283-5293.
- [2] Fan X, Cheng Y, Fu Q. Moving target detection algorithm based on susan edge detection and frame difference[C]// Proceedings of the 2nd International Conference on Information Science and Control Engineering, 2015: 323-326.
- [3] Biswas B, Chakrabarti A, Dey K N. Image registration method using harris corner and modified hausdorff distance with near set[C]// Proceedings of the IEEE 2nd International Conference on Recent Trends in Information Systems, 2015: 393-398.
- [4] Almaadeed S, Bouridane A, Crookes D, et al. Partial shoe-print retrieval using multiple point-of-interest detectors and sift descriptors[J]. Integrated Computer-aided Engineering, 2015, 22(1): 41-58.
- [5] Chang L, Duarte M M, Sucar L E, et al. A bayesian approach for object classification based on clusters of sift local features[J]. Expert Systems with Applications, 2012, 39(2): 1679-1686.
- [6] Borji A, Itti L. State-of-the-art in visual attention modeling[J]. IEEE Transactions on Pattern Analysis and Machine intelligence, 2013, 35(1): 185-207.
- [7] Wu J, Shi G, Lin W, et al. Reduced-reference image quality assessment with orientation selectivity based visual pattern[C]// Proceedings of the IEEE China Summit and International Conference on Signal and Information Processing, 2015: 663-666.
- [8] Torrealão J R A, Victor S M C, Amaral M S. Signal-tuned gabor functions as models for stimulus dependent cortical receptive fields[J]. Neural Computation, 2014, 26(5): 920-952.
- [9] Liu C, Wang J, Yu H, et al. Dynamical analysis of parkinsonian state emulated by hybrid izhikevich Neuron Models[J]. Communications in Nonlinear Science and Numerical Simulation, 2015, 28(1): 10-26.
- [10] 王典, 范影乐, 张梦楠, 等. 基于突触连接视通路方位敏感的图像分级边缘检测方法[J]. 中国生物医学工程学报, 2015, 34(5): 522-532.
- [11] Izhikevich E M. Simple model of spiking neurons[J]. IEEE Transactions on Neural Networks, 2003, 14(6): 1569-1572.
- [12] Kazantsev V B, Gordleeva S Y, Stasenko S V, et al. Appearance of multistability in a neuron model with network feedback[J]. JETP Letters, 2013, 96(11): 739-742.
- [13] Wu Q X, McGinnity T M, Maguire L, et al. A visual attention model based on hierarchical spiking neural networks[J]. Neurocomputing, 2013, 116: 3-12.
- [14] Li J, Duan H. Novel biological visual attention mechanism via Gaussian harmony search[J]. Optik-International Journal for Light and Electron Optics, 2014, 125(10): 2313-2319.
- [15] Mokhtarian F, Mohanna F. Performance evaluation of corner detectors using consistency and accuracy measures[J]. Computer Vision and Image Understanding, 2006, 102(1): 81-94.
- [16] 李伟生, 韦巧燕. 一种无阈值的冗余角点去除方法[J]. 计算机应用与软件, 2014, 31(8): 141-144.